

人工智能学院2024级本科生课程

# 《机器学习》

## 第九章(补充) 高斯混合模型及EM算法

吉林大学 人工智能学院

授课教师：王鑫

# 内 容 大 纲

- 高斯分布
- 高斯模型
- 高斯混合模型
- 极大似然估计
- 高斯混合模型求解

# 高斯分布


- 定义

- 正态分布 (normal distribution) ，是一种在自然界大量的存在的、最为常见的分布形式。

$$f(x | \mu, \sigma^2) = \frac{1}{\sqrt{2\sigma^2\pi}} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

- 参数

- 参数 $\mu$ 表示均值
- 参数 $\sigma$ 表示标准差





# 高斯分布

- 高斯分布建模

采样数据




Figure 2.9 Histogram of a normal distribution, in this case the height of 334 fictitious people. The modal (most frequently occurring) bin is centered at 180 cm.

均值180cm附近, 20~30是标准差

建模数据




Figure 2.10 Fictional data on the height of 334 people. The sample probability of a given user occurring in a given height range is shown in red (the bar on the left in each pair). The probability from a Gaussian model, with parameters  $\mu=180, \sigma=28$ , is shown in green (the bar on the right).

$$\mu = 180, \sigma = 28$$

# 高斯模型

- 一维数据高斯模型

- 当样本数据  $X$  是一维数据(Univariate)时，高斯分布的概率密度函数 (Probability Density Function) :

$$P(x | \theta) = \frac{1}{\sqrt{2\pi\sigma^2}} \exp\left(-\frac{(x - \mu)^2}{2\sigma^2}\right)$$

- 当样本数据  $X$  是多维数据(Multivariate)时，高斯分布的概率密度函数:

$$P(x | \theta) = \frac{1}{(2\pi)^{\frac{D}{2}} |\Sigma|^{\frac{1}{2}}} \exp\left(-\frac{(x - \mu)^T \Sigma^{-1} (x - \mu)}{2}\right)$$

- $\mu$  为数据均值(期望),  $\Sigma$  为协方差(Covariance),  $D$  为数据维度

# 高斯混合模型

- 定义

- 生成模型，它假设观测数据是由多个高斯分布组合而成的，每个高斯分布称为一个分量，这些分量通过权重来控制其在数据中的贡献

- 高斯混合模型的概率分布为

$$p_{\mathcal{M}}(\mathbf{x}) = \sum_{i=1}^k \alpha_i \cdot p(\mathbf{x} \mid \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)$$

- $k$ 表示混合模型中子高斯模型的数量
- 参数集合， $\alpha_i$ 表示是观测数据属于第 $i$ 个子模型的概率， $\mu_i$ 和 $\sigma_i$ 期望和方差
- $p(\mathbf{x} \mid \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)$ 表示第 $i$ 高斯分布密度函数



# 高斯混合模型

- 举例




Figure 2.11 Probability distributions of height for men and women. Note that these probabilities are conditioned on the fact that gender is known: so, for example, given that we know a particular person is a woman, her probability of having a height in a particular bucket can be read off the y-axis.



# 极大似然估计

- 定义

- 一种给定观察数据来评估模型参数的方法，即：“模型已定，参数未知”，其中重要假设：采样都是独立同分布
- 概率  $p(x|\theta)$ ， $x$  表示样本数据， $\theta$  表示模型的参数
  - $\theta$  已知， $x$  是变量，函数叫**概率函数形式**，对于不同的样本  $x$ ，其出现概率是多少；
  - $x$  已知， $\theta$  是变量，函数叫**似然函数形式**，对于不同参数，出现样本  $x$  的概率是多少；
- 利用已知的样本，反推最大概率导致样本出现的模型参数，通过极大似然估计方法求出



# 极大似然估计

- 联合概率分布

$$P(X; \theta) = P(x^{(1)}, \dots, x^{(N)}; \theta) = \prod_{i=1}^N P(x_i; \theta)$$

- 参数  $\theta$  影响着样本产生的概率，思考  $\theta$  的真实值如何获取？从参数空间  $\Theta$  选出来一个最好的参数。思考什么是最好？最好的标准是什么？
- 概率越大，事件发生可能性越大； $P(X; \theta)$  越大，样本  $X$  可能就越接近真实值

- 似然函数

- 在概率统计中，将观测样本的联合概率看成一种为似然 (likelihood) 形式，一般用符号  $L(\theta; X) = P(X; \theta)$  表示，选择参数  $\theta$  使得联合概率最大。

# 极大似然估计

- 参数 $\theta$ 的最大似然估计值

$$\hat{\theta}_{ML} = \arg \max_{\theta} L(\theta; X) = \arg \max_{\theta} \prod_{i=1}^N P(x_i; \theta)$$

- 概率相乘，连乘会趋近于0，通常加对数的似然函数，对数似然函数

- 

$$\ell(\theta; X) = \log L(\theta; X)$$

$$\hat{\theta}_{ML} = \arg \max_{\theta} \ell(\theta; X)$$

$$= \arg \max_{\theta} \log \prod_{i=1}^N P(x_i; \theta)$$

$$= \arg \max_{\theta} \sum_{i=1}^N \log P(x_i; \theta)$$

直接求解

$$\frac{\partial \ell}{\partial \theta} = 0$$

# 高斯混合模型求解

- EM 算法

- 高斯混合模型的对数似然函数

$$\log L(\theta) = \sum_{j=1}^N \log P(x_j | \theta) = \sum_{j=1}^N \log \left( \sum_{k=1}^K \alpha_k \phi(x | \theta_k) \right)$$

- 单个高斯模型可使用最大似然法来求导求得使 likelihood 最大的参数，但多个高斯模型则需要通过迭代的方法求解。
  - 前面公式中  $X$  表示完整数据样本，这些样本都是可观测。在实际应用中，只能观察到部分数据，即不完全数据集。假设有观测数据集  $X$  和未观测（隐含）变量数据集  $Z$ ，对  $\Theta$  最大似然估计，

$$L(\Theta | X) = \ln(P(X | \Theta)) \quad \longrightarrow \quad L(\Theta | X, Z) = \ln(P(X, Z | \Theta))$$



# 高斯混合模型求解

- EM 算法

- 基本思想：若参数 $\Theta$ 已知，则可根据训练数据推断出最优隐变量 $Z$ 的值（E步）；若 $Z$ 的值已知，则可方便地对参数 $\Theta$ 更新，获得极大似然估计（M步）。

- E步：以当前参数 $\Theta^t$ 推断隐变量分布 $P(Z|X, \Theta^t)$ ，并计算对数似然 $L(\Theta|X, Z)$ ，即隐含变量 $Z$ 的期望，

$$Q(\mathbf{Z} | \Theta^t) = \mathbb{E}_{\mathbf{Z}|\mathbf{X}, \Theta^t} L(\Theta | \mathbf{X}, \mathbf{Z})$$

- M步：使用E步骤中计算的隐含变量的期望，重新估计参数，从而最大化观察数据的完全数据对数似然，即通过最大化完全数据的似然来重新估计参数

$$\Theta^{t+1} = \arg \max_{\Theta} Q(\mathbf{Z} | \Theta^t) = \arg \max_{\theta} \sum_{\mathbf{Z}} Q(\mathbf{Z} | \theta^{(t)}) \log \frac{p(\mathbf{X}, \mathbf{Z} | \theta)}{Q(\mathbf{Z} | \theta^{(t)})}$$

谢谢！