

人工智能学院2025级本科生课程

《机器学习》

第十三章 半监督学习

吉林大学 人工智能学院

授课教师：王鑫

内 容 大 纲

- 未标记样本
- 生成式方法
- 半监督SVM
- 嵌图半监督学习
- 半监督聚类


未标记样本

- 形式化定义
 - 训练样本集 $D_l = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_l, y_l)\}$, 称为“有标记(labeled)”样本;
 - $D_u = \{\mathbf{x}_{l+1}, \mathbf{x}_{l+2}, \dots, \mathbf{x}_{l+u}\}, l \ll u$, 称为“未标记(unlabeled)”样本.
- 存在问题
 - 若 D_l 较小, 训练样本不足, 模型易过拟合, 即泛化能力差
 - 标记成本很高! 费时、费力
 - 如何充分利用 D_u 所包含信息? —> 主动学习和半监督学习

主动学习


- 主动学习

- 利用 D_l 训练模型，挑选未标记数据询问专家，加入 D_l 重新训练模型
- 每次挑选Hard Samples，即对改善模型性能最大的样本
- 目标：使用尽量少的“Query”来获得尽量好的性能
- 引入专家知识，将部分未标记样本转化为有标记样本



未标记样本的效用

- 如何利用未标记样本?
 - 未标记样本与标记样本服从同一独立分布将有助于建立模型
 - 若仅基于图中的一个正例和一个反例，则由于待判别样本恰位于两者正中间，大体上只能随机猜测；若能观察到图中的未标记样本，则将很有把握地判别为正例。



半监督学习

- 半监督学习
 - 需求强烈，易于收集大量未标记样本，而获取标记样本费时费力
 - “有标记数据少，未标记数据多”，比如医学影像、网页等
- 利用数据分布信息与类别标签联系的假设
 - “聚类假设”：假设数据存在簇结构，同一个簇的样本属于同一个类别.
 - “流形假设”：即假设数据分布在一个流形结构上，邻近的样本拥有相似的输出值.

"相似的样本有相似的输出"

半监督学习

- 半监督学习

- Inductive纯半监督学习:

- 假定训练数据中的未标记样本并非待预测的数据
- 基于"开放世界"假设, 希望学得模型能适用于训练过程中未观察到的数据



半监督学习

- 半监督学习

- Transductive 直推学习:

- 假定学习过程中所考虑的未标记样本恰是待预测数据，学习的目的就是在这些未标记样本上获得最优泛化性能.
- 直推学习是基于"封闭世界"，仅试图对学习过程中观察到的未标记数据进行预测.



内 容 大 纲

- 未标记样本
- 生成式方法
- 半监督SVM
- 嵌图半监督学习
- 半监督聚类

生成式方法

- 生成式模型
 - 假设所有数据都是由潜在的同一模型“生成”；
 - 通过潜在模型的参数将未标记数据与学习目标联系起来，而未标记数据的标签则可看作模型的缺失参数；
 - 利用 EM 算法进行极大似然估计求解；
 - 此类方法的区别主要在于生成式模型的假设，不同的模型假设将产生不同的方法，比如朴素贝叶斯模型；
 - 给定样本 x ，其真实类别标记为 $y \in Y$ ，其中 $Y = \{1, 2, \dots, N\}$ 为所有可能的类别。

生成式方法

- 生成式模型

- 假设样本由高斯混合模型生成，且每个类别对应一个高斯混合成分（即混合成分与类别之间一一对应）。数据样本是基于概率密度生成：

$$p(\mathbf{x}) = \sum_{i=1}^N \alpha_i \cdot p(\mathbf{x} \mid \mu_i, \Sigma_i)$$

- 其中，混合系数 $\alpha_i \geq 0$, $\sum_{i=1}^N \alpha_i = 1$; $p(\mathbf{x} \mid \mu_i, \Sigma_i)$ 是样本 x 属于第 i 个高斯混合成分的概率； μ_i, Σ_i 分别表示高斯混合成分的参数。

生成式方法

- 由最大化后验概率可知:

$\Theta \in \{1, 2, \dots, N\}$ 表示样本 x 隶属的高斯混合成分

$$f(x) = \arg \max_{j \in \mathcal{Y}} p(y = j | x)$$

$$= \arg \max_{j \in \mathcal{Y}} \sum_{i=1}^N p(y = j, \Theta = i | x)$$

边缘化 $P(A|X) = \sum_B P(A, B|X)$ 公式表示 x 由第 i 个高斯合成分生成且其类别为 j 的概率;

$$= \arg \max_{j \in \mathcal{Y}} \sum_{i=1}^N p(y = j | \Theta = i, x) \cdot p(\Theta = i | x)$$

$p(A, B|X) = p(B|X) \cdot p(A|B, X)$

$$p(y = j | \Theta = i)$$

由于每个类别对应一个高斯混合成分, 与 x 无关.

公式表示样本 x 由第 i 个高斯混合成分生成的后验概率

$$p(\Theta = i | x) = \frac{\alpha_i \cdot p(x | \mu_i, \Sigma_i)}{\sum_{i=1}^N \alpha_i \cdot p(x | \mu_i, \Sigma_i)}$$

生成式方法

- 由最大化后验概率可知：

$$f(\mathbf{x}) = \arg \max_{j \in \mathcal{Y}} p(y = j \mid \mathbf{x})$$

$$= \arg \max_{j \in \mathcal{Y}} \sum_{i=1}^N p(y = j, \Theta = i \mid \mathbf{x})$$

$$= \arg \max_{j \in \mathcal{Y}} \sum_{i=1}^N p(y = j \mid \Theta = i, \mathbf{x}) \cdot p(\Theta = i \mid \mathbf{x}) , \quad (13.2)$$

- 式 (13.2) 中估计 $p(y = j \mid \Theta = i, \mathbf{x})$ 需知道样本标签，因此仅能使用有标记数据；而 $p(\Theta = i \mid \mathbf{x})$ 不涉及样本标记，有标记和未标记数据均可利用，通过引入大量的未标记数据，对这一项的估计可望由于数据量的增长而更为准确，于是式 (13.2) 整体的估计可能会更准确。

- 未标记数据可以辅助提高分类模型的性能

生成式方法

- 假设样本独立同分布，且由同一个高斯混合模型生成，用极大似然法来估计高斯混合模型的参数 $\{(\alpha_i, \mu_i, \Sigma_i) \mid 1 \leq i \leq N\}$, $D_l \cup D_u$ 的对数似然函数：

$$LL(D_l \cup D_u) = \sum_{(x_j, y_j) \in D_l} \ln \left(\sum_{i=1}^N \alpha_i \cdot p(x_j \mid \mu_i, \Sigma_i) \cdot p(y_j \mid \Theta = i, x_j) \right) \\ + \sum_{x_j \in D_u} \ln \left(\sum_{i=1}^N \alpha_i \cdot p(x_j \mid \mu_i, \Sigma_i) \right)$$

- 由两项组成：基于有标记数据 D_l 的有监督项和基于未标记数据 D_u 的无监督项。
- 高斯混合模型 **参数估计** 利用 EM 算法求解。

$$p(x_j, y_j) = \sum_{i=1}^N p(x_j, y_j, \Theta = i) = \sum_{i=1}^N \alpha_i \cdot p(x_j \mid \mu_i, \Sigma_i) \cdot p(y_j \mid \Theta = i, x_j). \quad p(x_j) = \sum_{i=1}^N p(x_j, \Theta = i) = \sum_{i=1}^N \alpha_i \cdot p(x_j \mid \mu_i, \Sigma_i).$$

生成式方法

- E 步: 根据当前模型参数计算未标记样本 x_j 属于各高斯混合成分的概率

$$\gamma_{ji} = \frac{\alpha_i \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)}{\sum_{i=1}^N \alpha_i \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)}$$

$$\alpha_i = \frac{l_i}{|D_l|}, \text{ where } |D_l| = \sum_{i=1}^N l_i$$

$$\boldsymbol{\mu}_i = \frac{1}{l_i} \sum_{(\mathbf{x}_j, y_j) \in D_l \wedge y_j = i} \mathbf{x}_j$$

$$\boldsymbol{\Sigma}_i = \frac{1}{l_i} \sum_{(\mathbf{x}_j, y_j) \in D_l \wedge y_j = i} (\mathbf{x}_j - \boldsymbol{\mu}_i) (\mathbf{x}_j - \boldsymbol{\mu}_i)^\top$$

- M 步: 基于 γ_{ji} 更新模型参数, 其中 l_i 表示第 i 类的有标记样本数目:

$$\boldsymbol{\mu}_i = \frac{1}{\sum_{\mathbf{x}_j \in D_u} \gamma_{ji} + l_i} \left(\sum_{\mathbf{x}_j \in D_u} \gamma_{ji} \mathbf{x}_j + \sum_{(\mathbf{x}_j, y_j) \in D_l \wedge y_j = i} \mathbf{x}_j \right)$$

$$\boldsymbol{\Sigma}_i = \frac{1}{\sum_{\mathbf{x}_j \in D_u} \gamma_{ji} + l_i} \left(\sum_{\mathbf{x}_j \in D_u} \gamma_{ji} (\mathbf{x}_j - \boldsymbol{\mu}_i) (\mathbf{x}_j - \boldsymbol{\mu}_i)^\top + \sum_{(\mathbf{x}_j, y_j) \in D_l \wedge y_j = i} (\mathbf{x}_j - \boldsymbol{\mu}_i) (\mathbf{x}_j - \boldsymbol{\mu}_i)^\top \right)$$

$$\alpha_i = \frac{1}{m} \left(\sum_{\mathbf{x}_j \in D_u} \gamma_{ji} + l_i \right)$$

生成式方法

首先, $LL(D_l)$ 对 $\boldsymbol{\mu}_i$ 求偏导, $LL(D_l)$ 求和号中只有 $y_j = i$ 的项能留下来, 即

$$\begin{aligned}\frac{\partial LL(D_l)}{\partial \boldsymbol{\mu}_i} &= \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \frac{\partial \ln(\alpha_i \cdot p(\boldsymbol{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i))}{\partial \boldsymbol{\mu}_i} \\ &= \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \frac{1}{p(\boldsymbol{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)} \cdot \frac{\partial p(\boldsymbol{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)}{\partial \boldsymbol{\mu}_i} \\ &= \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \frac{1}{p(\boldsymbol{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)} \cdot p(\boldsymbol{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) \cdot \boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}_j - \boldsymbol{\mu}_i) \\ &= \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}_j - \boldsymbol{\mu}_i)\end{aligned}$$

$$p(\boldsymbol{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) = \frac{1}{(2\pi)^{\frac{n}{2}} |\boldsymbol{\Sigma}_i|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(\boldsymbol{x}_j - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}_j - \boldsymbol{\mu}_i)\right)$$

$$\begin{aligned}\frac{\partial p(\boldsymbol{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)}{\partial \boldsymbol{\mu}_i} &= \frac{\frac{\partial}{\partial \boldsymbol{\mu}_i} \frac{1}{(2\pi)^{\frac{n}{2}} |\boldsymbol{\Sigma}_i|^{\frac{1}{2}}} \exp\left(-\frac{1}{2}(\boldsymbol{x}_j - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}_j - \boldsymbol{\mu}_i)\right)}{\frac{\partial \boldsymbol{\mu}_i}{\partial \boldsymbol{\mu}_i}} \\ &= \frac{1}{(2\pi)^{\frac{n}{2}} |\boldsymbol{\Sigma}_i|^{\frac{1}{2}}} \cdot \frac{\partial \exp\left(-\frac{1}{2}(\boldsymbol{x}_j - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}_j - \boldsymbol{\mu}_i)\right)}{\partial \boldsymbol{\mu}_i} \\ &= \frac{1}{(2\pi)^{\frac{n}{2}} |\boldsymbol{\Sigma}_i|^{\frac{1}{2}}} \cdot \exp\left(-\frac{1}{2}(\boldsymbol{x}_j - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}_j - \boldsymbol{\mu}_i)\right) \cdot -\frac{1}{2} \frac{\partial (\boldsymbol{x}_j - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}_j - \boldsymbol{\mu}_i)}{\partial \boldsymbol{\mu}_i} \\ &= \frac{1}{(2\pi)^{\frac{n}{2}} |\boldsymbol{\Sigma}_i|^{\frac{1}{2}}} \cdot \exp\left(-\frac{1}{2}(\boldsymbol{x}_j - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}_j - \boldsymbol{\mu}_i)\right) \cdot \boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}_j - \boldsymbol{\mu}_i) \\ &= p(\boldsymbol{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) \cdot \boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}_j - \boldsymbol{\mu}_i)\end{aligned}$$

由矩阵求导的法则 $\frac{\partial \boldsymbol{a}^T \boldsymbol{X} \boldsymbol{a}}{\partial \boldsymbol{a}} = 2\boldsymbol{X}\boldsymbol{a}$ 可得

$$\begin{aligned}& -\frac{1}{2} \frac{\partial (\boldsymbol{x}_j - \boldsymbol{\mu}_i)^T \boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}_j - \boldsymbol{\mu}_i)}{\partial \boldsymbol{\mu}_i} \\ &= -\frac{1}{2} \cdot 2\boldsymbol{\Sigma}_i^{-1}(\boldsymbol{\mu}_i - \boldsymbol{x}_j) \\ &= \boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}_j - \boldsymbol{\mu}_i)\end{aligned}$$

$LL(D_u)$ 对 $\boldsymbol{\mu}_i$ 求导, 参考 9.33 的推导:

$$\begin{aligned}\frac{\partial LL(D_u)}{\partial \boldsymbol{\mu}_i} &= \sum_{\boldsymbol{x}_j \in D_u} \frac{\alpha_i}{\sum_{s=1}^N \alpha_s \cdot p(\boldsymbol{x}_j | \boldsymbol{\mu}_s, \boldsymbol{\Sigma}_s)} \cdot p(\boldsymbol{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) \cdot \boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}_j - \boldsymbol{\mu}_i) \\ &= \sum_{\boldsymbol{x}_j \in D_u} \gamma_{ji} \cdot \boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}_j - \boldsymbol{\mu}_i)\end{aligned}$$

$$\begin{aligned}\frac{\partial LL(D_l \cup D_u)}{\partial \boldsymbol{\mu}_i} &= \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}_j - \boldsymbol{\mu}_i) + \sum_{\boldsymbol{x}_j \in D_u} \gamma_{ji} \cdot \boldsymbol{\Sigma}_i^{-1}(\boldsymbol{x}_j - \boldsymbol{\mu}_i) \\ &= \boldsymbol{\Sigma}_i^{-1} \left(\sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} (\boldsymbol{x}_j - \boldsymbol{\mu}_i) + \sum_{\boldsymbol{x}_j \in D_u} \gamma_{ji} \cdot (\boldsymbol{x}_j - \boldsymbol{\mu}_i) \right) \\ &= \boldsymbol{\Sigma}_i^{-1} \left(\sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \boldsymbol{x}_j + \sum_{\boldsymbol{x}_j \in D_u} \gamma_{ji} \cdot \boldsymbol{x}_j - \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \boldsymbol{\mu}_i - \sum_{\boldsymbol{x}_j \in D_u} \gamma_{ji} \cdot \boldsymbol{\mu}_i \right)\end{aligned}$$

令 $\frac{\partial LL(D_l \cup D_u)}{\partial \boldsymbol{\mu}_i} = 0$, 两边同时左乘 $\boldsymbol{\Sigma}_i$ 并移项:

$$\sum_{\boldsymbol{x}_j \in D_u} \gamma_{ji} \cdot \boldsymbol{\mu}_i + \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \boldsymbol{\mu}_i = \sum_{\boldsymbol{x}_j \in D_u} \gamma_{ji} \cdot \boldsymbol{x}_j + \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \boldsymbol{x}_j$$

上式中, $\boldsymbol{\mu}_i$ 可以作为常量提到求和号外面, 而 $\sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} 1 = l_i$, 即第 i 类样本的有标记样本数目, 因此

$$\left(\sum_{\boldsymbol{x}_j \in D_u} \gamma_{ji} + \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} 1 \right) \boldsymbol{\mu}_i = \sum_{\boldsymbol{x}_j \in D_u} \gamma_{ji} \cdot \boldsymbol{x}_j + \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \boldsymbol{x}_j$$

生成式方法

[推导]: 首先 $LL(D_l)$ 对 Σ_i 求偏导, 类似于 13.6

$$\begin{aligned}\frac{\partial LL(D_l)}{\partial \Sigma_i} &= \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \frac{\partial \ln(\alpha_i \cdot p(\boldsymbol{x}_j | \boldsymbol{\mu}_i, \Sigma_i))}{\partial \Sigma_i} \\ &= \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \frac{1}{p(\boldsymbol{x}_j | \boldsymbol{\mu}_i, \Sigma_i)} \cdot \frac{\partial p(\boldsymbol{x}_j | \boldsymbol{\mu}_i, \Sigma_i)}{\partial \Sigma_i} \\ &= \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \frac{1}{p(\boldsymbol{x}_j | \boldsymbol{\mu}_i, \Sigma_i)} \cdot p(\boldsymbol{x}_j | \boldsymbol{\mu}_i, \Sigma_i) \cdot \left(\Sigma_i^{-1} (\boldsymbol{x}_j - \boldsymbol{\mu}_i) (\boldsymbol{x}_j - \boldsymbol{\mu}_i)^\top - \boldsymbol{I} \right) \cdot \frac{1}{2} \Sigma_i^{-1} \\ &= \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \left(\Sigma_i^{-1} (\boldsymbol{x}_j - \boldsymbol{\mu}_i) (\boldsymbol{x}_j - \boldsymbol{\mu}_i)^\top - \boldsymbol{I} \right) \cdot \frac{1}{2} \Sigma_i^{-1}\end{aligned}$$

然后 $LL(D_u)$ 对 Σ_i 求偏导, 类似于 9.35

$$\frac{\partial LL(D_u)}{\partial \Sigma_i} = \sum_{\boldsymbol{x}_j \in D_u} \gamma_{ji} \cdot \left(\Sigma_i^{-1} (\boldsymbol{x}_j - \boldsymbol{\mu}_i) (\boldsymbol{x}_j - \boldsymbol{\mu}_i)^\top - \boldsymbol{I} \right) \cdot \frac{1}{2} \Sigma_i^{-1}$$

综合可得:

$$\begin{aligned}\frac{\partial LL(D_l \cup D_u)}{\partial \Sigma_i} &= \sum_{\boldsymbol{x}_j \in D_u} \gamma_{ji} \cdot \left(\Sigma_i^{-1} (\boldsymbol{x}_j - \boldsymbol{\mu}_i) (\boldsymbol{x}_j - \boldsymbol{\mu}_i)^\top - \boldsymbol{I} \right) \cdot \frac{1}{2} \Sigma_i^{-1} \\ &\quad + \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \left(\Sigma_i^{-1} (\boldsymbol{x}_j - \boldsymbol{\mu}_i) (\boldsymbol{x}_j - \boldsymbol{\mu}_i)^\top - \boldsymbol{I} \right) \cdot \frac{1}{2} \Sigma_i^{-1} \\ &= \left(\sum_{\boldsymbol{x}_j \in D_u} \gamma_{ji} \cdot \left(\Sigma_i^{-1} (\boldsymbol{x}_j - \boldsymbol{\mu}_i) (\boldsymbol{x}_j - \boldsymbol{\mu}_i)^\top - \boldsymbol{I} \right) \right. \\ &\quad \left. + \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \left(\Sigma_i^{-1} (\boldsymbol{x}_j - \boldsymbol{\mu}_i) (\boldsymbol{x}_j - \boldsymbol{\mu}_i)^\top - \boldsymbol{I} \right) \right) \cdot \frac{1}{2} \Sigma_i^{-1}\end{aligned}$$

令 $\frac{\partial LL(D_l \cup D_u)}{\partial \Sigma_i} = 0$, 两边同时右乘 $2\Sigma_i$ 并移项:

$$\begin{aligned}\sum_{\boldsymbol{x}_j \in D_u} \gamma_{ji} \cdot \Sigma_i^{-1} (\boldsymbol{x}_j - \boldsymbol{\mu}_i) (\boldsymbol{x}_j - \boldsymbol{\mu}_i)^\top &+ \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \Sigma_i^{-1} (\boldsymbol{x}_j - \boldsymbol{\mu}_i) (\boldsymbol{x}_j - \boldsymbol{\mu}_i)^\top \\ &= \sum_{\boldsymbol{x}_j \in D_u} \gamma_{ji} \cdot \boldsymbol{I} + \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} \boldsymbol{I} \\ &= \left(\sum_{\boldsymbol{x}_j \in D_u} \gamma_{ji} + l_i \right) \boldsymbol{I}\end{aligned}$$

两边同时左乘以 Σ_i :

$$\sum_{\boldsymbol{x}_j \in D_u} \gamma_{ji} \cdot (\boldsymbol{x}_j - \boldsymbol{\mu}_i) (\boldsymbol{x}_j - \boldsymbol{\mu}_i)^\top + \sum_{(\boldsymbol{x}_j, y_j) \in D_l \wedge y_j = i} (\boldsymbol{x}_j - \boldsymbol{\mu}_i) (\boldsymbol{x}_j - \boldsymbol{\mu}_i)^\top = \left(\sum_{\boldsymbol{x}_j \in D_u} \gamma_{ji} + l_i \right) \Sigma_i$$

生成式方法

$$\frac{\partial \mathcal{L}(D_l \cup D_u, \lambda)}{\partial \alpha_i} = \frac{l_i}{\alpha_i} + \sum_{\mathbf{x}_j \in D_u} \frac{p(\mathbf{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)}{\sum_{s=1}^N \alpha_s \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_s, \boldsymbol{\Sigma}_s)} + \lambda$$

令 $\frac{\partial LL(D_l \cup D_u)}{\partial \alpha_i} = 0$ 并且两边同乘以 α_i ，得

$$\alpha_i \cdot \frac{l_i}{\alpha_i} + \sum_{\mathbf{x}_j \in D_u} \frac{\alpha_i \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)}{\sum_{s=1}^N \alpha_s \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_s, \boldsymbol{\Sigma}_s)} + \lambda \cdot \alpha_i = 0$$

对 α_i 求偏导。对于 $LL(D_u)$ ，求导结果与式 9.37 的推导过程一样

$$\frac{\partial LL(D_u)}{\partial \alpha_i} = \sum_{\mathbf{x}_j \in D_u} \frac{1}{\sum_{s=1}^N \alpha_s \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_s, \boldsymbol{\Sigma}_s)} \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)$$

结合式 9.30 发现，求和号内即为后验概率 γ_{ji} ，即

$$l_i + \sum_{\mathbf{x}_j \in D_u} \gamma_{ji} + \lambda \alpha_i = 0$$

对所有混合成分求和，得

$$\sum_{i=1}^N l_i + \sum_{i=1}^N \sum_{\mathbf{x}_j \in D_u} \gamma_{ji} + \sum_{i=1}^N \lambda \alpha_i = 0$$

这里 $\sum_{i=1}^N \alpha_i = 1$ ，因此 $\sum_{i=1}^N \lambda \alpha_i = \lambda \sum_{i=1}^N \alpha_i = \lambda$ ，根据 9.30 中 γ_{ji} 表达式可知

$$\sum_{i=1}^N \gamma_{ji} = \sum_{i=1}^N \frac{\alpha_i \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)}{\sum_{s=1}^N \alpha_s \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_s, \boldsymbol{\Sigma}_s)} = \frac{\sum_{i=1}^N \alpha_i \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)}{\sum_{s=1}^N \alpha_s \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_s, \boldsymbol{\Sigma}_s)} = 1$$

再结合加法满足交换律，所以

$$\sum_{i=1}^N \sum_{\mathbf{x}_j \in D_u} \gamma_{ji} = \sum_{\mathbf{x}_j \in D_u} \sum_{i=1}^N \gamma_{ji} = \sum_{\mathbf{x}_j \in D_u} 1 = u$$

以上分析过程中， $\sum_{\mathbf{x}_j \in D_u}$ 形式与 $\sum_{j=1}^u$ 等价，其中 u 为未标记样本集的样本个数； $\sum_{i=1}^N l_i = l$ 其中 l 为有标记样本集的样本个数；将这些结果代入

$$\sum_{i=1}^N l_i + \sum_{i=1}^N \sum_{\mathbf{x}_j \in D_u} \gamma_{ji} + \sum_{i=1}^N \lambda \alpha_i = 0$$

解出 $l + u + \lambda = 0$ 且 $l + u = m$ 其中 m 为样本总个数，移项即得 $\lambda = -m$ 最后带入整理解得

$$l_i + \sum_{\mathbf{x}_j \in D_u} \gamma_{ji} - \lambda \alpha_i = 0$$

对于 $LL(D_l)$ ，类似于 13.6 和 13.7 的推导过程

$$\begin{aligned} \frac{\partial LL(D_l)}{\partial \alpha_i} &= \sum_{(\mathbf{x}_j, y_j) \in D_l \wedge y_j = i} \frac{\partial \ln(\alpha_i \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i))}{\partial \alpha_i} \\ &= \sum_{(\mathbf{x}_j, y_j) \in D_l \wedge y_j = i} \frac{1}{\alpha_i \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)} \cdot \frac{\partial(\alpha_i \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i))}{\partial \alpha_i} \\ &= \sum_{(\mathbf{x}_j, y_j) \in D_l \wedge y_j = i} \frac{1}{\alpha_i \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i)} \cdot p(\mathbf{x}_j | \boldsymbol{\mu}_i, \boldsymbol{\Sigma}_i) \\ &= \sum_{(\mathbf{x}_j, y_j) \in D_l \wedge y_j = i} \frac{1}{\alpha_i} = \frac{1}{\alpha_i} \cdot \sum_{(\mathbf{x}_j, y_j) \in D_l \wedge y_j = i} 1 = \frac{l_i}{\alpha_i} \end{aligned}$$

生成式方法


- 将上述过程中的高斯混合模型换成混合专家模型，朴素贝叶斯模型等即可推导出其他的生成式半监督学习算法。
- 此类方法简单、易于实现，在有标记数据极少的情形下往往比其他方法性能更好。
- 然而，此类方法有一个关键：模型假设必须准确，即假设的生成式模型必须与真实数据分布吻合；否则利用未标记数据反而会显著降低泛化性能。

内 容 大 纲

- 未标记样本
- 生成式方法
- 半监督SVM
- 嵌图半监督学习
- 半监督聚类

半监督SVM

- 不考虑未标记样本时，SVM试图找到最大间隔划分超平面，而在考虑未标记样本后，半监督SVM试图找到能将两类有标记样本分开，且穿过数据低密度区域的划分超平面。



基本假设是“低密度分隔” (low-density separation)，聚类假设在考虑了线性超平面划分后的推广。

半监督SVM


• 复习SVM

求解几何间隔最大的分离超平面可以表示为约束的最优化问题：

$$\begin{aligned} \max_{\vec{w}, b} \quad & \gamma = \frac{2}{\|\vec{w}\|} \quad \text{两个异类支持向量到超平面的距离之和} \\ \text{s.t.} \quad & \tilde{y}_i \left(\frac{\vec{w}}{\|\vec{w}\|_2} \cdot \vec{x}_i + \frac{b}{\|\vec{w}\|_2} \right) \geq \gamma, i = 1, 2, \dots, N \end{aligned}$$

考虑几何间隔和函数间隔的关系，改写问题为：

$$\begin{aligned} \max_{\vec{w}, b} \quad & \hat{\gamma} \\ \text{s.t.} \quad & \tilde{y}_i (\vec{w} \cdot \vec{x}_i + b) \geq \hat{\gamma}, i = 1, 2, \dots, N \end{aligned}$$



假设训练数据集不是线性可分的，这意味着某些样本点 $(\vec{x}_i, \tilde{y}_i)$ 不满足函数间隔大于等于 1 的约束条件。

◦ 对每个样本点 $(\vec{x}_i, \tilde{y}_i)$ 引进一个松弛变量 $\xi_i \geq 0$ ，使得函数间隔加上松弛变量大于等于 1。

即约束条件变成了： $\tilde{y}_i (\vec{w} \cdot \vec{x}_i) \geq 1 - \xi_i$ 。

◦ 对每个松弛变量 ξ_i ，支付一个代价 ξ_i 。目标函数由原来的 $\frac{1}{2} \|\vec{w}\|_2^2$ 变成：

$$\min \frac{1}{2} \|\vec{w}\|_2^2 + C \sum_{i=1}^N \xi_i$$

这里 $C > 0$ 称作惩罚参数，一般由应用问题决定。

- C 值大时，对误分类的惩罚增大，此时误分类点凸显的更重要
- C 值较大时，对误分类的惩罚增加，此时误分类点比较重要。
- C 值较小时，对误分类的惩罚减小，此时误分类点相对不重要。

相对于硬间隔最大化， $\frac{1}{2} \|\vec{w}\|_2^2 + C \sum_{i=1}^N \xi_i$ 称为软间隔最大化。

于是线性不可分的线性支持向量机的学习问题变成了凸二次规划问题：

$$\begin{aligned} \min_{\vec{w}, b, \xi} \quad & \frac{1}{2} \|\vec{w}\|_2^2 + C \sum_{i=1}^N \xi_i \\ \text{s.t.} \quad & \tilde{y}_i (\vec{w} \cdot \vec{x}_i + b) \geq 1 - \xi_i, \quad i = 1, 2, \dots, N \\ & \xi_i \geq 0, \quad i = 1, 2, \dots, N \end{aligned}$$

半监督SVM

- TSVM(Transductive Support Vector Machine)
 - TSVM也是针对二分类问题
 - 思想：试图考虑对未标记样本进行各种可能的标记指派(label assignment)，即尝试将每个未标记样本分别作为正例或反例，然后在所有这些结果中，寻求一个在所有样本上间隔最大化的划分超平面。一旦划分超平面得以确定，未标记样本的最终标记指派就是其预测结果。

半监督SVM

- TSVM (Transductive Support Vector Machine)
 - 给定 $D_l = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_l, y_l)\}$ 和 $D_u = \{\mathbf{x}_{l+1}, \mathbf{x}_{l+2}, \dots, \mathbf{x}_{l+u}\}$, 其中 $y_i \in \{-1, +1\}$, $l \ll u$, $l + u = m$ 。TSVM学习目标是给 D_u 中的样本给出预测标签 $\hat{\mathbf{y}} = (\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_{l+u})$, $\hat{y}_i \in \{-1, +1\}$, 使得

$$\begin{aligned} \min_{\mathbf{w}, b, \hat{\mathbf{y}}, \boldsymbol{\xi}} \quad & \frac{1}{2} \|\mathbf{w}\|_2^2 + C_l \sum_{i=1}^l \xi_i + C_u \sum_{i=l+1}^m \xi_i \\ \text{s.t.} \quad & y_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \quad i = 1, \dots, l, \\ & \hat{y}_i(\mathbf{w}^\top \mathbf{x}_i + b) \geq 1 - \xi_i, \quad i = l+1, \dots, m, \\ & \xi_i \geq 0, \quad i = 1, \dots, m, \end{aligned}$$

半监督SVM

- TSVM采用局部搜索来迭代地寻找近似解。
 - 先利用 D_l 学到SVM，忽略 D_u 和 $\hat{y}$ 的项及约束，然后利用SVM对未标记数据指定标签，即伪标签，也就是 $\hat{y}$ 已知，利用上述公式得到标准SVM分类器
 - 由于未标记样本的伪标签不准确， C_u 设置要比 C_l 小，让标记样本发挥作用
 - TSVM 找出两个标记指派为异类且很可能发生错误的未标记样本，交换它们的标记，再重新利用基于式(13.9)求解；然后迭代求解，逐渐增大 C_u 。



半监督SVM

未标记样本的伪标记不准确

输入：有标记样本集 $D_l = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_l, y_l)\}$;
未标记样本集 $D_u = \{\mathbf{x}_{l+1}, \mathbf{x}_{l+2}, \dots, \mathbf{x}_{l+u}\}$;
折中参数 C_l, C_u .

过程：

- 1: 用 D_l 训练一个 SVM_l ;
- 2: 用 SVM_l 对 D_u 中样本进行预测, 得到 $\hat{\mathbf{y}} = (\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_{l+u})$;

3: 初始化 $C_u \ll C_l$;

4: while $C_u < C_l$ do

5: 基于 $D_l, D_u, \hat{\mathbf{y}}, C_l, C_u$ 求解式(13.9), 得到 $(\mathbf{w}, b), \xi$;

6: while $\exists \{i, j \mid (\hat{y}_i \hat{y}_j < 0) \wedge (\xi_i > 0) \wedge (\xi_j > 0) \wedge (\xi_i + \xi_j > 2)\}$ do

7: $\hat{y}_i = -\hat{y}_i$;

8: $\hat{y}_j = -\hat{y}_j$;

9: 基于 $D_l, D_u, \hat{\mathbf{y}}, C_l, C_u$ 重新求解式(13.9), 得到 $(\mathbf{w}, b), \xi$

10: end while

11: $C_u = \min\{2C_u, C_l\}$

12: end while

输出：未标记样本的预测结果: $\hat{\mathbf{y}} = (\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_{l+u})$

标记指派不同

标记指派是错误,
需要交换

图 13.4 TSVM 算法

半监督SVM

- 未标记样本进行标记指派及调整的过程中，有可能出现**类别不平衡问题**，即某类的样本远多于另一类。
- 为了减轻类别不平衡性所造成的不利影响，可对算法稍加改进：将优化目标中的 C_u 项拆分为 C_u^+ 与 C_u^- 两项，并在初始化时令：

$$C_u^+ = \frac{u_-}{u_+} C_u^-$$

u_- 和 u_+ 为基于伪标记而当作正、反例使用的未标记样本数。

半监督SVM

- 显然, 搜寻标记指派可能出错的每一对未标记样本进行调整, 仍是一个涉及 **巨大计算开销** 的大规模优化问题。
- 因此, 半监督SVM研究的一个重点是如何 **设计出高效的优化求解策略**。
- 例如基于图核(graph kernel)函数梯度下降的Laplacian SVM[Chapelle and Zien, 2005]、基于标记均值估计的meanS3VM[Li et al., 2009]等。

内 容 大 纲

- 未标记样本
- 生成式方法
- 半监督SVM
- 图半监督学习
- 半监督聚类
- 基于分歧的方法*

图半监督学习


- 给定一个数据集，将其映射为一个图，数据集中每个样本对应于图中一个节点，若两个样本之间的相似度高，则对应的节点之间存在一条边，边的“强度”正比于样本之间的相似度。
- 将有标记样本所对应的节点设定为染过色，而未标记样本所对应的节点则尚未染色，半监督学习相当于“染色”。
- 一个图对应了一个矩阵，这就可采用基于矩阵运算来进行半监督学习算法的推导与分析。

图半监督学习 $\Leftrightarrow$ 图上标签扩散或传播的过程

Smoothness Assumption

- Assumption: “similar” x has the same $\hat{y}$
- More precisely:
 - x is not uniform.
 - If x^1 and x^2 are close in a high density region, $\hat{y}^1$ and $\hat{y}^2$ are the same.

connected by a
high density path




x^1 and x^2 have the same label

x^2 and x^3 have different labels

Source of image:

<http://hips.seas.harvard.edu/files/pinwheel.png>

为什么要有Smoothness Assumption



“indirectly” similar
with stepping stones

“过渡形态”

Classify astronomy vs. travel articles

	d_1	d_5	d_6	d_7	d_3
asteroid	•				
bright	•	•			
comet		•	•		
year			•	•	
zodiac				•	•
⋮					
airport					
bike					
camp					
yellowstone					
zion					

	d_1	d_3	d_4	d_2
asteroid	•			
bright	•			
comet				
year		•		
zodiac				
⋮				
airport			•	
bike			•	
camp				
yellowstone				•
zion				•

(The example is from the tutorial slides of Xiaojin Zhu.)

如何通过图方法实现Smoothness Assumption


- How to know x^1 and x^2 are close in a high density region (connected by a high density path)

Represented the data points as a **graph**

Graph representation is nature sometimes.

E.g. Hyperlink of webpages, citation of papers

Sometimes you have to construct the graph yourself.




图半监督学习

- 如何构建图?
 - 根据 $D_l \cup D_u$, 构建 $G = (V, E)$, 节点集合 $V = \{x_1, \dots, x_l, x_{l+1}, \dots, x_{l+u}\}$, 边的集合 E 表示为亲和矩阵, 常基于高斯函数定义:

$$W_{ij} = \begin{cases} \exp\left(\frac{-\|x_i - x_j\|_2^2}{2\sigma^2}\right), & \text{if } i \neq j; \\ 0, & \text{otherwise,} \end{cases}$$


Add edge:

- K Nearest Neighbor
- e-Neighborhood





图半监督学习

Label
Propagation



The labelled data influence their neighbors.

Propagate through the graph




图半监督学习

- Define the smoothness of the labels on the graph

$$S = \frac{1}{2} \sum_{i,j} w_{i,j} (y^i - y^j)^2$$

Smaller means smoother

For all data (no matter labelled or not)



图半监督学习

- Define the smoothness of the labels on the graph

$$S = \frac{1}{2} \sum_{i,j} w_{i,j} (y^i - y^j)^2 = \mathbf{y}^T L \mathbf{y}$$

$\mathbf{y}$: (R+U)-dim vector


$$\mathbf{y} = [\dots y^i \dots y^j \dots]^T$$

L: (R+U) x (R+U) matrix

Graph Laplacian

$$L = \underline{D} - \underline{W}$$

$$W = \begin{bmatrix} 0 & 2 & 3 & 0 \\ 2 & 0 & 1 & 0 \\ 3 & 1 & 0 & 1 \\ 0 & 0 & 1 & 0 \end{bmatrix} \quad D = \begin{bmatrix} 5 & 0 & 0 & 0 \\ 0 & 3 & 0 & 0 \\ 0 & 0 & 5 & 0 \\ 0 & 0 & 0 & 1 \end{bmatrix}$$



图半监督学习

- 能量函数

- 假定从图 $G = (V, E)$, 学到实值函数 $f: V \rightarrow \mathbb{R}$ 其对应的分类规则为

$$y_i = \text{sign} \left(f(\mathbf{x}_i) \right), y_i \in \{-1, +1\}$$

- 直观上讲, 相似的样本应该具有相似的标记, 于是定义关于 f 的“能量函数” (Energy Function) :

$$E(f) = \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m (\mathbf{W})_{ij} \left(f(\mathbf{x}_i) - f(\mathbf{x}_j) \right)^2$$

基于图的半监督学习方法更适合 Smoothness Assumption

图半监督学习

- 能量函数

$$E(f) = \frac{1}{2} \sum_{i=1}^m \sum_{j=1}^m (\mathbf{W})_{ij} (f(\mathbf{x}_i) - f(\mathbf{x}_j))^2$$

$$= \frac{1}{2} \left(\sum_{i=1}^m d_i f^2(\mathbf{x}_i) + \sum_{j=1}^m d_j f^2(\mathbf{x}_j) - 2 \sum_{i=1}^m \sum_{j=1}^m (\mathbf{W})_{ij} f(\mathbf{x}_i) f(\mathbf{x}_j) \right)$$

$$= \sum_{i=1}^m d_i f^2(\mathbf{x}_i) - \sum_{i=1}^m \sum_{j=1}^m (\mathbf{W})_{ij} f(\mathbf{x}_i) f(\mathbf{x}_j)$$

d_i 为矩阵 $\mathbf{W}$ 的第 i 行元素之和

$$= \mathbf{f}^T (\mathbf{D} - \mathbf{W}) \mathbf{f},$$

$$\mathbf{f} = (\mathbf{f}_l^T \mathbf{f}_u^T)^T,$$

$$\mathbf{f}_l = (f(\mathbf{x}_1); f(\mathbf{x}_2); \dots; f(\mathbf{x}_l)),$$

$$\mathbf{f}_u = (f(\mathbf{x}_{l+1}); f(\mathbf{x}_{l+2}); \dots; f(\mathbf{x}_{l+u}))$$

$$\mathbf{D} = \begin{bmatrix} d_1 & 0 & 0 & \cdots & 0 \\ 0 & d_2 & 0 & \cdots & 0 \\ 0 & 0 & d_3 & \cdots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \cdots & d_N \end{bmatrix}$$

图半监督学习

- 标签传播算法：将样本 $\mathbf{x}$ 的标记函数 $f(\mathbf{x})$ 视为能量函数，假定在满足约束条件下，能量函数 $E(f)$ 最低
- 标记约束：函数 f 在标记样本上满足 $f(x_i) = y_i, i = 1, 2, \dots, l$
- 能量守恒：定义拉普拉斯矩阵 $\mathbf{L} = \mathbf{D} - \mathbf{W}$
- 求解约束最优化问题：

$$\begin{aligned} & \min_f E(f) \\ \text{s.t. } & f(\vec{\mathbf{x}}_i) = y_i, i = 1, 2, \dots, l \\ & \Delta f = \mathbf{0} \quad \Delta = \mathbf{D} - \mathbf{W} \\ & (\mathbf{D} - \mathbf{W}) \left(0, \dots, 0, f(\vec{\mathbf{x}}_{l+1}), \dots, f(\vec{\mathbf{x}}_N) \right)^T = \vec{\mathbf{0}} \end{aligned}$$

图半监督学习

- 以第 l 行第 l 列为界，采用分块矩阵表示方式：

$$\mathbf{W} = \begin{bmatrix} \mathbf{W}_{l,l} & \mathbf{W}_{l,u} \\ \mathbf{W}_{u,l} & \mathbf{W}_{u,u} \end{bmatrix}, \quad \mathbf{D} = \begin{bmatrix} \mathbf{D}_{l,l} & \mathbf{0}_{l,u} \\ \mathbf{0}_{u,l} & \mathbf{D}_{u,u} \end{bmatrix}$$

$$\begin{aligned} E(f) &= (\mathbf{f}_l^T \ \mathbf{f}_u^T) \left(\begin{bmatrix} \mathbf{D}_{ll} & \mathbf{0}_{lu} \\ \mathbf{0}_{ul} & \mathbf{D}_{uu} \end{bmatrix} - \begin{bmatrix} \mathbf{W}_{ll} & \mathbf{W}_{lu} \\ \mathbf{W}_{ul} & \mathbf{W}_{uu} \end{bmatrix} \right) \begin{bmatrix} \mathbf{f}_l \\ \mathbf{f}_u \end{bmatrix} \\ &= \mathbf{f}_l^T (\mathbf{D}_{ll} - \mathbf{W}_{ll}) \mathbf{f}_l - 2\mathbf{f}_u^T \mathbf{W}_{ul} \mathbf{f}_l + \mathbf{f}_u^T (\mathbf{D}_{uu} - \mathbf{W}_{uu}) \mathbf{f}_u \end{aligned}$$

- 考虑到 f_l 是已知的， $E(f)$ 完全由 f_u 决定，为使 $E(f)$ 的最小值，**根据** $\frac{\partial E(f)}{\partial \mathbf{f}_u} = 0$

$$\begin{aligned} \frac{\partial E(f)}{\partial \mathbf{f}_u} &= \frac{\partial \mathbf{f}_l^T (\mathbf{D}_{ll} - \mathbf{W}_{ll}) \mathbf{f}_l - 2\mathbf{f}_u^T \mathbf{W}_{ul} \mathbf{f}_l + \mathbf{f}_u^T (\mathbf{D}_{uu} - \mathbf{W}_{uu}) \mathbf{f}_u}{\partial \mathbf{f}_u} \\ &= -2\mathbf{W}_{ul} \mathbf{f}_l + 2(\mathbf{D}_{uu} - \mathbf{W}_{uu}) \mathbf{f}_u \end{aligned}$$

$$\mathbf{f}_u = (\mathbf{D}_{uu} - \mathbf{W}_{uu})^{-1} \mathbf{W}_{ul} \mathbf{f}_l$$

图半监督学习

• 令

$$\mathbf{P} = \mathbf{D}^{-1} \mathbf{W} = \begin{bmatrix} \mathbf{D}_{l,l}^{-1} & \mathbf{0}_{l,u} \\ \mathbf{0}_{u,l} & \mathbf{D}_{u,u}^{-1} \end{bmatrix} \begin{bmatrix} \mathbf{W}_{l,l} & \mathbf{W}_{l,u} \\ \mathbf{W}_{u,l} & \mathbf{W}_{u,u} \end{bmatrix} = \begin{bmatrix} \mathbf{D}_{l,l}^{-1} \mathbf{W}_{l,l} & \mathbf{D}_{l,l}^{-1} \mathbf{W}_{l,u} \\ \mathbf{D}_{u,u}^{-1} \mathbf{W}_{u,l} & \mathbf{D}_{u,u}^{-1} \mathbf{W}_{u,u} \end{bmatrix}$$

$$\mathbf{P}_{u,u} = \mathbf{D}_{u,u}^{-1} \mathbf{W}_{u,u}, \quad \mathbf{P}_{u,l} = \mathbf{D}_{u,u}^{-1} \mathbf{W}_{u,l}$$

$$\begin{aligned} \mathbf{f}_u &= (\mathbf{D}_{uu}(\mathbf{I} - \mathbf{D}_{uu}^{-1} \mathbf{W}_{uu}))^{-1} \mathbf{W}_{ul} \mathbf{f}_l \\ &= (\mathbf{I} - \mathbf{D}_{uu}^{-1} \mathbf{W}_{uu})^{-1} \mathbf{D}_{uu}^{-1} \mathbf{W}_{ul} \mathbf{f}_l \\ &= (\mathbf{I} - \mathbf{P}_{uu})^{-1} \mathbf{P}_{ul} \mathbf{f}_l . \end{aligned}$$

图半监督学习

- 多分类问题的标签传播方法

- 定义一个 $(l+u) \times |y|$ 的非负标记矩阵 $\mathbf{F} = (\mathbf{F}_1^T, \mathbf{F}_2^T, \dots, \mathbf{F}_{l+u}^T)^T$, 其中, 第 i 行元素 $\mathbf{F}_i = ((\mathbf{F})_{i1}, (\mathbf{F})_{i2}, \dots, (\mathbf{F})_{i|y|})$ 为实例 x_i 的标记向量, 相应的分类规则为 $y_i = \arg \max_{1 \leq j \leq |y|} (\mathbf{F})_{ij}$.

- 将 $\mathbf{F}$ 初始化为

$$\mathbf{F}(0) = (\mathbf{Y})_{ij} = \begin{cases} 1, & \text{if } (1 \leq i \leq l) \wedge (y_i = j); \\ 0, & \text{otherwise.} \end{cases}$$

- $\mathbf{Y}$ 的前 l 行就是 l 个有标记样本的标记向量.

图半监督学习

- 多分类问题的标签传播方法
 - 基于 $\mathbf{W}$ 构建标签传播矩阵 $\mathbf{S} = \mathbf{D}^{-\frac{1}{2}}\mathbf{W}\mathbf{D}^{-\frac{1}{2}}$ ，于是有迭代计算式

$$\mathbf{F}(t+1) = \alpha\mathbf{S}\mathbf{F}(t) + (1-\alpha)\mathbf{Y}$$

- 其中， $\alpha \in (0,1)$ 为用户指定的参数，用于标记传播项 $\mathbf{S}\mathbf{F}(t)$ 与初始化项 $\mathbf{Y}$ 的重要性进行折中。基于上式迭代至收敛

$$\mathbf{F}^* = \lim_{t \rightarrow \infty} \mathbf{F}(t) = (1-\alpha)(\mathbf{I} - \alpha\mathbf{S})^{-1}\mathbf{Y}$$

- 由 $\mathbf{F}^*$ 可获得 D_u 中样本标记 $(\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_{l+u})$

图半监督学习

- 多分类问题的标签传播方法

$$\mathbf{F}(t+1) = \alpha \mathbf{S} \mathbf{F}(t) + (1 - \alpha) \mathbf{Y}$$

- 当 t 取不同的值时，有：

$$\begin{aligned} t = 0 : \mathbf{F}(1) &= \alpha \mathbf{S} \mathbf{F}(0) + (1 - \alpha) \mathbf{Y} \\ &= \alpha \mathbf{S} \mathbf{Y} + (1 - \alpha) \mathbf{Y} \end{aligned}$$

$$\begin{aligned} t = 1 : \mathbf{F}(2) &= \alpha \mathbf{S} \mathbf{F}(1) + (1 - \alpha) \mathbf{Y} = \alpha \mathbf{S} (\alpha \mathbf{S} \mathbf{Y} + (1 - \alpha) \mathbf{Y}) + (1 - \alpha) \mathbf{Y} \\ &= (\alpha \mathbf{S})^2 \mathbf{Y} + (1 - \alpha) \left(\sum_{i=0}^1 (\alpha \mathbf{S})^i \right) \mathbf{Y} \end{aligned}$$

$$\begin{aligned} t = 2 : \mathbf{F}(3) &= \alpha \mathbf{S} \mathbf{F}(2) + (1 - \alpha) \mathbf{Y} \\ &= \alpha \mathbf{S} \left((\alpha \mathbf{S})^2 \mathbf{Y} + (1 - \alpha) \left(\sum_{i=0}^1 (\alpha \mathbf{S})^i \right) \mathbf{Y} \right) + (1 - \alpha) \mathbf{Y} \\ &= (\alpha \mathbf{S})^3 \mathbf{Y} + (1 - \alpha) \left(\sum_{i=0}^2 (\alpha \mathbf{S})^i \right) \mathbf{Y} \end{aligned}$$

可以观察到规律

$$\mathbf{F}(t) = (\alpha \mathbf{S})^t \mathbf{Y} + (1 - \alpha) \left(\sum_{i=0}^{t-1} (\alpha \mathbf{S})^i \right) \mathbf{Y}$$

图半监督学习

- 多分类问题的标签传播方法

则

$$\mathbf{F}^* = \lim_{t \rightarrow \infty} \mathbf{F}(t) = \lim_{t \rightarrow \infty} (\alpha \mathbf{S})^t \mathbf{Y} + \lim_{t \rightarrow \infty} (1 - \alpha) \left(\sum_{i=0}^{t-1} (\alpha \mathbf{S})^i \right) \mathbf{Y}$$

其中第一项由于 $\mathbf{S} = \mathbf{D}^{-\frac{1}{2}} \mathbf{W} \mathbf{D}^{-\frac{1}{2}}$ 的特征值介于 $[-1, 1]$ 之间 [1], 而 $\alpha \in (0, 1)$, 所以 $\lim_{t \rightarrow \infty} (\alpha \mathbf{S})^t = 0$, 第二项由等比数列公式

$$\lim_{t \rightarrow \infty} \sum_{i=0}^{t-1} (\alpha \mathbf{S})^i = \frac{\mathbf{I} - \lim_{t \rightarrow \infty} (\alpha \mathbf{S})^t}{\mathbf{I} - \alpha \mathbf{S}} = \frac{\mathbf{I}}{\mathbf{I} - \alpha \mathbf{S}} = (\mathbf{I} - \alpha \mathbf{S})^{-1}$$

综合可得式 13.20。

图半监督学习

- 迭代式标签
- 传播算法

输入: 有标记样本集 $D_l = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_l, y_l)\}$;
未标记样本集 $D_u = \{\mathbf{x}_{l+1}, \mathbf{x}_{l+2}, \dots, \mathbf{x}_{l+u}\}$;
构图参数 σ ;
折中参数 α .

过程:

- 1: 基于式(13.11)和参数 σ 得到 $\mathbf{W}$;
- 2: 基于 $\mathbf{W}$ 构造标记传播矩阵 $\mathbf{S} = \mathbf{D}^{-\frac{1}{2}} \mathbf{W} \mathbf{D}^{-\frac{1}{2}}$;
- 3: 根据式(13.18)初始化 $\mathbf{F}(0)$;
- 4: $t = 0$;
- 5: **repeat**
- 6: $\mathbf{F}(t+1) = \alpha \mathbf{S} \mathbf{F}(t) + (1 - \alpha) \mathbf{Y}$;
- 7: $t = t + 1$
- 8: **until** 迭代收敛至 $\mathbf{F}^*$
- 9: **for** $i = l+1, l+2, \dots, l+u$ **do**
- 10: $y_i = \arg \max_{1 \leq j \leq |\mathcal{Y}|} (\mathbf{F}^*)_{ij}$
- 11: **end for**

输出: 未标记样本的预测结果: $\hat{\mathbf{y}} = (\hat{y}_{l+1}, \hat{y}_{l+2}, \dots, \hat{y}_{l+u})$

图半监督学习

- 迭代式标签传播算法

- 事实上，图13.5算法对应于正则化框架：

$$\min_{\mathbf{F}} \frac{1}{2} \left(\sum_{i,j=1}^{l+u} (\mathbf{W})_{ij} \left\| \frac{1}{\sqrt{d_i}} \mathbf{F}_i - \frac{1}{\sqrt{d_j}} \mathbf{F}_j \right\|^2 \right) + \mu \sum_{i=1}^l \left\| \mathbf{F}_i - \mathbf{Y}_i \right\|^2$$

- $\mu > 0$ 为正则化参数，当 $\mu = \frac{1 - \alpha}{\alpha}$ ，上式的最优解恰为算法的迭代

收敛解

- 第一项则迫使相近样本具有相似的标记
- 第二项是迫使结果在有标记样本上的预测与真实标记尽可能相同

内 容 大 纲

- 未标记样本
- 生成式方法
- 半监督SVM
- 嵌图半监督学习
- 半监督聚类
- 基于分歧的方法*

半监督聚类

- 聚类是一种典型的无监督学习任务，然而在现实聚类中往往能获得一些额外的监督信息，于是可通过“半监督聚类”来利用监督信息以获得更好的聚类效果。
- 聚类任务中获得的监督信息大致有两种类型：
 - 第一种类型是“必连”(must-link)与“勿连”(cannot-link)约束，前者是指样本必属于同一个簇，后者则是指样本必不属于同一个簇；
 - 第二种类型的监督信息则是少量的有标记样本。

半监督聚类

• 约束k均值算法

k 均值算法的扩展

“必连”是指样本必
属于同一个簇, x_i

和 x_j 必属于同簇;

“勿连”是指样本必
不属于同一簇, x_i

和 x_j 必不属于同簇;

输入: 样本集 $D = \{x_1, x_2, \dots, x_m\}$;
必连约束集合 $\mathcal{M}$;
勿连约束集合 $\mathcal{C}$;
聚类簇数 k .

过程:


```
1: 从  $D$  中随机选取  $k$  个样本作为初始均值向量  $\{\mu_1, \mu_2, \dots, \mu_k\}$ ;  
2: repeat  
3:    $C_j = \emptyset$  ( $1 \leq j \leq k$ );  
4:   for  $i = 1, 2, \dots, m$  do  
5:     计算样本  $x_i$  与各均值向量  $\mu_j$  ( $1 \leq j \leq k$ ) 的距离:  $d_{ij} = \|x_i - \mu_j\|_2$ ;  
6:      $\mathcal{K} = \{1, 2, \dots, k\}$ ;  
7:     is_merged=false;  
8:     while  $\neg$  is_merged do  
9:       基于  $\mathcal{K}$  找出与样本  $x_i$  距离最近的簇:  $r = \arg \min_{j \in \mathcal{K}} d_{ij}$ ;  
10:      检测将  $x_i$  划入聚类簇  $C_r$  是否会违背  $\mathcal{M}$  与  $\mathcal{C}$  中的约束;  
11:      if  $\neg$  is_voilated then  
12:         $C_r = C_r \cup \{x_i\}$ ;  
13:        is_merged=true  
14:      else  
15:         $\mathcal{K} = \mathcal{K} \setminus \{r\}$ ;  
16:        if  $\mathcal{K} = \emptyset$  then  
17:          break并返回错误提示  
18:        end if  
19:      end if  
20:    end while  
21:  end for  
22:  for  $j = 1, 2, \dots, k$  do  
23:     $\mu_j = \frac{1}{|C_j|} \sum_{x \in C_j} x$ ;  
24:  end for  
25: until 均值向量均未更新  
输出: 簇划分  $\{C_1, C_2, \dots, C_k\}$ 
```

半监督聚类-约束k均值算法


以西瓜数据集 4.0 为例, 令样本 x_4 与 x_{25} , x_{12} 与 x_{20} , x_{14} 与 x_{17} 之间存在必连约束, x_2 与 x_{21} , x_{13} 与 x_{23} , x_{19} 与 x_{23} 之间存在勿连约束, 即

$$\mathcal{M} = \{(x_4, x_{25}), (x_{25}, x_4), (x_{12}, x_{20}), (x_{20}, x_{12}), (x_{14}, x_{17}), (x_{17}, x_{14})\},$$


$$\mathcal{C} = \{(x_2, x_{21}), (x_{21}, x_2), (x_{13}, x_{23}), (x_{23}, x_{13}), (x_{19}, x_{23}), (x_{23}, x_{19})\}.$$




(a) 第 1 轮迭代后



(b) 第 2 轮迭代后



(c) 第 3 轮迭代后



(d) 第 4 轮迭代后

半监督聚类

● 约束种子k均值算法

输入: 样本集 $D = \{\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m\}$;
少量有标记样本 $S = \bigcup_{j=1}^k S_j$;
聚类簇数 k .


过程:

```
1: for  $j = 1, 2, \dots, k$  do
2:    $\mu_j = \frac{1}{|S_j|} \sum_{\mathbf{x} \in S_j} \mathbf{x}$ 
3: end for
4: repeat
5:    $C_j = \emptyset$  ( $1 \leq j \leq k$ );
6:   for  $j = 1, 2, \dots, k$  do
7:     for all  $\mathbf{x} \in S_j$  do
8:        $C_j = C_j \cup \{\mathbf{x}\}$ 
9:     end for
10:  end for
11:  for all  $\mathbf{x}_i \in D \setminus S$  do
12:    计算样本  $\mathbf{x}_i$  与各均值向量  $\mu_j$  ( $1 \leq j \leq k$ ) 的距离:  $d_{ij} = \|\mathbf{x}_i - \mu_j\|_2$ ;
13:    找出与样本  $\mathbf{x}_i$  距离最近的簇:  $r = \arg \min_{j \in \{1, 2, \dots, k\}} d_{ij}$ ;
14:    将样本  $\mathbf{x}_i$  划入相应的簇:  $C_r = C_r \cup \{\mathbf{x}_i\}$ 
15:  end for
16:  for  $j = 1, 2, \dots, k$  do
17:     $\mu_j = \frac{1}{|C_j|} \sum_{\mathbf{x} \in C_j} \mathbf{x}$ ;
18:  end for
19: until 均值向量均未更新
```


输出: 簇划分 $\{C_1, C_2, \dots, C_k\}$

半监督聚类


- 约束种子 k
- 均值算法




(a) 第 1 轮迭代后



(b) 第 2 轮迭代后



(c) 第 3 轮迭代后



(d) 第 4 轮迭代后

内容大纲

- 未标记样本
- 生成式方法
- 半监督SVM
- 嵌图半监督学习
- 半监督聚类
- 基于分歧的方法*

基于分歧的方法


- 基于分歧的方法(disagreement-based methods)使用多个学习器,而学习器之间的“分歧”(disagreement)对未标记数据的利用至关重要。
- 协同训练(co-training)[Blum and Mitchell, 1998]是基于分歧的方法的重要代表,它最初是针对“多视图”(multi-view)数据设计的,因此也被看作“多视图学习”(multi-view learning)的代表本。

基于分歧的方法

- 数据视图
 - 数据对象往往同时拥有多个属性集attribute-set，每个属性集就构成了一个视图。
 - 数据集 $D = \{(x_1, y_1), (x_2, y_2), \dots, (x_n, y_n)\}$ ，其中 $\mathbf{x} = \{x_1, x_2, \dots, x_d\}$ ，假设属性结合划分为 $\mathbf{x} = \mathbf{x}^{(1)} \cup \mathbf{x}^{(2)}$
 - 原始样本 $\mathbf{x}_i$ 就被划分为两个属性向量 $\langle \mathbf{x}_i^{(1)}, \mathbf{x}_i^{(2)} \rangle$ ，分别两个属性集
 - $(\langle \mathbf{x}_i^{(1)}, \mathbf{x}_i^{(2)} \rangle, y_i)$ 表示多视图数据，每个属性集对应一个视图
 - 不同视图具有相容性，即输出空间 y 的信息是一致的

基于分歧的方法

- 协同训练算法



基于分歧的方法

输入: 有标记样本集 $D_l = \{(\langle \mathbf{x}_1^1, \mathbf{x}_1^2 \rangle, y_1), \dots, (\langle \mathbf{x}_l^1, \mathbf{x}_l^2 \rangle, y_l)\}$;
未标记样本集 $D_u = \{\langle \mathbf{x}_{l+1}^1, \mathbf{x}_{l+1}^2 \rangle, \dots, \langle \mathbf{x}_{l+u}^1, \mathbf{x}_{l+u}^2 \rangle\}$;
缓冲池大小 s ;
每轮挑选的正例数 p ;
每轮挑选的反例数 n ;
基学习算法 $\mathcal{L}$;
学习轮数 T .

过程:

```
1: 从  $D_u$  中随机抽取  $s$  个样本构成缓冲池  $D_s$ ;  
2:  $D_u = D_u \setminus D_s$ ;  
3: for  $j = 1, 2$  do  
4:    $D_l^j = \{(\mathbf{x}_i^j, y_i) \mid (\langle \mathbf{x}_i^j, \mathbf{x}_i^{3-j} \rangle, y_i) \in D_l\}$ ;  
5: end for  
6: for  $t = 1, 2, \dots, T$  do  
7:   for  $j = 1, 2$  do  
8:      $h_j \leftarrow \mathcal{L}(D_l^j)$ ;  
9:     考察  $h_j$  在  $D_s^j = \{\mathbf{x}_i^j \mid \langle \mathbf{x}_i^j, \mathbf{x}_i^{3-j} \rangle \in D_s\}$  上的分类置信度, 挑选  $p$  个正例  
       置信度最高的样本  $D_p \subset D_s$ 、 $n$  个反例置信度最高的样本  $D_n \subset D_s$ ;  
10:    由  $D_p^j$  生成伪标记正例  $\tilde{D}_p^{3-j} = \{(\mathbf{x}_i^{3-j}, +1) \mid \mathbf{x}_i^j \in D_p^j\}$ ;  
11:    由  $D_n^j$  生成伪标记反例  $\tilde{D}_n^{3-j} = \{(\mathbf{x}_i^{3-j}, -1) \mid \mathbf{x}_i^j \in D_n^j\}$ ;  
12:     $D_s = D_s \setminus (D_p \cup D_n)$ ;  
13:   end for  
14:   if  $h_1, h_2$  均未发生改变 then  
15:     break  
16:   else  
17:     for  $j = 1, 2$  do  
18:        $D_l^j = D_l^j \cup (\tilde{D}_p^j \cup \tilde{D}_n^j)$ ;  
19:     end for  
20:     从  $D_u$  中随机抽取  $2p + 2n$  个样本加入  $D_s$   
21:   end if  
22: end for
```

输出: 分类器 h_1, h_2