

人工智能学院2024级本科生课程

《机器学习》

第九章 特征选择与稀疏学习

吉林大学 人工智能学院

授课教师：王鑫

内容大纲

- 背景知识
- 子集搜索与评价
- 过滤式选择
- 包裹式选择
- 嵌入式选择与L1正则化
- 稀疏表示与字典学习
- 压缩感知

背景知识

- 特征

- 描述物体的属性
- 别名：字段、属性、自变量


- 特征分类

- 连续特征和Category特征
- 相关特征和无关特征
- 冗余特征

编号	色泽	根蒂	敲声	纹理	脐部	触感	密度	含糖率	好瓜
1	青绿	蜷缩	浊响	清晰	凹陷	硬滑	0.697	0.460	是
2	乌黑	蜷缩	沉闷	清晰	凹陷	硬滑	0.774	0.376	是
3	乌黑	蜷缩	浊响	清晰	凹陷	硬滑	0.634	0.264	是
4	青绿	蜷缩	沉闷	清晰	凹陷	硬滑	0.608	0.318	是
5	浅白	蜷缩	浊响	清晰	凹陷	硬滑	0.556	0.215	是
6	青绿	稍蜷	浊响	清晰	稍凹	软粘	0.403	0.237	是
7	乌黑	稍蜷	浊响	稍糊	稍凹	软粘	0.481	0.149	是
8	乌黑	稍蜷	浊响	清晰	稍凹	硬滑	0.437	0.211	是
9	乌黑	稍蜷	沉闷	稍糊	稍凹	硬滑	0.666	0.091	否
10	青绿	硬挺	清脆	清晰	平坦	软粘	0.243	0.267	否
11	浅白	硬挺	清脆	模糊	平坦	硬滑	0.245	0.057	否
12	浅白	蜷缩	浊响	模糊	平坦	软粘	0.343	0.099	否
13	青绿	稍蜷	浊响	稍糊	凹陷	硬滑	0.639	0.161	否
14	浅白	稍蜷	沉闷	稍糊	凹陷	硬滑	0.657	0.198	否
15	乌黑	稍蜷	浊响	清晰	稍凹	软粘	0.360	0.370	否
16	浅白	蜷缩	浊响	模糊	平坦	硬滑	0.593	0.042	否
17	青绿	蜷缩	沉闷	稍糊	稍凹	硬滑	0.719	0.103	否

例子：西瓜的特征

当前任务：西瓜是否是好瓜



背景知识

- 特征工程
 - 利用数据领域的相关知识来创建能够使机器学习算法达到最佳性能的特征的过程，在机器学习中占有重要的地位。





背景知识

- 特征构造
 - 从原始数据形成特征过程，根据数据结构，比如表格、文本、图像、Graph等
- 特征抽取（特征降维）
 - 通过空间维度映射实现维度降低，映射关系多对多，组合问题
- 特征选择
 - 通过从原始空间维度选择部分维度，新特征空间与原始特征映射关系一对一。

背景知识

- 特征抽取和特征选择联系
 - 共同目的：降维、减少冗余
- 特征抽取和特征选择区别



背景知识

- 特征学习目的
 - 降维：（1）减少特征属性的个数；（2）确保特征属性之间是相互独立的；（3）高维空间样本具有稀疏性，导致模型难找到数据特征
 - 选择：（1）特征冗余、部分特征相关度太高，消耗计算资源；（2）存在噪声，对模型有负面影响；（3）部分特征容易引起模型overfitting，泛化能力差；（4）模型时空复杂度大，简化模型，缩短训练时间

内容大纲

- 背景知识
- 子集搜索与评价
- 过滤式选择
- 包裹式选择
- 嵌入式选择与L1正则化
- 稀疏表示与字典学习
- 压缩感知


特征选择

- 特征选择
 - 从给定的特征集合中选出任务相关特征子集
 - 必须确保不丢失重要特征
- 原因
 - 维度灾难：在少量属性上构建模型
 - 降低学习难度：留下关键信息，去除不相关特征

特征选择的一般方法

- 遍历所有可能的子集
 - 计算上遭遇组合爆炸，不可行
 - 必须确保不丢失重要特征

- 可行方法



两个关键环节： 子集搜索和子集评价

子集搜索


用贪心策略选择包含重要信息的特征子集

- 前向搜索：逐渐增加相关特征
- 后向搜索：从完整的特征集合开始，逐渐减少无关特征
- 双向搜索：每一轮逐渐增加相关特征，同时减少无关特征
- 终止条件：本轮的最优的子集评价结果不如上一轮

贪心策略存在问题：最优和次优？

前向搜索

- 最优子集初始为空集，特征集合初始时包括所有给定特征



基于信息熵的子集评价

- 给定数据集 D ，假定 D 中第 i 类样本所占的比例为 P_i ($i=1, \dots, |Y|$)。

- 信息熵 $\text{Ent}(D) = - \sum_{i=1}^{|Y|} p_i \log_2 p_i$

- 属性子集 A ，根据其取值将 D 分成 V 个子集 $\{D^1, \dots, D^V\}$,

特征子集 A 的信息增益

$$\text{Gain}(A) = \text{Ent}(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} \text{Ent}(D^v)$$

子集评价

- 特征子集 A 确定了对数据集 D 的一个划分
 - 每个划分区域对应着特征子集 A 的某种取值
- 样本标记 Y 对应着对数据集 D 的真实划分
- 通过估算这两个划分的差异，就能对特征子集 A 进行评价；与样本标记对应的划分的差异越小，则说明当前特征子集 A 越好

其它的子集评价

- 方差过滤
 - 通过特征方差筛选特征；方差小，样本在特征上没有差异；剔除方差小的特征。

$$\sigma^2 = \frac{1}{n} \sum_{i=1}^n (x_i - \bar{x})^2$$

```
1 from sklearn.feature_selection import VarianceThreshold
2 variancethreshold = VarianceThreshold() #实例化, 默认方差为 0.方差<=0 的过滤掉
3 df_titanic_numerical = df_titanic[['age', 'sibsp', 'parch', 'fare', 'family_size']]
4 X_var = variancethreshold.fit_transform(df_titanic_numerical) #获取删除不合格特征后的新特征矩阵
5 del_list = df_titanic_numerical.columns[variancethreshold.get_support()==0].to_list() #获得删除
```

其它的子集评价

- 卡方校验

$$\chi^2 = \sum \frac{(\text{观测频数} - \text{期望频数})^2}{\text{期望频数}} = \sum_{i=1}^r \sum_{j=1}^c \frac{(O_{i,j} - E_{i,j})^2}{E_{i,j}}$$

- 卡方校验特征选择方法，即特征 f_i 和类别 Y 之间的独立性检验
- 原假设 H_0 ，特征 f_i 和类别 Y 之间是独立的。为了获得更好的分类效果，肯定是要找类别 Y 相关的特征，所以选择特征应该是拒绝原假设 (H_1) 的特征。
- 基本流程：1. 根据观察值构建期望值；2. 计算统计量和p-value；3. 计算自由度；4. 根据统计量和p-value进行决策。
- 为了更好地捕捉相关性，追求p小于显著性水平的特征。

其它的子集评价

- 卡方校验(举例)

```
1 df_titanic_categorical = df_titanic[['sex', 'class', 'embarked', 'who',  
   'age_bin', 'adult_male', 'alone', 'fare_bin']]  
2 df_titanic_numerical = df_titanic[['age', 'sibsp', 'parch', 'fare', 'family_size', 'pclass']]  
3 df_titanic_categorical_one_hot = pd.get_dummies(df_titanic_categorical, columns=['sex', 'class', 'embarked',  
   'who', 'age_bin', 'adult_male', 'alone', 'fare_bin'], drop_first=True)  
4 df_titanic_combined = pd.concat([df_titanic_numerical, df_titanic_categorical_one_hot], axis=1)  
5  
6 y = df_titanic['survived']  
7 X = df_titanic_combined.iloc[:, 1:]  
8  
9 from sklearn.feature_selection import chi2  
10 from sklearn.feature_selection import SelectKBest  
11 chi_value, p_value = chi2(X, y)  
12 #根据 p 值, 得出 k 值  
13 k = chi_value.shape[0] - (p_value > 0.05).sum() #要保留的特征的数量 14  
14 #根据卡方值, 选择前几特征, 筛选后特征  
15 X_chi = SelectKBest(chi2, k=14).fit_transform(X, y)
```


其它的子集评价

- F检验

- 建立在 F 分布基础上的假设检验方法，服从 F 分布的随机变量与上文中卡方分布的关系如下：

$$F = \frac{X_1/d_1}{X_2/d_2}$$

- 其中 X_1 和 X_2 分别服从自由度为 d_1 和 d_2 的卡方分布，且 X_1 与 X_2 独立，则随机变量 F 服从自由度为 (d_1, d_2) 的 F 分布。
- 捕获相关性，追求p-value值小于显著性水平特征。

```
1 from sklearn.feature_selection import f_classif
2 f_value, p_value = f_classif(X,y)
3 #根据 p 值, 得出 k 值
4 k = f_value.shape[0] - (p_value > 0.05).sum()
5 #筛选后特征
6 X_classif = SelectKBest(f_classif, k=14).fit_transform(X, y)
```

其它的子集评价

- 互信息法

- 互信息法是用来捕捉每个特征与标签之间的关系过的滤方法，可从基于 KL 散度和基于信息增益两个角度解释。

- KL 散度可以用来衡量两个概率分布之间的差异，若 $I(X; Y)$ 越大，则表示两个变量相关性越大。

$$I(X; Y) = \sum_{y \in \mathcal{Y}} \sum_{x \in \mathcal{X}} p(x, y) \log \left(\frac{p(x, y)}{p(x)p(y)} \right) = D_{KL}(p(x, y) || p(x)p(y))$$

- 从信息增益的角度来看，互信息表示由于引入 X 而使 Y 的不确定性减少的量。信息增益越大，意味着特征 X 包含的有助于将 Y 分类的信息越。

$$I(D; A) = H(D) - H(D|A) = H(D) - \sum_{v=1}^V \frac{|D^v|}{|D|} H(D^v)$$

其它的子集评价

- 互信息法

```
1 from sklearn.feature_selection import mutual_info_classif as MIC
2 #互信息法
3 mic_result = MIC(X,y)    #互信息量估计
4 k = mic_result.shape[0] - sum(mic_result <= 0)    #16
5 X_mic = SelectKBest(MIC, k=16).fit_transform(X, y)
```

特征选择方法

- 将特征子集搜索机制与子集评价机制相结合，即可得到特征选择方法，主要考虑2个方向：
 - 特征发散程度：如果一个特征不发散，例如方差接近于0，也就是说样本在这个特征上基本上没有差异，这个特征对于样本的区分并没有什么用。
 - 特征与目标的相关性：特征与目标相关性高，越应当被保留。

特征选择方法

- 常见的特征选择方法大致分为如下三类：
 - 过滤式：按照发散性或者相关性对各个特征评分，设定阈值或者待选择阈值的个数来选择特征.
 - 包裹式：根据目标函数预测效果评分，每次选择若干特征或者排除若干特征.
 - 嵌入式：先使用机器学习的算法进行训练，得到各个特征的权值系数，根据系数从大到小选择特征.

内容大纲

- 背景知识
- 子集搜索与评价
- 过滤式选择
- 包裹式选择
- 嵌入式选择与L1正则化
- 稀疏表示与字典学习
- 压缩感知

过滤式选择

- 先用特征选择过程过滤原始数据，再用过滤后的特征来训练模型；特征选择过程与后续学习器无关
- Relief (Relevant Features) 方法
 - 为每个初始特征赋予一个“相关统计量”，度量特征的重要性
 - 特征子集的重要性：子集中特征所对应的相关统计量之和决定
 - 设计一个阈值，选择比阈值大的相关统计量分量所对应的特征
 - 或者指定欲选取的特征个数，然后选择相关统计量分量最大的指定个数特征

过滤式选择

- Relief (Relevant Features) 方法

- 给定训练集 $\{(x_1, y_1), (x_2, y_2), \dots, (x_m, y_m)\}$, 对于任意个样本 x_i
- 猜中近邻(near-hit): x_i 的同类样本中的最近邻 $x_{i,nh}$
- 猜错近邻(near-miss): x_i 的异类样本中的最近邻 $x_{i,nm}$
- 相关统计量对应于属性 j 的分量

$$\delta^j = \sum_i -\text{diff}\left(x_i^j, x_{i,nh}^j\right)^2 + \text{diff}\left(x_i^j, x_{i,nm}^j\right)^2$$

- x_i^j 表示样本 x_i 在属性 j 上的取值, $\text{diff}(x_a^j, x_b^j)$ 取决于属性 j 的类型

过滤式选择

- Relief (Relevant Features) 方法
 - 若属性 j 为离散型，则 $x_a^j = x_b^j$ 时 $\text{diff}(x_a^j, x_b^j)=0$ ，否则为 1；
 - 若属性 j 为连续型，则 $\text{diff}(x_a^j, x_b^j)=|x_a^j - x_b^j|$ 。
 - 若 $|x_a^j - x_{a,nh}^j| < |x_a^j - x_{a,nm}^j|$ ，则说明属性 j 对区分同类与异类样本是有益，增大属性 j 所对应的统计量分量；
 - 若 $|x_a^j - x_{a,nh}^j| \geq |x_a^j - x_{a,nm}^j|$ ，则说明属性 j 起负面作用，减少属性 j 所对应的统计量分量。
 - 统计分量越大，则对应属性的分类能力越强。

过滤式选择

- Relief (Relevant Features) 扩展多分类方法
 - 数据集中的样本来自 $|Y|$ 个类别，其中 x_i 属于第 k 类
 - 猜中近邻：第 k 类中 x_i 的最近邻 $x_{i,nh}$
 - 猜错近邻：第 k 类之外的每个类中找到一个 x_i 的最近邻作为猜错近邻，记为 $x_{i,l,nm} (l = 1, 2, \dots, |Y|; l \neq k)$
 - 相关统计量对应于属性 j 的分量为

$$\delta^j = \sum_i -\text{diff}\left(x_i^j, x_{i,nh}^j\right)^2 + \sum_{l \neq k} \left(p_l \times \text{diff}\left(x_i^j, x_{i,l,nm}^j\right)^2 \right)$$

p_l 为第 l 类样本
在数据集 D 中
所占的比例.

内容大纲

- 背景知识
- 子集搜索与评价
- 过滤式选择
- 包裹式选择
- 嵌入式选择与L1正则化
- 稀疏表示与字典学习
- 压缩感知

包裹式选择

- 直接把最终将要使用的学习器的性能作为特征子集的评价准则
 - 包裹式特征选择的目的是为给定学习器选择最有利于其性能、“量身定做”的特征子集
 - 包裹式选择方法直接针对给定学习器进行优化，因此从最终学习器性能来看，包裹式特征选择比过滤式特征选择更好
 - 包裹式特征选择过程中需多次训练学习器，计算开销通常比过滤式特征选择大得多

包裹式选择

- LVW包裹式特征选择算法
 - 在每一轮循环中，随机产生一个特征子集
 - 在随机产生的特征子集上，通过交叉验证推断当前特征子集的误差
 - 进行多次循环，在多个随机产生的特征子集中选择误差最小的特征子集作为最终解*

输入：数据集 D ;
特征集 A ;
学习算法 $\mathcal{L}$;
停止条件控制参数 T .

过程:

```
1:  $E = \infty$ ;  
2:  $d = |A|$ ;  
3:  $A^* = A$ ;  
4:  $t = 0$ ;  
5: while  $t < T$  do  
6:   随机产生特征子集  $A'$ ;  
7:    $d' = |A'|$ ;  
8:    $E' = \text{CrossValidation}(\mathcal{L}(D^{A'}))$ ;  
9:   if  $(E' < E) \vee ((E' = E) \wedge (d' < d))$  then  
10:     $t = 0$ ;  
11:     $E = E'$ ;  
12:     $d = d'$ ;  
13:     $A^* = A'$   
14:   else  
15:     $t = t + 1$   
16:   end if  
17: end while
```

输出：特征子集 A^* .

包裹式选择

- LVW 算法分析
 - 算法第 8 行是通过在数据集 D 上，使用交叉验证法来估计学习器 L 的误差，注意这个误差是在仅考虑特征子集 A' 时得到的，即特征子集 A' 上的误差，若它比当前特征子集 A 上的误差更小，或误差相当，但 A' 中包含特征数更少，则将 A' 保留下来。
 - 特征子集搜索采用了随机策略，而每次特征子集评价都需训练学习器，计算开销很大，因此算法设置了停止条件控制参数 T

内 容 大 纲

- 子集搜索与评价
- 过滤式选择
- 包裹式选择
- 嵌入式选择与L1正则化
- 稀疏表示与字典学习
- 压缩感知

嵌入式选择

- 将特征选择过程与学习器训练过程融为一体，两者在同一个优化过程中完成，在学习器训练过程中自动地进行特征选择
- 给定数据集 $D = \{(\mathbf{x}_1, y_1), (\mathbf{x}_2, y_2), \dots, (\mathbf{x}_m, y_m)\}$
- 线性回归模型，平方误差作为损失函数，优化目标：

$$\min_w \sum_{i=1}^m (y_i - w^T \mathbf{x}_i)^2$$

嵌入式选择

- 在线性回归模型基础上，引入L2范数正则化项防止过拟合，则有：

$$\min_{\mathbf{w}} \sum_{i=1}^m (y_i - \mathbf{w}^T \mathbf{x}_i)^2 + \lambda \|\mathbf{w}\|_2^2 \quad \text{岭回归 (Ridge Regression)}$$

- 将L2范数替换为L1范数，则有Lasso

$$\min_{\mathbf{w}} \sum_{i=1}^m (y_i - \mathbf{w}^T \mathbf{x}_i)^2 + \lambda \|\mathbf{w}\|_1$$


易获得稀疏解，也是一种嵌入式特征选择方法

嵌入式选择

- 为什么不用L0范数做正则化
- 矩阵的L0范数就是非0元素的个数，通常用它来表示稀疏，L0范数越小，0元素越多，也就越稀疏。

$$\|\mathbf{x}\|_0 = \lim_{p \rightarrow 0} \|\mathbf{x}\|_p^p = \lim_{p \rightarrow 0} \sum_{k=1}^m |x_k|^p = \#\{i : x_i \neq 0\}.$$

- p 趋近于0时，函数就只有在 $x = 0$ 的时候等于0，其他的位置都为1，也就是说，L0-Norm可以用于表达一个向量/矩阵的稀疏性，且是非凸函数。




计算困难：随着参数维度的增加，需要枚举所有可能的参数组合，这在计算上是不现实的，特别是在高维数据中。

函数性质：L0函数是不连续、非凸、且在0处不可导的。

凸近似的替代方案：为了克服L0优化的困难，我们通常使用L1范数来代替。

嵌入式选择



假设 x 仅有两个属性，那么 w 有两个 w_1 和 w_2 ，绘制平方误差和L1、L2范数等值线

目标优化的解要在平方误差项与正则化项之间折中，即出现在图中平方误差等值线与正则化等值线相交处。

从图中看出，采用L1范数时交点常出现在坐标轴上，即产生 w_1 或 w_2 为0的稀疏解。

等值线即取值相同的点的连线

嵌入式选择

- 由于不可微凸函数，L1正则化问题求解近端梯度下降 (PGD)，优化目标：
$$\min_{\mathbf{x}} f(\mathbf{x}) + \lambda \|\mathbf{x}\|_1$$

- $f(\mathbf{x})$ 的二阶泰勒展开式

$$f(\mathbf{x}) = f(\mathbf{x}_k) + \left\langle \nabla f(\mathbf{x}_k), \mathbf{x} - \mathbf{x}_k \right\rangle + \frac{1}{2} (\mathbf{x} - \mathbf{x}_k)^\top \frac{\delta^2 f(\mathbf{x}_k)}{\delta \mathbf{x}_k^2} (\mathbf{x} - \mathbf{x}_k)$$

- 假设 $f(\mathbf{x})$ 满足L-Lipschitz条件（比“连续”更强的光滑性条件，符合L条件的函数斜率，小于L常数），即存在常数 $L > 0$ ，使得

$$\| \nabla f(\mathbf{x}') - \nabla f(\mathbf{x}) \| \leq L \| \mathbf{x}' - \mathbf{x} \| \quad (\forall \mathbf{x}, \mathbf{x}') \quad \nabla^2 f(\mathbf{x}) \leq L$$

嵌入式选择

- L-Lipschitz条件代入泰勒展开式，可得

$$\begin{aligned}\hat{f}(\mathbf{x}) &\simeq f(\mathbf{x}_k) + \langle \nabla f(\mathbf{x}_k), \mathbf{x} - \mathbf{x}_k \rangle + \frac{\nabla^2 f(\mathbf{x}_k)}{2} \|\mathbf{x} - \mathbf{x}_k\|^2 \\ &\leq f(\mathbf{x}_k) + \langle \nabla f(\mathbf{x}_k), \mathbf{x} - \mathbf{x}_k \rangle + \frac{L}{2} \|\mathbf{x} - \mathbf{x}_k\|^2 \\ &= f(\mathbf{x}_k) + \nabla f(\mathbf{x}_k)^\top (\mathbf{x} - \mathbf{x}_k) + \frac{L}{2} (\mathbf{x} - \mathbf{x}_k)^\top (\mathbf{x} - \mathbf{x}_k) \\ &= f(\mathbf{x}_k) + \frac{L}{2} \left((\mathbf{x} - \mathbf{x}_k)^\top (\mathbf{x} - \mathbf{x}_k) + \frac{2}{L} \nabla f(\mathbf{x}_k)^\top (\mathbf{x} - \mathbf{x}_k) \right) \\ &= f(\mathbf{x}_k) + \frac{L}{2} \left((\mathbf{x} - \mathbf{x}_k)^\top (\mathbf{x} - \mathbf{x}_k) + \frac{2}{L} \nabla f(\mathbf{x}_k)^\top (\mathbf{x} - \mathbf{x}_k) + \frac{1}{L^2} \nabla f(\mathbf{x}_k)^\top \nabla f(\mathbf{x}_k) \right) - \frac{1}{2L} \nabla f(\mathbf{x}_k)^\top \nabla f(\mathbf{x}_k) \\ &= f(\mathbf{x}_k) + \frac{L}{2} \left((\mathbf{x} - \mathbf{x}_k) + \frac{1}{L} \nabla f(\mathbf{x}_k) \right)^\top \left((\mathbf{x} - \mathbf{x}_k) + \frac{1}{L} \nabla f(\mathbf{x}_k) \right) - \frac{1}{2L} \nabla f(\mathbf{x}_k)^\top \nabla f(\mathbf{x}_k) \\ &= \frac{L}{2} \left\| \mathbf{x} - \left(\mathbf{x}_k - \frac{1}{L} \nabla f(\mathbf{x}_k) \right) \right\|_2^2 + \text{const}\end{aligned}$$

其中 $\text{const} = f(\mathbf{x}_k) - \frac{1}{2L} \nabla f(\mathbf{x}_k)^\top \nabla f(\mathbf{x}_k)$

嵌入式选择

- L-Lipschitz条件代入泰勒展开式, 可得

$$\begin{aligned}\hat{f}(\mathbf{x}) &\simeq f(\mathbf{x}_k) + \left\langle \nabla f(\mathbf{x}_k), \mathbf{x} - \mathbf{x}_k \right\rangle + \frac{L}{2} \|\mathbf{x} - \mathbf{x}_k\|^2 \\ &= \frac{L}{2} \left\| \mathbf{x} - \left(\mathbf{x}_k - \frac{1}{L} \nabla f(\mathbf{x}_k) \right) \right\|_2^2 + \text{const}\end{aligned}$$

- 上式最小值在如下 $\mathbf{x}_{k+1}$ 获得:

$$\mathbf{x}_{k+1} = \mathbf{x}_k - \frac{1}{L} \nabla f(\mathbf{x}_k)$$

嵌入式选择

- 对 $f(x)$ 的梯度下降法进行最小化求解，每一步梯度下降迭代求解释等价于最小化二次函数 $\hat{f}(\mathbf{x})$ ，即每步优化为：

$$\mathbf{x}_{k+1} = \arg \min_{\mathbf{x}} \frac{L}{2} \left\| \mathbf{x} - \left(\mathbf{x}_k - \frac{1}{L} \nabla f(\mathbf{x}_k) \right) \right\|_2^2 + \lambda \|\mathbf{x}\|_1$$

- 每步对 $f(x)$ 梯度下降迭代时都要考虑1范数最小化。令 $\mathbf{z} = \mathbf{x}_k - \frac{1}{L} \nabla f(\mathbf{x}_k)$ ，只需求解

$$\mathbf{x}_{k+1} = \arg \min_{\mathbf{x}} \frac{L}{2} \|\mathbf{x} - \mathbf{z}\|_2^2 + \lambda \|\mathbf{x}\|_1$$

嵌入式选择

- 如何求上式的闭式解

$$g(\mathbf{x}) = \frac{L}{2} \|\mathbf{x} - \mathbf{z}\|_2^2 + \lambda \|\mathbf{x}\|_1$$

按照第*i*个
分量展开

$$= \frac{L}{2} \sum_{i=1}^d \|x^i - z^i\|_2^2 + \lambda \sum_{i=1}^d \|x^i\|_1$$

$\mathbf{x}$ 的各分量
互不影响

$$= \sum_{i=1}^d \left(\frac{L}{2} (x^i - z^i)^2 + \lambda |x^i| \right)$$

$$g(x^i) = \frac{L}{2} (x^i - z^i)^2 + \lambda |x^i|$$

$$\frac{dg(x^i)}{dx^i} = L(x^i - z^i) + \lambda \operatorname{sgn}(x^i)$$

$$\operatorname{sign}(x^i) = \begin{cases} 1, & x^i > 0 \\ -1, & x^i < 0 \end{cases}$$

$$x_{k+1}^i = \begin{cases} z^i - \lambda/L, & \lambda/L < z^i; \\ 0, & |z^i| \leq \lambda/L; \\ z^i + \lambda/L, & z^i < -\lambda/L, \end{cases}$$

$$x^i = z^i - \frac{\lambda}{L} \operatorname{sign}(x^i)$$

当 $z^i > \frac{\lambda}{L}$ 时

当 $z^i < -\frac{\lambda}{L}$ 时

当 $-\frac{\lambda}{L} \leq z^i \leq \frac{\lambda}{L}$ 时

假设

$$x^i > 0$$

$$x^i < 0$$

分步骤讨论?

嵌入式选择

• 如何求上式的闭式解

$$g(\mathbf{x}) = \frac{L}{2} \|\mathbf{x} - \mathbf{z}\|_2^2 + \lambda \|\mathbf{x}\|_1$$

按照第*i*个
分量展开

$$= \frac{L}{2} \sum_{i=1}^d \|x^i - z^i\|_2^2 + \lambda \sum_{i=1}^d \|x^i\|_1$$

$\mathbf{x}$ 的各分量

$$= \sum_{i=1}^d \left(\frac{L}{2} (x^i - z^i)^2 + \lambda |x^i| \right)$$

互不影响

$$g(x^i) = \frac{L}{2} (x^i - z^i)^2 + \lambda |x^i|$$

$$\frac{dg(x^i)}{dx^i} = L(x^i - z^i) + \lambda \operatorname{sgn}(x^i)$$

$$\operatorname{sign}(x^i) = \begin{cases} 1, & x^i > 0 \\ -1, & x^i < 0 \end{cases}$$

$$x_{k+1}^i = \begin{cases} z^i - \lambda/L, & \lambda/L < z^i; \\ 0, & |z^i| \leq \lambda/L; \\ z^i + \lambda/L, & z^i < -\lambda/L, \end{cases}$$

$$x^i = z^i - \frac{\lambda}{L} \operatorname{sign}(x^i)$$

(1) 当 $z^i > \frac{\lambda}{L}$ 时:

a. 假设 $x^i < 0$, 则 $\operatorname{sgn}(x^i) = -1$, 那么有 $x^i = z^i + \frac{\lambda}{L} > 0$ 与假设矛盾.

b. 假设 $x^i > 0$, 则 $\operatorname{sgn}(x^i) = 1$, 那么有 $x^i = z^i - \frac{\lambda}{L} > 0$ 和假设相符合.

(2) 当 $z^i < -\frac{\lambda}{L}$ 时:

a. 假设 $x^i > 0$, 则 $\operatorname{sgn}(x^i) = 1$, 那么有 $x^i = z^i - \frac{\lambda}{L} < 0$ 与假设矛盾.

b. 假设 $x^i < 0$, 则 $\operatorname{sgn}(x^i) = -1$, 那么有 $x^i = z^i + \frac{\lambda}{L} < 0$ 与假设相符.

(3) 当 $-\frac{\lambda}{L} \leq z^i \leq \frac{\lambda}{L}$ 时:

a. 假设 $x^i > 0$, 则 $\operatorname{sgn}(x^i) = 1$, 那么有 $x^i = z^i - \frac{\lambda}{L} \leq 0$ 与假设矛盾.

b. 假设 $x^i < 0$, 则 $\operatorname{sgn}(x^i) = -1$, 那么有 $x^i = z^i + \frac{\lambda}{L} \geq 0$ 与假设矛盾.

内容大纲

- 背景知识
- 子集搜索与评价
- 过滤式选择
- 包裹式选择
- 嵌入式选择与L1正则化
- 稀疏表示与字典学习
- 压缩感知

稀疏表示


- 将数据集考虑成一个矩阵，每行对应一个样本，每列对应一个特征
 - 特征选择中“稀疏性”，去除与当前学习任务无关，学习器仅在较小矩阵训练，学习难度降低.
 - 矩阵中有很多零元素，且非整行整列出现，如文本分类.
- 稀疏表达的优势
 - 文本数据的词频表示，稀疏性使得模型线性可分，如SVM.
 - 稀疏性存储效率高，比如元组表示 (x, a, value) .

能否将稠密表示的数据集转化为“稀疏表示”？

字典学习

以图像分类为例，为普通稠密表达的样本找到合适的字典，将样本转化为稀疏表示，这一过程称为字典学习。

$$x = D\alpha$$



字典学习

字典学习或稀疏编码，同一优化过程完成，简化学习任务.

- 给定数据集 $x_1, x_2, \dots, x_m, x_i \in R^d$
- 学习目标是字典矩阵 $B \in R^{d \times k}$ 和样本的稀疏表示 $\alpha_i \in R^k$;
- k 为字典的词汇量，通常由用户指定;

$k > d$: over-complete (超完备字典)

$k = d$: complete, 如傅里叶变换和DCT变换

$k < d$: under-complete (欠完备字典)

- 字典学习的优化形式，定义为

$$\min_{\mathbf{B}, \alpha_i} \sum_{i=1}^m \left\| \mathbf{x}_i - \mathbf{B}\alpha_i \right\|_2^2 + \lambda \sum_{i=1}^m \left\| \alpha_i \right\|_1$$

与Lasso的区别?

字典学习

- 如何求解字典学习? 变量交替优化策略

- Step1: 固定字典 $\mathbf{B}$, 参考Lasso的求解方法, 为每个样本 x_i 找到相应的 α_i :

- $$\min_{\alpha_i} \left\| \mathbf{x}_i - \mathbf{B}\alpha_i \right\|_2^2 + \lambda \left\| \alpha_i \right\|_1$$

- Step2: 固定住 α_i 来更新字典 $\mathbf{B}$, 公式改写为:

- $$\min_{\mathbf{B}} \left\| \mathbf{X} - \mathbf{B}\mathbf{A} \right\|_F^2$$

- 其中, $\mathbf{X} = (\mathbf{x}_1, \mathbf{x}_2, \dots, \mathbf{x}_m) \in \mathbb{R}^{d \times m}$, $\mathbf{A} = (\alpha_1, \alpha_2, \dots, \alpha_m) \in \mathbb{R}^{k \times m}$,
上式解法, 常用的有基于逐列更新策略的 KSVD

字典学习

- 上式可以转换为

$$\min_{\mathbf{B}} \|\mathbf{X} - \mathbf{BA}\|_F^2 = \min_{b_i} \left\| \mathbf{X} - \sum_{j=1}^k b_j \alpha^j \right\|_F^2$$

- b_i 表示字典矩阵 $\mathbf{B}$ 的第 i 列
- α^i 表示稀疏矩阵 $\mathbf{A}$ 的第 i 行
- 在更新字典的第 i 列时

$$= \min_{b_i} \left\| \left(\mathbf{X} - \sum_{j \neq i} b_j \alpha^j \right) - b_i \alpha^i \right\|_F^2$$

其它列固定不变

$$= \min_{b_i} \left\| \mathbf{E}_i - b_i \alpha^i \right\|_F^2$$

只更新第 i 列

- 对 $\mathbf{E}_i$ 进行奇异值分解，取得最大奇异值对应的正交向量
- 为了不破坏 $\mathbf{A}$ 的稀疏性， α_i 仅保留非零元素， $\mathbf{E}_i$ 仅保留 $\mathbf{b}_i$ 与 α_i 非零元素的乘积项
- 反复迭代已获得最优解

内容大纲

- 背景知识
- 子集搜索与评价
- 过滤式选择
- 包裹式选择
- 嵌入式选择与L1正则化
- 稀疏表示与字典学习
- 压缩感知

压缩感知

能否利用部分数据恢复全部数据?

- 模拟信号 $\rightarrow$ 数字信号
 - 利用奈奎斯特定理（采样频率达到模拟信号最高频率的两倍），采样后保留模拟信号的全部信息，即数字信号能重构出原始模拟信号.
- 数据传输中，能否利用接收到的（采样时）压缩、（传输时）丢包后的数字信号，精确重构出原信号?
- 压缩感知 (compressive sensing) [Cándes et al., 2006, Donoho, 2006] 为解决此类问题提供了新的思路.

压缩感知

- 长度为 m 的离散信号 x ，以远小于奈奎斯特采样定理要求采样率，得到长度为 n 的采样后信号 y ， $n \ll m$ ，即 $y = \Phi x$ ，其中 $\Phi \in \mathbb{R}^{n \times m}$ 为对信号 x 的测量矩阵。
- 已知离散信号 x 和测量矩阵 Φ 时要得到测量值 y 很容易，能否通过测量值和测量矩阵还原出原始信号 x 吗？
- 一般情况下， $n \ll m$ ，不能用 y 还原 x 。
- 若存在某个线性变换 $\Psi \in \mathbb{R}^{m \times m}$ ，使得 x 可以表示为 Ψs ， y 表示为

$$y = \Phi \Psi s = \Lambda s, \Lambda = \Phi \Psi \in \mathbb{R}^{n \times m}$$

若能根据 y 恢复出 s ，则可通过 $x = \Psi s$ 来恢复出信号 x 。

Ψ 称为稀疏基， Λ 的作用相当于字典，将信号转化为稀疏表示， s 具有稀疏性。

压缩感知

- 如何利用信号的稀疏性，从部分观测样本中恢复原信号。
压缩感知分为“感知测量”和“重构恢复”这两个阶段。
 - “感知测量”：如何对原始信号进行处理以获得稀疏样本表示。
 - “重构恢复”：如何基于稀疏性从少量观测中恢复原信号。
- “限定等距性”：大小为 $n \times m (n \ll m)$ 的矩阵 $\mathbf{A}$ ，若存在常数 $\delta_k \in (0,1)$ 使得任意向量 $\mathbf{s}$ 和 $\mathbf{A}$ 的所有子矩阵 $\mathbf{A}_k \in \mathbb{R}^{n \times k}$ 有
$$(1 - \delta_k) \|\mathbf{s}\|_2^2 \leq \|\mathbf{A}_k \mathbf{s}\|_2^2 \leq (1 + \delta_k) \|\mathbf{s}\|_2^2$$
- 则称 $\mathbf{A}$ 满足 k 限定等距性 (k-RIP).

压缩感知

- 通过下面的优化问题近乎完美地从 y 中恢复出稀疏信号 s , 进而恢复出 x :

$$\min_{\mathbf{s}} \|\mathbf{s}\|_0$$

$$\text{s.t. } \mathbf{y} = \mathbf{A}\mathbf{s}$$

- L_0 范数最小化是 NP 难问题, 将上式转化为共解的 L_1 范数最小化问题

$$\min_{\mathbf{s}} \|\mathbf{s}\|_1$$

$$\text{s.t. } \mathbf{y} = \mathbf{A}\mathbf{s}$$

- 转化为 LASSO 的等价形式再通过近端梯度下降法求解, 即使使用"基追踪去噪"

压缩感知

- 恢复信息(部分信息恢复全部信息-典型应用)

	《笑傲江湖》	《万历十五年》	《人间词话》	《云海玉弓缘》	《人类的故事》
赵大	5	?	?	3	2
钱二	?	5	3	?	5
孙三	5	3	?	?	?
李四	3	?	5	4	?

- 矩阵补全，形式化描述， $\mathbf{X}$ 表示要恢复的稀疏信号

$$\min_{\mathbf{X}} \text{rank}(\mathbf{X}), \text{ s.t. } (\mathbf{X})_{ij} = (\mathbf{A})_{ij}, \quad (i,j) \in \Omega$$

- 上式也是 NP 难问题， $\text{rank}(\mathbf{X})$ 在集合 $\{\mathbf{X} \in \mathbb{R}^{m \times n} : \|\mathbf{X}\|_F^2 \leq 1\}$ 上的凸包是 $\mathbf{X}$ 的"核范数"

$$\|\mathbf{X}\|_* = \sum_{j=1}^{\min\{m,n\}} \sigma_j(\mathbf{X})$$

压缩感知

- $\sigma_j(\mathbf{X})$ 表示 $\mathbf{X}$ 的奇异值，即矩阵的核范数为矩阵的奇异值之和，于是可通过最小化矩阵核范数来近似求解式

$$\min_{\mathbf{X}} \|\mathbf{X}\|_* \quad \mathbf{s.t.} \quad (\mathbf{X})_{ij} = (\mathbf{A})_{ij}, \quad (i, j) \in \Omega$$

- 凸优化问题，通过半正定规划 (Semi-Definite Programming, 简称 SDP) 求解。
- 在满足一定条件时，若 A 的秩为 r , $n \ll m$, 则只需观察到 $O(mr \log 2m)$ 个元素就能完美恢复出 A

矩阵补全

- 将一个含有缺失值的矩阵通过一定的方法将其恢复为一个完全的矩阵。为什么满足低秩?
- 矩阵分解： $X \approx \tilde{X} = UV^T$

	Item				
	W	X	Y	Z	
User	A		4.5	2.0	
	B	4.0		3.5	
	C		5.0		2.0
	D		3.5	4.0	1.0

Rating Matrix

=

User	A	1.2	0.8
	B	1.4	0.9
	C	1.5	1.0
	D	1.2	0.8

User Matrix

X

	Item			
	W	X	Y	Z
	1.5	1.2	1.0	0.8
	1.7	0.6	1.1	0.4

Item Matrix

$$e_{ij} = x_{ij} - \sum_{l=1}^k u_{il}v_{jl}$$

矩阵补全

- 低秩矩阵分解目标函数

$$e_{ij} = x_{ij} - \sum_{l=1}^k u_{il} v_{jl}$$

- 梯度为

$$\frac{\partial J}{\partial u_{il}} = -2e_{ij}v_{jl}$$

$$\frac{\partial J}{\partial v_{jl}} = -2e_{ij}u_{il}$$

$$J = \|X - \hat{X}\|^2$$

$$= \|X - UV^T\|^2$$

$$= \sum_{i,j,x_i \neq \mathbf{nan}} \left(x_{ij} - \sum_{l=1}^k u_{il} v_{jl} \right)^2$$

梯度下降更新公式

$$u_{il} = u_{il} - \alpha \frac{\partial J}{\partial u_{il}} = u_{il} + 2\alpha e_{ij} v_{jl}$$

$$v_{jl} = v_{jl} - \alpha \frac{\partial J}{\partial v_{jl}} = u_{il} + 2\alpha e_{ij} u_{il}$$

谢谢！