

《神经网络与深度学习》

第八章—注意力机制

人工智能学院


王亚星

◆ 注意力机制 —— 信息筛选

- ◆ 注意力机制
- ◆ 人工神经网络的注意力机制
- ◆ 注意力机制的应用
- ◆ 自注意力模型
- ◆ Transformer

◆ 记忆增强网络 —— 外部信息

- ◆ 外部记忆
- ◆ 结构化外部记忆
- ◆ 基于神经动力学的联想记忆



全连接
前馈网络

循环网络



局部连接
权重共享



自反馈
记忆



结构扩展



卷积网络


图网络

增加网络能力的另一种思路：

- 注意力机制
- 外部记忆

◆ 阅读理解任务

◆ 让机器阅读文章后，通过问题判断机器是否理解文章



RNN

1. “张同学在五月花食堂买了一个肉夹馍。”
2. “他带着肉夹馍回到了南岭校区。”
3. “他又去日新楼拿了快递。”
4. 问：肉夹馍在哪？

◆ 阅读理解任务

- ◆ 长程依赖问题
- ◆ 无用信息混杂
- ◆ 内容信息增大，
维度升高，导致参
数量变大

The first recorded travels by Europeans to China and back date from this time. The most famous traveler of the period was the Venetian Marco Polo, whose account of his trip to "Cambaluc," the capital of the Great Khan, and of life there astounded the people of Europe. The account of his travels, *Il milione* (or, *The Million*, known in English as the *Travels of Marco Polo*), appeared about the year 1299. Some argue over the accuracy of Marco Polo's accounts due to the lack of mentioning the Great Wall of China, tea houses, which would have been a prominent sight since Europeans had yet to adopt a tea culture, as well the practice of foot binding by the women in capital of the Great Khan. Some suggest that Marco Polo acquired much of his knowledge **through contact with Persian traders** since many of the places he named were in Persian.

How did some suspect that Polo learned about China instead of by actually visiting it?

Answer: **through contact with Persian traders**

Wiki

Story非常长



寻找与问题
相关信息


注意力机制

- ◆人脑每个时刻接收的外界输入信息非常多，包括来源于视觉、听觉、触觉的各种各样的信息。
 - ◆单就视觉来说，眼睛每秒钟都会发送千万比特的信息给视觉神经系统。
- ◆人脑通过**注意力**来解决信息超载问题



注意力示例





所有黑色牌的数字之和为多少？

黑色牌中哪个花色是错的？

所有黑色牌的数字之和为多少？

神经网络中的注意力机制

◆ 自下而上：汇聚 (pooling)

例：报纸中的图片、大文字

◆ 自上而下：会聚 (focus)


例：回答已知问题

Attention!


- ◆鸡尾酒会效应：当一个人在吵闹的鸡尾酒会上和朋友聊天时，尽管周围噪音干扰很多，他还是可以听到朋友的谈话内容，而忽略其他人的声音。
- ◆同时，如果未注意到的背景声中有重要的词（比如他的名字），他会马上注意到。

较高的注意力保持在关键信息，并且对背景信息保持一定的注意力。

问题



Try to find 8 less than 8 seconds



◆软性注意力机制 (soft attention mechanism) 分为两步


◆计算注意力分布 α ,

$$\begin{aligned}\alpha_n &= p(z = n | \mathbf{X}, \mathbf{q}) \\ &= \text{softmax}(s(\mathbf{x}_n, \mathbf{q})) \\ &= \frac{\exp(s(\mathbf{x}_n, \mathbf{q}))}{\sum_{j=1}^N \exp(s(\mathbf{x}_j, \mathbf{q}))}\end{aligned}$$

$s(\mathbf{x}_n, \mathbf{q})$ 打分函数

◆根据 α 来计算输入信息的加权平均。

$$\begin{aligned}\text{att}(\mathbf{X}, \mathbf{q}) &= \sum_{n=1}^N \alpha_n \mathbf{x}_n, \\ &= \mathbb{E}_{z \sim p(z | \mathbf{X}, \mathbf{q})} [\mathbf{x}_z]\end{aligned}$$



◆ 注意力分布

- ◆ 为了从 N 个输入向量中选择出和某个特定任务相关的信息，需要引入一个和任务相关的表示，称为查询向量，并通过一个打分函数来计算每个输入向量和查询向量之间的相关性。
- ◆ 注意力分布可以解释为在给定任务相关的查询时，第 n 个输入向量受关注的程度。

◆ 常见的打分函数

◆ 加性模型

$$s(\mathbf{x}, \mathbf{q}) = \mathbf{v}^\top \tanh(\mathbf{W}\mathbf{x} + \mathbf{U}\mathbf{q}),$$

◆ 点积模型

$$s(\mathbf{x}, \mathbf{q}) = \mathbf{x}^\top \mathbf{q},$$

◆ 缩放点积模型

$$s(\mathbf{x}, \mathbf{q}) = \frac{\mathbf{x}^\top \mathbf{q}}{\sqrt{D}},$$



缩小方差，增大softmax梯度

◆ 双线性模型



$$s(\mathbf{x}, \mathbf{q}) = \mathbf{x}^\top \mathbf{W} \mathbf{q},$$

非对称性



◆常见的注意力机制的应用



(a) Text Classification



(b) Natural Language Inference



(c) Neural Machine Translation

◆ 注意力机制的变体


- ◆ 硬性注意力 (hard attention)
- ◆ 键值对注意力 (key-value pair attention)
- ◆ 多头注意力 (multi-head attention)
- ◆ 结构化注意力 (structural attention)
- ◆ 指针网络 (Pointer Network)

◆ 键值对注意力 (key-value pair attention)

◆ 用 $(K, V) = [(k_1, v_1), (k_2, v_2) \cdots, (k_n, v_n)]$ 表示 n 对输入信息，注意力分数计算如下：

$$\begin{aligned} \text{att}((K, V), q) &= \sum_{n=1}^N \alpha_n v_n, \\ &= \sum_{n=1}^N \frac{\exp(s(k_n, q))}{\sum_j \exp(s(k_j, q))} v_n \end{aligned}$$

$K = V$




◆ 多头注意力 (multi-head attention)

◆ 利用多个查询 $\mathbf{Q} = [q_1, q_2, \dots, q_m]$ ，来并行地从输入信息中选取多组信息。每个注意力关注输入信息的不同部分。

$$\text{att}(\mathbf{K}, \mathbf{V}, \mathbf{Q}) = \text{att}(\mathbf{K}, \mathbf{V}, \mathbf{q}_1) \oplus \dots \oplus \text{att}(\mathbf{K}, \mathbf{V}, \mathbf{q}_M)$$


↑
向量拼接操作

◆ **指针网络**：一种序列到序列模型；只利用注意力机制中的第一步，将注意力分布作为一个软性的指针（pointer）来指出相关信息的位置。



◆ 文本分类

The **infantile** cart is **easy** to use.



◆ 文本分类

I have not read the original version of this work , but the translation lacks originality and art . A beautiful story , but the writing style lacks grace and creativity . This is the only time I have liked a movie better than the book . Do yourself a favor and skip the book . the movie is quite beautiful and moving


(a) Attention of task “Books” in SA-MTL, Output: Negative

I have not read the original version of this work , but the translation lacks originality and art . A beautiful story , but the writing style lacks grace and creativity . This is the only time I have liked a movie better than the book . Do yourself a favor and skip the book . the movie is quite beautiful and moving

(b) Attention of task “DVD” in SA-MTL, Output: Positive

◆ 文本分类

◆ 层次化



长文章






Figure 2: Hierarchical Attention Network.

◆ 机器翻译



◆ 机器翻译




Alignment

◆ 机器翻译



◆ Image Caption



◆ Image Caption

remote(0.23)



a(0.41)



sky(0.61)



on(0.27)



red(0.38)



woman(0.36)



of(0.19)



A(0.99)



racket(0.16)




a(0.33)




sink(0.48)



of(0.20)




◆ 多模态检索 Retrieval




Chuan Tang, Xi Yang, Bojian Wu, Zhizhong Han, Yi Chang; Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition (CVPR), 2023, pp. 6884–6893

自注意力模型

- ◆ 在使用神经网络来处理一个变长的向量序列时，通常可以使用卷积网络或循环网络进行编码来得到一个相同长度的输出向量序列。但这样只建模了输入信息的局部依赖关系。




(a) 卷积网络



(b) 双向循环网络



◆ 如何建立非局部的依赖关系？

◆ 自注意力 (Self-Attention) 模型



(a) 全连接模型

无法处理变长问题




(b) 自注意力模型

连接权重 α_{ij} 由注意力机制动态生成

权重与内容相关？ 位置相关？

◆ 示例



$$x' = x \cdot \text{softmax}(x^T \cdot x)$$

$$w_1, w_2, w_3, w_4, w_5 = \text{softmax} \left(\begin{bmatrix} 0.6 & 0.2 & 0.8 \end{bmatrix} \times \begin{bmatrix} 0.6 & 0.2 & 0.9 & 0.4 & 0.4 \\ 0.2 & 0.3 & 0.1 & 0.1 & 0.1 \\ 0.8 & 0.1 & 0.8 & 0.4 & 0.6 \end{bmatrix} \right)$$

The

The weather is nice today

$$\begin{bmatrix} 1.8 \\ 2.3 \\ 0.4 \end{bmatrix} = w_1 \times \begin{bmatrix} 0.6 \\ 0.2 \\ 0.8 \end{bmatrix} + w_2 \times \begin{bmatrix} 0.2 \\ 0.3 \\ 0.1 \end{bmatrix} + w_3 \times \begin{bmatrix} 0.9 \\ 0.1 \\ 0.8 \end{bmatrix} + w_4 \times \begin{bmatrix} 0.4 \\ 0.1 \\ 0.4 \end{bmatrix} + w_5 \times \begin{bmatrix} 0.4 \\ 0.1 \\ 0.6 \end{bmatrix}$$

The The weather is nice today

◆ 查询-键-值模式 (Query-Key-Value)

◆ 通过输入序列首先生成三个向量序列

$$Q = W_q X \in \mathbb{R}^{D_k \times N},$$

$$K = W_k X \in \mathbb{R}^{D_k \times N},$$


$$V = W_v X \in \mathbb{R}^{D_v \times N},$$

◆ 计算输出向量


$$h_n = \text{att}((K, V), q_n)$$

◆ 如果使用缩放点积作为注意力打分函数，输出向量序列可以简写为

$$H = V \text{softmax}\left(\frac{K^T Q}{\sqrt{D_k}}\right),$$



◆ 加入多头 (multi-head)



与 CNN 多通道
作用相似

◆ 自注意力模型作为神经网络中的一层使用

◆ 仅仅自注意力还不够
(位置无关)


◆ 除自注意力还引入其它操作:

◆ 位置编码


◆ 层归一化

◆ 直连边 (残差连接)

◆ 逐位的FFN



◆Transformer 编码器



TRANSFORMER EXPLAINER

Examples ▾

I love china, she is beaufaful and careful


Generate

Temperature

0.8

Sampling ☒ Top-k ☐ Top-p

— $k=5$



<https://poloclub.github.io/transformer-explainer/>


◆ 复杂度比较

模型	每层复杂度	序列操作数	最大路径长度
CNN	$O(kLd^2)$	$O(1)$	$O(\log_k(L))$
RNN	$O(Ld^2)$	$O(L)$	$O(L)$
Transformer	$O(L^2d)$	$O(1)$	$O(1)$

k 卷积核大小 L 序列长度 d 维度

◆ Transformer 完整结构


◆ 左侧为编码器，右侧为解码器



◆Transformer

◆ Bert

◆ 仅使用Transformer编码器结构的预训练语言模型



Vision Transformer




Image generation

Try Seedance 2.0 from ByteDance >

Idwangyaxing-cmd

Search 'best image models' or 'text to image' cmd+k

Dashboard ▾ Explore ▾ Create ▾ Pricing Enterprise Docs Blog

 **black-forest-labs / flux-2-pro** 

High-quality image generation and editing with support for eight reference images

• Warm  Official  6.3M runs  Priced by multiple properties  Commercial use  Zero training

► Playground  API  Examples  README

Input

Form JSON Node.js Python HTTP

T prompt * string  +  to add a new line

a paper with "jilin university " on fly outside 

Text prompt for image generation

Reset to default inputs Run (cmd+enter)

Output

Preview JSON



<https://replicate.com/black-forest-labs/flux-2-pro?prediction=hkjm93ex1rmr0cy19mrjvxyem>

外部记忆

- ◆记忆：外界信息在人脑中的内部表示
- ◆记忆过程
 - ◆工作记忆（短期记忆）
 - ◆情景记忆
 - ◆结构记忆（长期记忆）
- ◆特点：联想记忆（Associative Memory）

◆不严格的类比

记忆周期	计算机	人脑	神经网络
短期	寄存器	短期记忆	状态（神经元活性）
中期	内存	工作记忆	外部记忆
长期	外存	长期记忆	可学习参数
存储方式	随机寻址	内容寻址	内容寻址为主

◆人的记忆

◆外部存储

◆例：笔记

◆分组


◆例：手机号码

◆ 记忆增强神经网络 (Memory Augmented Neural Network)

◆ 主网络

◆ 外部记忆 (一个辅助的模块)

◆ 读写操作




结构化的外部记忆

◆外部记忆定义为二维矩阵 $M \in \mathbb{R}^{d \times k}$ ， k 是记忆片段的数量， d 是每个记忆片段的大小，大部分信息存储于外部记忆中，不需要全时参与主网络的运算。

◆端到端的记忆网络

“软性”寻址
(softmax)

注意力机制



$$q^{(1)} \Leftarrow f(x)$$

$$r = \sum_{n=1}^N \text{softmax}(a_n^T q) c_n,$$

$$q^{(2)} \Leftarrow r^{(1)} + q^{(1)}$$

◆ 图灵机

◆ 一种抽象数学模型，可以用来模拟任何可计算问题。


◆ 神经图灵机组件


◆ 控制器

◆ 外部记忆

◆ 读写操作

◆ 整个架构可微分






r_t 读向量

e_t 删除向量

a_t 增加向量

Differentiable neural computers (DeepMind)

Illustration of the DNC architecture



多个读入模块

调度策略

◆外部记忆类型

◆只读

- ◆记忆网络
- ◆RNN中的 h_t


◆可读写

- ◆NTM


基于神经动力学的联想记忆

◆通过神经网络的动态演化进行联想，将记忆模型引入神经网络


◆自联想/自编码器 (Auto-Encoder)



◆异联想（大部分机器学习问题都为异联想）



如何实现联想记忆?



Classical Conditioning



► 赫布法则 Hebb's Rule

- “当神经元A的一个轴突和神经元B很近，足以对它产生影响，并且持续地、重复地参与了对神经元B的兴奋，那么在这两个神经元或其中之一会发生某种生长过程或新陈代谢变化，以致于神经元A作为能使神经元B兴奋的细胞之一，它的效能加强了。”

----加拿大心理学家Donald Hebb,
《行为的组织》，1949

◆除了作为机器学习模型外，神经网络还可以作为一种记忆的存储和检索模型。

◆Hopfield网络



更新规则

$$w_{ii} = 0 \quad \forall i \in [1, m]$$

$$w_{ij} = w_{ji} \quad \forall i, j \in [1, m].$$

$$s_i = \begin{cases} +1 & \text{if } \sum_{j=1}^m w_{ij} s_j + b_i \geq 0, \\ -1 & \text{otherwise,} \end{cases}$$



$$\mathbf{s}_t = f(W\mathbf{s}_{t-1} + \mathbf{b})$$

$$X = s_0 \rightarrow s_1 \rightarrow \dots \rightarrow s_T \rightarrow y$$


◆Hopfield网络稳定可收敛

◆每个不同的网络状态定义一个标量属性，称为“能量”。

能量函数

$$E = -\frac{1}{2} \sum_{i,j} w_{ij} s_i s_j - \sum_i b_i s_i$$
$$= -\frac{1}{2} \mathbf{s}^T \mathbf{W} \mathbf{s} - \mathbf{b}^T \mathbf{s}.$$

◆从网络输入到收敛到吸引点的过程可认为是检索的过程



吸引点：给定一个外部输入，网络经过演化，会达到的稳定状态。
吸引点可以看作是网络中存储的信息

◆Hopfield网络

◆将一组向量**存储**在网络中的过程，可以看做是一种学习过程。

◆两个神经元之间的连接权重公式

$$w_{ij} = \frac{1}{N} \sum_{n=1}^N x_i^{(n)} x_j^{(n)},$$

◆赫布规则：如果两个神经元经常同时激活，则它们之间的连接加强；如果经常不同时激活，则连接消失。

◆作为网络中的组件

◆在不引入额外参数的情况下增加网络容量

◆将循环神经网络中的部分连接权重作为短期记忆，通过联想记忆模型进行更新，从而提高网络性能


◆ 注意力机制

- ◆ 软性注意力
- ◆ 多头注意力
- ◆ 指针网络
- ◆ 自注意力模型 (Transformer)

◆ 记忆增强网络 (外部记忆)

- ◆ Memory Network
- ◆ ~~神经图灵机~~
- ◆ ~~Hopfield网络~~

- ◆ **截止时间：** 下周日晚12:00
- ◆ **提交方式：** 每人作业以 pdf 格式提交，命名为“学号_姓名”，班长收齐将全班作业压缩包发送到邮箱：jyh24@mails.jlu.edu.cn
- ◆ **作业晚交政策：** 作业超过截止时间但在24小时以内，该次作业按照60%分数计算，超过24小时不计分
- ◆ 按装TRDE /Cursor
- ◆ latex (overleaf 使用)



◆**截止时间：** 下周日晚12:00

◆**提交方式：** 每人作业以 pdf 格式提交，命名为“学号_姓名”，班长收齐将全班作业压缩包发送到邮箱：jyh24@mails.jlu.edu.cn

◆**作业晚交政策：** 作业超过截止时间但在24小时以内，该次作业按照60%分数计算，超过24小时不计分

习题8-2 分析缩放点积模型可以缓解 Softmax 函数梯度消失的原因.

参见公式(8.4).

缩放点积模型

$$s(\mathbf{x}, \mathbf{q}) = \frac{\mathbf{x}^\top \mathbf{q}}{\sqrt{D}}, \quad (8.4)$$

习题8-3 当将自注意力模型作为一个神经层使用时，分析它和卷积层以及循环层在建模长距离依赖关系的效率和计算复杂度方面的差异. 参见第8.3节.

- ◆**截止时间**：下周日晚12:00
- ◆**提交方式**：每人作业以 pdf 格式提交，命名为“学号_姓名”，班长收齐将全班作业压缩包发送到邮箱：jyh24@mails.jlu.edu.cn
- ◆**作业晚交政策**：作业超过截止时间但在24小时以内，该次作业按照60%分数计算，超过24小时不计分

习题8-2 分析缩放点积模型可以缓解 Softmax 函数梯度消失的原因.

参见公式(8.4).

缩放点积模型

$$s(\mathbf{x}, \mathbf{q}) = \frac{\mathbf{x}^\top \mathbf{q}}{\sqrt{D}}, \quad (8.4)$$