

深度学习

第2章：机器学习概述

王亚星

人工智能学院


2026.03

- 机器学习
 - 概念
 - 原理
- 线性回归
 - 定义
 - 经验风险最小化
 - 最小均方误差
 - 结构风险最小化
 - 最大似然估计
 - 最大后验估计
- 评价指标
- 机器学习的几个关键点

机器学习 $\approx$ 构建一个映射函数 (mapping)

- 语音识别

$$f(\text{语音波形图}) = \text{“你好”}$$



- 图像识别

$$f(\text{猫咪照片}) = \text{“猫”}$$



- 围棋

$$f(\text{围棋棋盘}) = \text{“5-5” (落子位置)}$$



- 对话系统

$$f(\text{“你好”}) = \text{“今天天气真不错”}$$

用户输入


机器输出

为什么要“机器学习”？

- 现实世界的问题都比较复杂
 - 很难通过规则来手工实现




https://aistudio.google.com/prompts/1I_LHVjhpa0fl-p6alyFxn5Q9P_14lo1



https://adamharley.com/nn_vis/mlp/2d.html

什么是机器学习？

- 机器学习：通过**算法**使得机器能从大量**数据**中学习**规律**从而对新的样本做**决策**。
 - 规律：决策（预测）函数



机器学习的三要素

• 模型

- 线性方法: $f(\mathbf{x}, \theta) = \mathbf{w}^T \mathbf{x} + b$
- 广义线性方法: $f(\mathbf{x}, \theta) = \mathbf{w}^T \phi(\mathbf{x}) + b$
 - 如果 $\phi(\mathbf{x})$ 为可学习的非线性基函数, $f(\mathbf{x}, \theta)$ 就等价于神经网络。

例如 $\phi_k(\mathbf{x}) = h(\mathbf{w}_k^T \phi'(\mathbf{x}) + b_k), \forall 1 \leq k \leq K$

• 学习准则


- 期望风险 (Expected Risk)

$$\mathcal{R}(f) = \mathbb{E}_{(\mathbf{x}, y) \sim p(\mathbf{x}, y)} [\mathcal{L}(f(\mathbf{x}), y)],$$


• 优化

- 梯度下降


常见的机器学习问题



回归



分类




聚类

- 以线性回归（Linear Regression）为例
- 模型：

$$f(\mathbf{x}; \mathbf{w}, b) = \mathbf{w}^T \mathbf{x} + b$$

回归



• 损失函数

- 0-1 损失函数：模型在训练集上的错误率

$$\mathcal{L}(y, f(\mathbf{x}; \theta)) = \begin{cases} 0 & \text{if } y = f(\mathbf{x}; \theta) \\ 1 & \text{if } y \neq f(\mathbf{x}; \theta) \end{cases}$$

缺点：不连续，或导数为0，
难以优化



用连续可微的损失函数来替代

- 平方损失函数，可用于回归任务

$$\mathcal{L}(y, f(\mathbf{x}; \theta)) = \frac{1}{2} (y - f(\mathbf{x}; \theta))^2$$

- 交叉熵损失函数（Cross-Entropy Loss）

$$\mathcal{L}(\mathbf{y}, f(\mathbf{x}; \theta)) = -\mathbf{y}^T \log f(\mathbf{x}; \theta)$$

- 可用于分类任务

- 用于衡量两个概率分布之间的差异

$$= - \sum_{c=1}^C y_c \log f_c(\mathbf{x}; \theta)$$

模型预测为类别c的概率

- 期望风险未知，通过经验风险（Empirical Risk）近似

- 训练数据： $\mathcal{D} = \{x^{(n)}, y^{(n)}\}, i \in [1, N]$

$$\mathcal{R}_{\mathcal{D}}^{emp}(\theta) = \frac{1}{N} \sum_{n=1}^N \mathcal{L}(y^{(n)}, f(x^{(n)}, \theta))$$

- 经验风险最小化（Empirical Risk Minimization, 即ERM）



- 在选择合适的风险函数后，我们寻找一组参数 θ^* ，使得经验风险函数最小化。

$$\theta^* = \arg \min_{\theta} \mathcal{R}_{\mathcal{D}}^{emp}(\theta)$$

- 机器学习问题转化成为一个最优化问题

最优化问题

- 机器学习问题转化成为一个最优化问题
(<https://losslandscape.com/gallery/>)



$$\min_{\mathbf{x}} f(\mathbf{x})$$



优化方法可以分为：

- 迭代优化法
- 直接优化法

梯度下降法 (Gradient Descent)

注：迭代优化法的代表





提问：左图中的梯度方向是哪个方向？



$$\begin{aligned}\theta_{t+1} &= \theta_t - \alpha \frac{\partial \mathcal{R}(\theta)}{\partial \theta_t} \\ &= \theta_t - \alpha \frac{1}{N} \sum_{i=1}^N \frac{\partial \mathcal{L}(\theta_t; x^{(i)}, y^{(i)})}{\partial \theta}.\end{aligned}$$

搜索步长 α 也叫作**学习率**
(Learning Rate)

学习率是十分重要的超参数！



学习率: <https://playground.tensorflow.org/#activation=tanh&batchSize=10&dataset=circle®Dataset=reg-plane&learningRate=0.03®ularizationRate=0&noise=0&networkShape=4,2&seed=0.20745&showTestData=false&discretize=false&percTrainData=50&x=true&y=true&xTimesY=false>

随机梯度下降法

- **随机**梯度下降法（Stochastic Gradient Descent, SGD）也叫**增量**梯度下降，每个样本都进行更新

$$\begin{aligned}\theta_{t+1} &= \theta_t - \alpha \frac{\partial \mathcal{R}(\theta)}{\partial \theta_t} \\ &= \theta_t - \alpha \frac{1}{N} \sum_{i=1}^N \frac{\partial \mathcal{L}(\theta_t; x^{(i)}, y^{(i)})}{\partial \theta}.\end{aligned}$$

梯度下降



$$\theta_{t+1} = \theta_t - \alpha \frac{\partial \mathcal{L}(\theta_t; x^{(t)}, y^{(t)})}{\partial \theta},$$

随机梯度下降

- 小批量（Mini-Batch）随机梯度下降法

$$\theta_{t+1} \leftarrow \theta_t - \alpha \frac{1}{K} \sum_{(x,y) \in \mathcal{S}_t} \frac{\partial \mathcal{L}(y, f(\mathbf{x}; \theta))}{\partial \theta}$$

batch size:

<https://playground.tensorflow.org/#activation=tanh&batchSize=10&dataset=circle®Dataset=reg-plane&learningRate=0.03®ularizationRate=0&noise=0&networkShape=4,2&seed=0.20745&showTestData=false&discretize=false&percTrainData=50&x=true&y=true&xTimesY=false>

随机梯度下降法

算法 2.1: 随机梯度下降法

输入: 训练集 $\mathcal{D} = \{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$, 验证集 $\mathcal{V}$, 学习率 α

1 随机初始化 θ ;

2 repeat

3 对训练集 $\mathcal{D}$ 中的样本 随机重排序;

4 for $n = 1 \cdots N$ do

5 从训练集 $\mathcal{D}$ 中选取样本 $(\mathbf{x}^{(n)}, y^{(n)})$;

 // 更新参数

6 $\theta \leftarrow \theta - \alpha \frac{\partial \mathcal{L}(\theta; x^{(n)}, y^{(n)})}{\partial \theta}$;

7 end

8 until 模型 $f(\mathbf{x}; \theta)$ 在 验证集 $\mathcal{V}$ 上的错误率不再下降;

输出: θ

Why?


后续会解释为什么选取
验证集作为停止迭代的
判断依据

机器学习 = 优化？

机器学习 = 优化？

NO!

机器学习并不是只是
单纯追求最小化经验
风险




过拟合（Overfitting）：经验风险最小化原则很容易导致模型在训练集上错误率很低，但是在未知数据上错误率很高。

过拟合问题往往是由于训练数据少和噪声等原因造成的。

期望风险

$$\mathcal{R}(f) = \mathbb{E}_{(\mathbf{x}, y) \sim p(\mathbf{x}, y)} [\mathcal{L}(f(\mathbf{x}), y)],$$


真实分布 p_r



$\neq$

经验风险

$$\mathcal{R}_D^{emp}(\theta) = \frac{1}{N} \sum_{n=1}^N \mathcal{L}(y^{(n)}, f(x^{(n)}, \theta))$$



$$\mathcal{G}_D(f) = \mathcal{R}(f) - \mathcal{R}_D^{emp}(f)$$

泛化错误

如何减少泛化错误？

优化

经验风险最小

正则化

降低模型复杂度



正则化 (regularization)



所有损害优化的方法都是正则化。

增加优化约束

L1/L2约束、数据增强


干扰优化过程

权重衰减、随机梯度下降、提前停止




提前停止 (Early Stopping)

- 我们使用一个验证集 (Validation Dataset) 来测试每一次迭代的参数在验证集上是否最优。如果在验证集上的错误率不再下降，就停止迭代。



多项式回归

一个例子：多项式曲线拟合







模型

$$y(x, \mathbf{w}) = w_0 + w_1x + w_2x^2 + \dots + w_Mx^M$$

损失函数

$$E(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2$$

如何确定多项式的阶数



这是一个模型选择问题


红色为多项式曲线

绿色为样本的真实分布曲线

$$y(x, \mathbf{w}) = w_0 + w_1x + w_2x^2 + \dots + w_Mx^M$$

$M = 9 \rightarrow E(\mathbf{w}) = 0$: 过拟合了!

控制过拟合：正则化



	$M = 0$	$M = 1$	$M = 3$	$M = 9$
w_0^*	0.19	0.82	0.31	0.35
w_1^*		-1.27	7.99	232.37
w_2^*			-25.43	-5321.83
w_3^*			17.37	48568.31
w_4^*				-231639.30
w_5^*				640042.26
w_6^*				-1061800.52
w_7^*				1042400.18
w_8^*				-557682.99
w_9^*				125201.43

系数的数量级随着多项式阶数升高而增加



$$\tilde{E}(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2$$

对大的系数进行惩罚

控制过拟合：正则化



$$\tilde{E}(\mathbf{w}) = \frac{1}{2} \sum_{n=1}^N \{y(x_n, \mathbf{w}) - t_n\}^2 + \frac{\lambda}{2} \|\mathbf{w}\|^2$$

注： $\lambda = e^t$



	ln $\lambda = -\infty$	ln $\lambda = -18$	ln $\lambda = 0$
w_0^*	0.35	0.35	0.13
w_1^*	232.37	4.74	-0.05
w_2^*	-5321.83	-0.77	-0.06
w_3^*	48568.31	-31.97	-0.05
w_4^*	-231639.30	-3.89	-0.03
w_5^*	640042.26	55.28	-0.02
w_6^*	-1061800.52	41.32	-0.01
w_7^*	1042400.18	-45.95	-0.00
w_8^*	-557682.99	-91.53	0.00
w_9^*	125201.43	72.68	0.01

控制过拟合：数据集大小



线性回归

线性回归 (Linear Regression)

- 模型:

$$f(\mathbf{x}; \mathbf{w}, b) = \mathbf{w}^T \mathbf{x} + b$$


- 增广权重向量和增广特征向量

$$\hat{\mathbf{x}} = \mathbf{x} \oplus 1 \triangleq \begin{bmatrix} \mathbf{x} \\ 1 \end{bmatrix} = \begin{bmatrix} x_1 \\ \vdots \\ x_k \\ 1 \end{bmatrix},$$

$$\hat{\mathbf{w}} = \mathbf{w} \oplus b \triangleq \begin{bmatrix} \mathbf{w} \\ b \end{bmatrix} = \begin{bmatrix} w_1 \\ \vdots \\ w_k \\ b \end{bmatrix},$$



$$f(\mathbf{x}; \hat{\mathbf{w}}) = \hat{\mathbf{w}}^T \hat{\mathbf{x}},$$



优化方法

注：以下四种方法均为直接优化法

- 经验风险最小化（最小二乘法）
- 结构风险最小化（岭回归）
- 最大似然估计
- 最大后验估计

经验风险最小化

- 标量关于向量的偏导数

$$\frac{\partial y}{\partial \mathbf{x}} = \left[\frac{\partial y}{\partial x_1}, \dots, \frac{\partial y}{\partial x_M} \right]^\top$$

- 向量关于向量的偏导数

$$\frac{\partial f(\mathbf{x})}{\partial \mathbf{x}} = \begin{bmatrix} \frac{\partial y_1}{\partial x_1} & \dots & \frac{\partial y_N}{\partial x_1} \\ \vdots & \vdots & \vdots \\ \frac{\partial y_1}{\partial x_M} & \dots & \frac{\partial y_N}{\partial x_M} \end{bmatrix}$$

- 向量函数及其导数

$$\begin{aligned} \frac{\partial \mathbf{x}}{\partial \mathbf{x}} &= \mathbf{I}, \\ \frac{\partial \mathbf{A}\mathbf{x}}{\partial \mathbf{x}} &= \mathbf{A}^\top, \\ \frac{\partial \mathbf{x}^\top \mathbf{A}}{\partial \mathbf{x}} &= \mathbf{A} \end{aligned}$$

- 模型

$$f(\mathbf{x}; \mathbf{w}) = \mathbf{w}^T \mathbf{x}$$

- 学习准则

$$\begin{aligned}\mathcal{R}(\mathbf{w}) &= \sum_{n=1}^N \mathcal{L}(y^{(n)}, f(\mathbf{x}^{(n)}; \mathbf{w})) \\ &= \frac{1}{2} \sum_{n=1}^N \left(y^{(n)} - \mathbf{w}^T \mathbf{x}^{(n)} \right)^2 \\ &= \frac{1}{2} \|\mathbf{y} - X^T \mathbf{w}\|^2,\end{aligned}$$

经验风险最小化

• 优化 $\frac{\partial}{\partial \mathbf{w}} \mathcal{R}(\mathbf{w}) = 0$

$$\begin{aligned}\frac{\partial \mathcal{R}(\mathbf{w})}{\partial \mathbf{w}} &= \frac{1}{2} \frac{\partial \|\mathbf{y} - X^T \mathbf{w}\|^2}{\partial \mathbf{w}} \\ &= -X(\mathbf{y} - X^T \mathbf{w}),\end{aligned}$$

令 $\frac{\partial}{\partial \mathbf{w}} \mathcal{R}(\mathbf{w}) = 0$, 得到最优的参数 $\mathbf{w}^*$ 为

$$\begin{aligned}\mathbf{w}^* &= (XX^T)^{-1}X\mathbf{y} \\ &= \left(\sum_{n=1}^N \mathbf{x}^{(n)}(\mathbf{x}^{(n)})^T \right)^{-1} \left(\sum_{n=1}^N \mathbf{x}^{(n)}y^{(n)} \right).\end{aligned}$$

最小二乘法 (Least Square Method, LSM)

结构风险最小化 (Structure Risk Minimization, SRM)

- 结构风险最小化准则

$$\mathcal{R}(\mathbf{w}) = \frac{1}{2} \|\mathbf{y} - \mathbf{X}^\top \mathbf{w}\|^2 + \underbrace{\frac{1}{2} \lambda \|\mathbf{w}\|^2}_{\text{正则化项}},$$

令 $\frac{\partial}{\partial \mathbf{w}} \mathcal{R}(\mathbf{w}) = 0$

得到 $\mathbf{w}^* = (\mathbf{X}\mathbf{X}^\top + \lambda \mathbf{I})^{-1} \mathbf{X}\mathbf{y}$

- 等价于岭回归 (Ridge Regression)

- 为解决最小二乘法的解 $\mathbf{w}^* = (\mathbf{X}\mathbf{X}^\top)^{-1} \mathbf{X}\mathbf{y}$, 在计 $(\mathbf{X}\mathbf{X}^\top)^{-1}$ 时可能出现的~~不稳定~~问题 $\mathbf{X}\mathbf{X}^\top$ 的对角线元素都加上一个常数 λ

最大似然估计

关于概率的一些基本概念

- 概率 (Probability)

- 一个随机事件发生的可能性大小，为0到1之间的实数。

- 随机变量 (Random Variable)

- 比如随机掷一个骰子，得到的点数就可以看成一个随机变量 X ，其取值为 $\{1, 2, 3, 4, 5, 6\}$ 。

- 概率分布 (Probability Distribution)

- 一个随机变量 X 取每种可能值的概率

- 并满足
$$P(X = x_i) = p(x_i), \quad \forall i \in \{1, \dots, n\}.$$

$$\sum_{i=1}^n p(x_i) = 1,$$

$$p(x_i) \geq 0, \quad \forall i \in \{1, \dots, n\}.$$


概率的一些基本概念

- 连续随机变量 Y 的概率分布一般用概率密度函数（Probability Density Function, PDF） $p(x)$ 来描述。

$$\int_{-\infty}^{+\infty} p(x) dx = 1$$

- 高斯分布（Gaussian Distribution）

$$X \sim \mathcal{N}(\mu, \sigma^2) \quad p(x) = \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(x-\mu)^2}{2\sigma^2}\right)$$



概率的一些基本概念

- 条件概率 (Conditional Probability)

- 对于离散随机向量 (X, Y) , 已知 $X = x$ 的条件下, 随机变量 $Y = y$ 的条件概率为:

$$p(y|x) = P(Y = y|X = x) = \frac{p(x, y)}{p(x)}$$

- 贝叶斯公式

- 两个条件概率 $p(y|x)$ 和 $p(x|y)$ 之间的关系

$$p(y|x) = \frac{p(x|y)p(y)}{p(x)}$$

后验概率
(posterior)
先验概率 (prior)

似然 (Likelihood)

贝叶斯公式:

$$p(Y|X) = \frac{p(X|Y)p(Y)}{p(X)}$$

描述已知随机变量X时，不同
参数w对其分布的影响

$$p(w|X) \propto p(X|w)p(w)$$

后验 似然 先验
posterior likelihood prior


$$\text{posterior} \propto \text{likelihood} \times \text{prior}$$

从概率角度来看线性回归

- 假设标签 y 为一个随机变量，其服从均值为 $f(x; w) = w^T x$ ，方差为 σ^2 的高斯分布。

$$\begin{aligned} p(y|\mathbf{x}; \mathbf{w}, \sigma) &= \mathcal{N}(y; \mathbf{w}^T \mathbf{x}, \sigma^2) \\ &= \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y - \mathbf{w}^T \mathbf{x})^2}{2\sigma^2}\right). \end{aligned}$$


注：也可以认为
 $y = f(\mathbf{x}; \mathbf{w}) + \epsilon$
其中 ϵ 是满足均值为0，方差为 σ^2 的高斯噪声



线性回归中的似然函数

- 参数 $\mathbf{w}$ 在训练集 D 上的似然函数 (Likelihood) 为

$$\begin{aligned} p(\mathbf{y}|\mathbf{X}; \mathbf{w}, \sigma) &= \prod_{n=1}^N p(y^{(n)}|\mathbf{x}^{(n)}; \mathbf{w}, \sigma) \\ &= \prod_{n=1}^N \mathcal{N}(y^{(n)}; \mathbf{w}^T \mathbf{x}^{(n)}, \sigma^2) \end{aligned}$$


$$\begin{aligned} p(y|\mathbf{x}; \mathbf{w}, \sigma) &= \mathcal{N}(y; \mathbf{w}^T \mathbf{x}, \sigma^2) \\ &= \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{(y - \mathbf{w}^T \mathbf{x})^2}{2\sigma^2}\right). \end{aligned}$$

- 最大似然估计 (Maximum Likelihood Estimate, MLE)
 - 是指找到一组参数 $\mathbf{w}$ 使得似然函数 $p(\mathbf{y}|\mathbf{X};\mathbf{w},\sigma)$ 最大

$$\begin{aligned} p(\mathbf{y}|\mathbf{X}; \mathbf{w}, \sigma) &= \prod_{n=1}^N p(y^{(n)}|\mathbf{x}^{(n)}; \mathbf{w}, \sigma) \\ &= \prod_{n=1}^N \mathcal{N}(y^{(n)}; \mathbf{w}^T \mathbf{x}^{(n)}, \sigma^2) \end{aligned}$$



$$\text{令 } \frac{\partial \log p(\mathbf{y}|\mathbf{X}; \mathbf{w}, \sigma)}{\partial \mathbf{w}} = 0$$



$$\mathbf{w}^{ML} = (\mathbf{X}\mathbf{X}^T)^{-1}\mathbf{X}\mathbf{y}.$$

最大似然估计的解 $\mathbf{w}^{ML}$ 和最小二乘法的解相同

最大后验估计

最大后验估计 (Maximum a Posteriori Estimate)

贝叶斯公式

$$p(\mathbf{w}|\mathbf{X}, \mathbf{y}; \nu, \sigma) = \frac{p(\mathbf{w}, \mathbf{y}|\mathbf{X}; \nu, \sigma)}{\sum_{\mathbf{w}} p(\mathbf{w}, \mathbf{y}|\mathbf{X}; \nu, \sigma)} \\ \propto \underbrace{p(\mathbf{y}|\mathbf{X}, \mathbf{w}; \sigma)}_{\text{似然}} p(\mathbf{w}; \nu),$$

后验
posterior

似然
likelihood

先验
prior

假设先验满足高斯分布

$$p(\mathbf{w}; \nu) = \mathcal{N}(\mathbf{w}; \mathbf{0}, \nu^2 I)$$

$$\log p(\mathbf{w}|\mathbf{X}, \mathbf{y}; \nu, \sigma) \propto \log p(\mathbf{y}|\mathbf{X}, \mathbf{w}; \sigma) + \log p(\mathbf{w}; \nu)$$

$$\propto -\frac{1}{2\sigma^2} \sum_{n=1}^N \left(y^{(n)} - \mathbf{w}^\top \mathbf{x}^{(n)} \right)^2 - \frac{1}{2\nu^2} \mathbf{w}^\top \mathbf{w},$$

$$= \underbrace{-\frac{1}{2\sigma^2} \|\mathbf{y} - \mathbf{X}^\top \mathbf{w}\|^2}_{\text{平方损失}} - \underbrace{\frac{1}{2\nu^2} \mathbf{w}^\top \mathbf{w}}_{\text{正则化}}$$

最大后验估计等价于平方损失的结构
风险最小化

其中正则化系数 $\lambda = \sigma^2/\nu^2$

注：以下四种方法均为直接优化法

	无先验	引入先验
平方误差	经验风险 最小化	结构风险 最小化
概率	最大似然估计	最大后验估计

$$\mathbf{w}^{ML} = (\mathbf{X}\mathbf{X}^\top)^{-1}\mathbf{X}\mathbf{y}$$

$$\mathbf{w}^* = (\mathbf{X}\mathbf{X}^\top + \lambda\mathbf{I})^{-1}\mathbf{X}\mathbf{y}$$

机器学习的几个关键点

常见的机器学习类型

	监督学习	无监督学习	强化学习
训练样本	训练集 $\{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$	训练集 $\{\mathbf{x}^n\}_{n=1}^N$	智能体和环境交互的 轨迹 τ 和累积奖励 G_τ
优化目标	$y = f(\mathbf{x})$ 或 $p(y \mathbf{x})$	$p(\mathbf{x})$ 或带隐变量 $\mathbf{z}$ 的 $p(\mathbf{x} \mathbf{z})$	期望总回报 $\mathbb{E}_\tau[G_\tau]$
学习准则	期望风险最小化 最大似然估计	最大似然估计 最小重构错误	策略评估 策略改进

如何选择一个合适的模型？

• 模型选择

- 拟合能力强的模型一般复杂度会比较高，容易过拟合。
- 如果限制模型复杂度（正则化），降低拟合能力，可能会欠拟合。

• 偏差与方差分解

- 期望错误可以分解为

注：可以使用交叉验证（Cross-Validation）的方法构造多个训练集。详细介绍可参加邱锡鹏Bilibili视频

- <https://www.bilibili.com/video/BV12F411s75z?p=18>

$$\mathcal{R}(f) = (\text{bias})^2 + \text{variance} + \varepsilon.$$

$$\mathbb{E}_{\mathbf{x}} \left[\left(\mathbb{E}_{\mathcal{D}} [f_{\mathcal{D}}(\mathbf{x})] - f^*(\mathbf{x}) \right)^2 \right]$$

偏差：模型在不同训练集上的平均性能和最优解之间的差异，可衡量模型的拟合能力



$$\mathbb{E}_{(\mathbf{x}, y) \sim p_r(\mathbf{x}, y)} \left[(y - f^*(\mathbf{x}))^2 \right]$$

由样本分布以及噪声引起的误差，无法通过优化模型来减少

$$\mathbb{E}_{\mathbf{x}} \left[\mathbb{E}_{\mathcal{D}} \left[(f_{\mathcal{D}}(\mathbf{x}) - \mathbb{E}_{\mathcal{D}} [f_{\mathcal{D}}(\mathbf{x})])^2 \right] \right]$$

方差：模型在不同训练集上的差异，可衡量模型是否过拟合

模型选择：偏差与方差



如果限制模型复杂度（正则化），降低拟合能力，可能会欠拟合→高偏差：模型能力弱
降低偏差（欠拟合）的方法：

- 减小正则化系数、提高模型复杂度、增加数据特征

拟合能力强的模型一般复杂度会比较高，容易过拟合→高方差：模型在不同数据集上的表现差异大，性能不稳定
降低方差（过拟合）的方法：

- 加大正则化系数、降低模型复杂度、引入先验
- 集成模型

归纳偏置 (Inductive Bias)

- 很多学习算法经常会对学习的问题做一些假设，这些假设就称为**归纳偏置**（或归纳偏好）。
 - 在最近邻分类器中，我们会**假设**在特征空间中，一个小的局部区域中的大部分样本都同属一类。
 - 在朴素贝叶斯分类器中，我们会**假设**每个特征的条件概率是互相独立的。
- 归纳偏置在贝叶斯学习中也经常称为**先验**（**Prior**）。

常用的定理

- 没有免费午餐定理（No Free Lunch Theorem, NFL）
 - 对于基于迭代的最优化算法，不存在某种算法对所有问题（有限的搜索空间内）都有效。如果一个算法对某些问题有效，那么它一定在另外一些问题上比纯随机搜索算法更差。



不能脱离具体的问题来谈论算法的优劣，任何算法都有局限性

- 奥卡姆剃刀原理 (Occam's Razor)

- 如无必要，勿增实体 (Entities should not be multiplied unnecessarily)
- 应选择尽量简单的模型，简单模型的泛化能力更好
- 例如通过引入正则化来限制模型的能力，避免过拟合



- 丑小鸭定理 (Ugly Duckling Theorem)

- 丑小鸭与白天鹅之间的区别和两只白天鹅之间的区别一样大.

世界上不存在相似性的客观标准,
一切相似性的标准都是主观的




评价指标

评价指标（Evaluation Metric）

- 为衡量模型性能的好坏，需要定义定量的评价指标
- 准确率（Accuracy）：最常用的分类任务指标

$$\mathcal{A} = \frac{1}{N} \sum_{n=1}^N I(y^{(n)} = \hat{y}^{(n)})$$

- 精确率（Precision）和召回率（Recall）：常用于分类或检索任务



How many retrieved items are relevant?

$$\text{Precision} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Positives}}$$

How many relevant items are retrieved?

$$\text{Recall} = \frac{\text{True Positives}}{\text{True Positives} + \text{False Negatives}}$$

$$\mathcal{P}_c = \frac{TP_c}{TP_c + FP_c} \text{ 又称为查准率}$$

$$\mathcal{R}_c = \frac{TP_c}{TP_c + FN_c} \text{ 又称为查全率}$$

F1-值 (F1-Score) 或 F值 (F Measure)

- 一个结合了精确率和召回率的综合指标

Precision和Recall的调和平均

$$F1 = \frac{2 \times P \times R}{P + R}$$



$$\frac{1}{F1} = \frac{1}{2} \cdot \left(\frac{1}{P} + \frac{1}{R} \right)$$

$$F_{\beta} = \frac{(1 + \beta^2) \times P \times R}{(\beta^2 \times P) + R}$$



$$\frac{1}{F_{\beta}} = \frac{1}{1 + \beta^2} \cdot \left(\frac{1}{P} + \frac{\beta^2}{R} \right)$$

Precision和Recall的加权调和平均， β 衡量了P和R之间的相对重要性

课后作业

截止时间：下周日晚上12点

提交方式：每人作业的word文档以“学号+姓名”命名，各班班长收齐压缩后，发到邮箱
514034538@qq.com

作业晚交政策：作业超过截止时间但在24小时以内，该次作业按60%分数计算，超过24小时则不记分

作业1：请分析为什么平方损失函数不适用于分类问题。

作业2：试分析什么因素会导致模型出现图2.6(d)所示的高偏差和高方差情况。

作业3：对于一个三分类问题，数据集的真实标签和模型的预测标签如下：

真实标签	1	2	2	2	2	3	3	3	3
预测标签	1	2	2	2	3	3	3	1	2

分别计算模型对于每个类别的精确率、召回率、F1值




图 2.6 机器学习模型的四种偏差和方差组合情况