

《神经网络与深度学习》

第三章-线性模型

人工智能学院

杨溪

- 分类问题示例
- 线性分类模型
 - Logistic 回归
 - Softmax 回归
 - 感知机
 - SVM



分类示例

示例：图像分类

- 数据集：CIFAR-10
 - 60000张32x32色彩图像，共10类
 - 每类6000张图像

airplane



automobile



bird



cat



deer



dog




frog



horse



ship




truck



示例：图像分类

- 数据集：ImageNet
 - 14,197,122 images, 21841 synsets



图像分类问题





[32x32x3]

array of numbers 0...1
(3072 numbers total)

image parameters
 $f(\mathbf{x}, \mathbf{W})$

10 numbers, indicating
class scores



图像分类、目标检测、实例分割

Classification




CAT

**Classification
+ Localization**



CAT

Object Detection



CAT, DOG, DUCK

**Instance
Segmentation**




CAT, DOG, DUCK

Single object

Multiple objects

示例：垃圾邮件过滤

- 通过识别邮件中的敏感词汇、发送者信誉及行为模式，将邮件自动归类为“垃圾”或“正常”。




示例：文档归类

- 根据文档的内容特征、结构或元数据，将其自动或人工分配到预定义类别体系中，以实现信息的有序组织与快速检索。



示例：情感分类



Review (X)

"This movie is fantastic! I really like it because it is so good!"

"Not to my taste, will skip and watch another movie"

"This movie really sucks! Can I get my money back please?"

Rating (Y)



- 将样本 x 从文本形式转为向量形式
 - 词袋模型 (Bag-of-Words, BoW)

the dog is on the table

0	0	1	1	0	1	1	1
are	cat	dog	is	now	on	table	the

比如两个文本“我 喜欢 读书”和“我 讨厌 读书”中共有“我”、“喜欢”、“讨厌”、“读书”四个词，它们的BoW表示分别为

$$\mathbf{v}_1 = [1 \ 1 \ 0 \ 1]^T,$$

$$\mathbf{v}_2 = [1 \ 0 \ 1 \ 1]^T.$$

根据文本内容来判断文本的相应类别

D_1 : “我喜欢读书”


D_2 : “我讨厌读书”

	我	喜欢	讨厌	读书
D_1	1	1	0	1
D_2	1	0	1	1

文本顺序?

+

-




线性分类模型

- 分类问题


- Logistic回归 (二分类)
- Softmax回归 (多分类)

- 分类模型

- 感知器
- 支持向量机




支持向量机 (SVM)



感知机 (Perceptron)

Logistic 回归

- 也称为对数几率回归，简称对率回归
- 二分类线性模型的一般图示



符号函数 $g(f(\mathbf{x}; \mathbf{w})) = \text{sgn}(f(\mathbf{x}; \mathbf{w}))$

$$\triangleq \begin{cases} +1 & \text{if } f(\mathbf{x}; \mathbf{w}) > 0, \\ -1 & \text{if } f(\mathbf{x}; \mathbf{w}) < 0. \end{cases}$$

Logistic函数

$$g(f(\mathbf{x}; \mathbf{w})) = \frac{1}{1 + \exp(-\mathbf{w}^T \mathbf{x})}$$

0-1 损失函数

思考：0-1 损失函数有什么缺点？

$$\mathcal{L}_{01}(y, g(f(\mathbf{x}; \mathbf{w}))) = I(y \neq g(f(\mathbf{x}; \mathbf{w})))$$

交叉熵损失

$$\mathcal{R}(\mathbf{w}) = -\frac{1}{N} \sum_{i=1}^N \left(y^{(i)} \log \left(\sigma(\mathbf{w}^T \mathbf{x}^{(i)}) \right) + (1 - y^{(i)}) \log \left(1 - \sigma(\mathbf{w}^T \mathbf{x}^{(i)}) \right) \right).$$

- 将分类问题看作条件概率估计问题

- 引入非线性函数 g 来预测类别标签的条件概率 $p(y = c|x)$ 。

- 以二分类为例，

$$p(y = 1|\mathbf{x}) = g(f(\mathbf{x}; \mathbf{w}))$$

- 函数 f : 线性函数


- 函数 g : 把线性函数的值域从实数区间“挤压”到了 $(0,1)$ 之间，可以用来表示概率。

如何构建函数 g ?

- Logistic函数 (Sigmoid 函数)

思考：除了logistic，还有什么函数 $f: \mathbb{R} \rightarrow (0,1)$?

$$\sigma(x) = \frac{1}{1 + \exp(-x)}$$



- Logistic回归

$$p(y = 1|\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x})$$

$$\triangleq \frac{1}{1 + \exp(-\mathbf{w}^\top \mathbf{x})}$$

可学习参数

- 模型预测条件概率 $p_{\theta}(y|\mathbf{x})$

$$p_{\theta}(y = 1|\mathbf{x}) = \sigma(\mathbf{w}^T \mathbf{x})$$

- 真实条件概率 $p_r(y|\mathbf{x})$

- 对于一个样本 $(\mathbf{x}, y^*)$, 其 真实条件概率为

$$\begin{aligned} p_r(y = 1|\mathbf{x}) &= y^* \\ p_r(y = 0|\mathbf{x}) &= 1 - y^* \end{aligned}$$

学习准则：如何衡量两个条件分布的差异？

- 在信息论中，熵用来衡量一个随机事件的**不确定性**。

- 自信息 (Self Information)


$$I(x) = -\log(p(x))$$

- 熵：自信息的数学期望

$$H(X) = \mathbb{E}_X[I(x)]$$

$$= \mathbb{E}_X[-\log p(x)]$$

$$= -\sum_{x \in \mathcal{X}} p(x) \log p(x)$$



- 熵越**高**，则随机变量的信息越**多**；

- 熵越**低**，则随机变量的信息越**少**。


- 熵编码（最优编码）：按照符号出现的概率对符号的分布进行编码，符号出现概率越高，编码长度越短

- 若符号出现的概率为 $p(x)$ ，其最优编码长度为 $-\log_2 p(x)$

- 交叉熵是按照概率分布 q 的最优编码对真实分布为 p 的信息进行编码的长度。

$$\begin{aligned} H(p, q) &= \mathbb{E}_p[-\log q(x)] \\ &= -\sum_x p(x) \log q(x) \end{aligned}$$

↓
 q 的最优编码



- 在给定 q 的情况下，如果 p 和 q 越接近，交叉熵越小；
- 如果 p 和 q 越远，交叉熵就越大。

二分类: $H(p_r, p_\theta) = -(y^* \log \hat{y} + (1 - y^*) \log(1 - \hat{y}))$

交叉熵 $H(p, q) = \mathbb{E}_p[-\log q(x)]$
 $= -\sum_x p(x) \log q(x)$

- 交叉熵损失函数，模型在训练集的风险函数为

$$\mathcal{R}(\mathbf{w}) = -\frac{1}{N} \sum_{i=1}^N \left(y^{(i)} \log \left(\sigma(\mathbf{w}^T \mathbf{x}^{(i)}) \right) + (1 - y^{(i)}) \log \left(1 - \sigma(\mathbf{w}^T \mathbf{x}^{(i)}) \right) \right).$$

- 梯度为
$$\frac{\partial \mathcal{R}(\mathbf{w})}{\partial \mathbf{w}} = \frac{1}{N} \sum_{i=1}^N \left(\mathbf{x}^{(i)} \cdot \left(\sigma(\mathbf{w}^T \mathbf{x}^{(i)}) - y^{(i)} \right) \right)$$

- 梯度下降法
$$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t + \alpha \frac{1}{N} \sum_{n=1}^N \mathbf{x}^{(n)} \left(y^{(n)} - \hat{y}_{\mathbf{w}_t}^{(n)} \right)$$

请自行推导 (使用链式法则)


$$\frac{\partial \mathcal{R}(\mathbf{w})}{\partial \mathbf{w}} = \frac{1}{N} \sum_{i=1}^N \left(\mathbf{x}^{(i)} \cdot \left(\sigma(\mathbf{w}^T \mathbf{x}^{(i)}) - y^{(i)} \right) \right)$$

$$\begin{aligned} \frac{\partial \mathcal{R}(\mathbf{w})}{\partial \mathbf{w}} &= -\frac{1}{N} \sum_{n=1}^N \left(y^{(n)} \frac{\hat{y}^{(n)}(1 - \hat{y}^{(n)})}{\hat{y}^{(n)}} \mathbf{x}^{(n)} - (1 - y^{(n)}) \frac{\hat{y}^{(n)}(1 - \hat{y}^{(n)})}{1 - \hat{y}^{(n)}} \mathbf{x}^{(n)} \right) \\ &= -\frac{1}{N} \sum_{n=1}^N \left(y^{(n)} (1 - \hat{y}^{(n)}) \mathbf{x}^{(n)} - (1 - y^{(n)}) \hat{y}^{(n)} \mathbf{x}^{(n)} \right) \\ &= -\frac{1}{N} \sum_{n=1}^N \mathbf{x}^{(n)} (y^{(n)} - \hat{y}^{(n)}). \end{aligned}$$

Logistic 回归

$$p(y = 1|\mathbf{x}) = \sigma(\mathbf{w}^\top \mathbf{x})$$

$$\triangleq \frac{1}{1 + \exp(-\mathbf{w}^\top \mathbf{x})}$$





思考：怎么根据Logistic回归的结果进行分类？


多分类 (Multi-class Classification)

可以理解为不同的分类器在投票


二分类



(a) “一对其余” 方式
C个分类器



(b) “一对一” 方式
 $C(C-1)/2$ 个分类器



(c) “argmax” 方式
C个分类器

“argmax” 方式: 这是一种改进的“一对其余”方式, 共需要 C 个判别函数

$$f_c(\mathbf{x}; \mathbf{w}_c) = \mathbf{w}_c^T \mathbf{x} + b_c, \quad c = [1, \dots, C] \quad (3.10)$$

如果存在类别 c , 对于所有的其他类别 $\tilde{c} (\tilde{c} \neq c)$ 都满足 $f_c(\mathbf{x}; \mathbf{w}_c) > f_{\tilde{c}}(\mathbf{x}; \mathbf{w}_{\tilde{c}})$, 那么 $\mathbf{x}$ 属于类别 c 。即

可理解为 $\mathbf{x}$ 距离哪个分类边界最近, 则 $\mathbf{x}$ 为相应类别

$$y = \arg \max_{c=1}^C f_c(\mathbf{x}; \mathbf{w}_c). \quad (3.11)$$

- 多分类问题

$$y = \arg \max_{c=1}^C f_c(\mathbf{x}; \mathbf{w}_c)$$

- Softmax函数

- 将多个标量映射为一个概率分布

$$\text{softmax}(x_k) = \frac{\exp(x_k)}{\sum_{i=1}^K \exp(x_i)}$$



- 利用Softmax函数，目标类别 $y = c$ 的条件概率为：


$$p(y = c|\mathbf{x}) = \text{softmax}(\mathbf{w}_c^\top \mathbf{x}) \\ = \frac{\exp(\mathbf{w}_c^\top \mathbf{x})}{\sum_{c'=1}^C \exp(\mathbf{w}_{c'}^\top \mathbf{x})}$$

- Softmax layer as the output layer

Probability:

$$\blacksquare 1 > y_i > 0$$

$$\blacksquare \sum_i y_i = 1$$



- 模型：Softmax回归

- 学习准则：交叉熵

$$\mathcal{R}(W) = -\frac{1}{N} \sum_{n=1}^N (\mathbf{y}^{(n)})^T \log \hat{\mathbf{y}}^{(n)}$$

- 优化：梯度下降

$$\frac{\partial \mathcal{R}(W)}{\partial W} = -\frac{1}{N} \sum_{n=1}^N \mathbf{x}^{(n)} \left(\mathbf{y}^{(n)} - \hat{\mathbf{y}}^{(n)} \right)^T$$

多分类问题的交叉熵损失函数

- 负对数似然损失函数

$$\mathcal{L}(\mathbf{y}, f(\mathbf{x}, \theta)) = - \sum_{c=1}^C y_c \log f_c(\mathbf{x}, \theta)$$

- 对于一个三类分类问题，类别为[0,0,1]，预测类别概率为[0.3,0.3,0.4]，则

$$\begin{aligned}\mathcal{L}(\theta) &= -(0 \times \log(0.3) + 0 \times \log(0.3) + 1 \times \log(0.4)) \\ &= -\log(0.4).\end{aligned}$$

注：这只是一个样本的损失，如果有N个样本，需要对N个样本的损失求和


$$L = \frac{1}{N} \sum_i L_i = -\frac{1}{N} \sum_i \sum_{c=1}^M y_{ic} \log(p_{ic})$$

多分类问题的交叉熵损失

$$-\sum_{y=1}^C p_r(y|x) \log p_{\theta}(y|x)$$

真实概率 $p_r(y|x)$

预测概率的负对数 $-\log p_{\theta}(y|x)$



真实概率和负对数的差异越大
(真实概率和预测概率的差异越小)



交叉熵越小
(两个概率分布的相似性
越大, 预测越准确)

感知器

感知器 (Perceptron)

- 感知机的诞生

Psychological Review
Vol. 65, No. 6, 1958

THE PERCEPTRON: A PROBABILISTIC MODEL FOR INFORMATION STORAGE AND ORGANIZATION IN THE BRAIN¹

F. ROSENBLATT
Cornell Aeronautical Laboratory



HAVING told you about the giant digital computer known as I.B.M. 704 and how it has been taught to play a fairly creditable game of chess, we'd like to tell you about an even more remarkable machine, the perceptron, which, as its name implies, is capable of what amounts to original thought. The first perceptron has yet to be built,

The New Yorker, December 6, 1958 P. 44



The IBM 704 computer

- 模拟生物神经元行为的机器，有与生物神经元相对应的部件，如**权重**（突触）、**偏置**（阈值）及**激活函数**（细胞体），**输出**为+1或-1。



• 学习算法

- 一种错误驱动的在线学习算法：
- 先初始化一个权重向量 $\mathbf{w} \leftarrow \mathbf{0}$ （通常是全零向量）；
- 每次分错一个样本 $(\mathbf{x}, y)$ 时，即

$$y\mathbf{w}^T \mathbf{x} \leq 0$$

- 用这个样本来更新权重

$$\mathbf{w} \leftarrow \mathbf{w} + y\mathbf{x}$$

- 根据感知器的学习策略，可以反推出感知器的损失函数为

$$\mathcal{L}(\mathbf{w}; \mathbf{x}, y) = \max(0, -y\mathbf{w}^T \mathbf{x})$$

• 学习目标

- 训练集 $\{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$
- 找到权重 $\mathbf{w}^*$ ，使得

$$y^{(n)} \mathbf{w}^{*T} \mathbf{x}^{(n)} > 0$$

算法 3.1 两类感知器的参数学习算法

输入: 训练集 $\mathcal{D} = \{(\mathbf{x}^{(n)}, y^{(n)})\}_{n=1}^N$, 最大迭代次数 T

```
1 初始化:  $\mathbf{w}_0 \leftarrow 0, k \leftarrow 0, t \leftarrow 0$ ;  
2 repeat  
3   对训练集  $\mathcal{D}$  中的样本随机排序;  
4   for  $n = 1 \dots N$  do  
5     选取一个样本  $(\mathbf{x}^{(n)}, y^{(n)})$ ;  
6     if  $\mathbf{w}_k^T (y^{(n)} \mathbf{x}^{(n)}) \leq 0$  then  
7        $\mathbf{w}_{k+1} \leftarrow \mathbf{w}_k + y^{(n)} \mathbf{x}^{(n)}$ ;  
8        $k \leftarrow k + 1$ ;  
9     end  
10     $t \leftarrow t + 1$ ;  
11    if  $t = T$  then break;  
12  end  
13 until  $t = T$ ;  
    输出:  $\mathbf{w}_k$ 
```

如果分类错误,
则更新权重 $\mathbf{w}$



对比Logistic回归的更新方式:

// 达到最大迭代次数



$$\mathbf{w}_{t+1} \leftarrow \mathbf{w}_t + \alpha \frac{1}{N} \sum_{n=1}^N \mathbf{x}^{(n)} \left(y^{(n)} - \hat{y}_{\mathbf{w}_t}^{(n)} \right)$$

感知器参数学习的更新过程


假设红色实心为正样本，
蓝色空心为负样本



$$w_{k+1} \leftarrow w_k + y^{(n)} x^{(n)}$$



支持向量机 (Support Vector Machine, SVM)



数据集 $\mathcal{D}$ 中每个样本 $\mathbf{x}^{(n)}$ 到分割超平面的距离为:

$$\gamma^{(n)} = \frac{\|\mathbf{w}^T \mathbf{x}^{(n)} + b\|}{\|\mathbf{w}\|} = \frac{y^{(n)}(\mathbf{w}^T \mathbf{x}^{(n)} + b)}{\|\mathbf{w}\|}.$$

支持向量机的目标是寻找一个超平面 $(\mathbf{w}^*, b^*)$ 使得 γ 最大, 即
间隔 (margin)

$$\begin{aligned} \max_{\mathbf{w}, b} \quad & \gamma \\ \text{s.t.} \quad & \frac{y^{(n)}(\mathbf{w}^T \mathbf{x}^{(n)} + b)}{\|\mathbf{w}\|} \geq \gamma, \forall n \in \{1, \dots, N\} \end{aligned}$$

↓ 令 $\|\mathbf{w}\| \cdot \gamma = 1$

$$\begin{aligned} \max_{\mathbf{w}, b} \quad & \frac{1}{\|\mathbf{w}\|^2} \\ \text{s.t.} \quad & y^{(n)}(\mathbf{w}^T \mathbf{x}^{(n)} + b) \geq 1, \forall n \in \{1, \dots, N\} \end{aligned}$$

总结


线性分类模型小结

线性模型	激活函数	损失函数	优化方法
线性回归	-	$(y - \mathbf{w}^\top \mathbf{x})^2$	最小二乘、梯度下降
Logistic 回归	$\sigma(\mathbf{w}^\top \mathbf{x})$	$\mathbf{y} \log \sigma(\mathbf{w}^\top \mathbf{x})$	梯度下降
Softmax 回归	$\text{softmax}(\mathbf{W}^\top \mathbf{x})$	$\mathbf{y} \log \text{softmax}(\mathbf{W}^\top \mathbf{x})$	梯度下降
感知器	$\text{sgn}(\mathbf{w}^\top \mathbf{x})$	$\max(0, -y\mathbf{w}^\top \mathbf{x})$	随机梯度下降
支持向量机	$\text{sgn}(\mathbf{w}^\top \mathbf{x})$	$\max(0, 1 - y\mathbf{w}^\top \mathbf{x})$	二次规划、SMO 等

分类问题的不同损失函数的对比

预测标签和真实标签的一致性

为了比较这些损失函数，我们统一定义类别标签 $y \in \{+1, -1\}$ ，并定义 $f(\mathbf{x}; \mathbf{w}) = \mathbf{w}^T \mathbf{x} + b$ 。这样对于样本 $(\mathbf{x}, y)$ ，若 $yf(\mathbf{x}; \mathbf{w}) > 0$ ，则分类正确，相反则分类错误。这样为了方便比较这些模型，我们可以将它们的损失函数都表述为定义在 $yf(\mathbf{x}; \mathbf{w})$ 上的函数。



交叉熵 $\mathcal{L}_{LR} = \log(1 + \exp(-yf(\mathbf{x}; \mathbf{w})))$

较链损失 $\mathcal{L}_{hinge} = \max(0, 1 - yf(\mathbf{x}; \mathbf{w}))$


感知器损失 $\mathcal{L}_p = \max(0, -yf(\mathbf{x}; \mathbf{w}))$

平方损失 $\mathcal{L}_{squared} = (1 - yf(\mathbf{x}; \mathbf{w}))^2$

一个好的损失应该随着 $yf(\mathbf{x}; \mathbf{w})$ 的增大而减小，
因此平方损失不适用于分类问题

非线性问题：XOR问题

非线性可分!





非线性问题：特征变换

<http://playground.tensorflow.org>

如何处理非线性可分问题？

引入非线性函数，对特征进行非线性变换。



◆ 知识点

- ◆ Logistic 回归
- ◆ Softmax 回归
- ◆ 感知机
- ◆ SVM

◆ 作业

课后题：3-1、3-2

◆ 作业提交：

- ◆ 各位同学将理论课作业（pdf格式）和实验课作业（ipynb格式）合并为一个压缩包，文件命名“学号_姓名”
- ◆ 各班班长收齐并制成班级作业的压缩包，发到邮箱：nuoxu25@mails.jlu.edu.cn（许诺）

◆ 截至时间：

- ◆ 下周日晚9点
- ◆ 若在下周日9点后，下周一晚10点前提交，则视为晚交，此次作业按60%分数计算
- ◆ 若在下周一晚9点后提交，则不计分。