

《神经网络与深度学习》

第五章-卷积神经网络

人工智能学院


杨溪

◆ 权重矩阵的参数非常多

◆ 每个连接都对应一个权重参数。随着隐藏层神经元数量的增多，参数的规模也会急剧增加，这会导致整个神经网络的训练效率非常低，也容易出现过拟合。

◆ 很难提取局部不变性特征：

◆ 自然图像中的物体都具有局部不变性特征，即尺度缩放、平移、旋转等操作不影响其语义信息。



◆ 卷积神经网络 (Convolutional Neural Networks, CNN)

- ◆ 一种前馈神经网络

- ◆ 一般是由卷积层、汇聚层和全连接层交叉堆叠而成的

- ◆ 受生物学上感受野 (Receptive Field) 的机制而提出的

在视觉神经系统中，一个神经元的**感受野**是指视网膜上的特定区域，只有这个区域内的刺激才能够激活该神经元

- ◆ 主要应用在图像和视频分析的各种任务中


◆ **三个结构上的特性**使得卷积神经网络具有一定程度上的平移、缩放和旋转不变性

- ◆ 局部连接


- ◆ 权重共享

- ◆ 汇聚 (空间或时间上的次采样)

◆ 卷积神经网络与全连接层的对比示意图：



(a) 全连接层



(b) 卷积层

➤ 卷积

➤ 卷积神经网络

➤ 其他卷积方式

➤ 典型的卷积网络

➤ 卷积网络的应用


卷积操作

◆ 一维卷积经常用在信号处理中，用于计算信号的延迟累积

◆ 例：

◆ 一个信号发生器每个时刻 t 产生一个信号 x_t ，其信息的衰减率为 w_k ，即在 $k-1$ 个时间步长后，信息为原来的 w_k 倍。假设 $w_1 = 1, w_2 = 1/2, w_3 = 1/4$ ，那么在时刻 t 收到的信号 y_t 为当前时刻产生的信息和以前时刻延迟信息的叠加，即：

窗口为3



$$\begin{aligned} y_t &= 1 \times x_t + 1/2 \times x_{t-1} + 1/4 \times x_{t-2} \\ &= w_1 \times x_t + w_2 \times x_{t-1} + w_3 \times x_{t-2} \\ &= \sum_{k=1}^3 w_k \cdot x_{t-k+1} \end{aligned}$$

滤波器(filter)或卷积核 (convolution kernel)

◆ 给定一个输入信号序列 x 和滤波器 w ，卷积的输出为：


$$[x_1, x_2, x_3, \dots] \quad [w_1, w_2, \dots, w_k]$$

$$y_t = \sum_{k=1}^K w_k x_{t-k+1}$$

$$y = w * x$$

卷积运算

Filter: $[-1, 0, 1]$



N -- Input

K -- Kernel

$N-K+1$ -- Output

◆ 近似微分

◆ 当令滤波器 $w=[1/2, 0, -1/2]$ 时，可以近似信号序列的一阶微分

$$x'(t) = \frac{x(t+1) - x(t-1)}{2}$$

$$\lim_{\varepsilon \rightarrow 0} \frac{f(x+\varepsilon) - f(x-\varepsilon)}{2\varepsilon}$$

◆ 当令滤波器 $w=[1, -2, 1]$ 时，可以近似信号序列的二阶微分


$$x''(t) = x(t+1) + x(t-1) - 2x(t)$$

$$\frac{x'(t+1) - x'(t-1)}{2}$$


$$x'(t+1) - x'(t) \quad \text{等价}$$

$$x'(t) - x'(t-1)$$

- ◆ 不同的滤波器可以提取信号序列中的不同特征：
 - ◆ 滤波器 $w=[1/3, 1/3, 1/3]$ 可以检测信号序列中的低频信息（低通滤波）
 - ◆ 滤波器 $w=[1, -2, 1]$ 可以检测信号序列中的高频信息（高通滤波）



(a) 滤波器 $[1/3, 1/3, 1/3]$




(b) 滤波器 $[1, -2, 1]$

◆ 引入滤波器的滑动步长 S 和零填充 P

Stride


Padding

$5 \rightarrow 3$



(a) 步长 $S = 2$

$5 \rightarrow 7$



(b) 零填充 $P = 1$

◆ 卷积的结果按输出长度不同可以分为三类：

- ◆ **窄卷积**：步长 $T = 1$ ，两端不补零 $P = 0$ ，卷积后输出长度为 $M - K + 1$
- ◆ **宽卷积**：步长 $T = 1$ ，两端补零 $P = K - 1$ ，卷积后输出长度 $M + K - 1$
- ◆ **等宽卷积**：步长 $T = 1$ ，两端补零 $P = (K - 1)/2$ ，卷积后输出长度 M

◆ 在早期的文献中，卷积一般默认为**窄卷积**。

◆ 而目前的文献中，卷积一般默认为**等宽卷积**。

◆在图像处理中，图像是以二维矩阵的形式进行存储的，因此我们需要二维卷积。


一个输入信息 X 和滤波器 W 的二维卷积定义为

$$Y = W * X,$$

$$y_{ij} = \sum_{u=1}^U \sum_{v=1}^V w_{uv} x_{i-u+1, j-v+1}.$$


$$\begin{array}{ccccc}
 & & \textcolor{red}{W_{33}} & & \\
 \begin{array}{|c|c|c|c|c|} \hline 1 & 1 & 1 & 1 & 1 \\ \hline -1 & 0 & -3 & 0 & 1 \\ \hline 2 & 1 & 1 & -1 & 0 \\ \hline 0 & -1 & 1 & 2 & 1 \\ \hline 1 & 2 & 1 & 1 & 1 \\ \hline \end{array} & * & \begin{array}{|c|c|c|} \hline \textcolor{red}{W_{11}} & & \\ \hline 1 & 0 & 0 \\ \hline 0 & 0 & 0 \\ \hline 0 & 0 & -1 \\ \hline \end{array} & = & \begin{array}{|c|c|c|} \hline & & \\ \hline 0 & -2 & -1 \\ \hline 2 & 2 & 4 \\ \hline -1 & 0 & 0 \\ \hline \end{array} \\
 & & \textcolor{red}{W_{33}} & &
 \end{array}$$

翻转！




◆ 在卷积的标准定义基础上，还可以引入卷积核的**滑动步长**和**零填充**来增加卷积的多样性，可以更灵活地进行特征抽取。


◆ 卷积核使用不同滑动步长和零填充的效果图：




步长1，零填充0



步长2，零填充0



步长1，零填充1



步长2，零填充1

◆ 公式:

1. 假设输入形状为 $h \times w$, 卷积核窗口形状为 $k_h \times k_w$, 则输出形状为:

$$(h - k_h + 1) \times (w - k_w + 1)$$

2. 假设输入形状为 $h \times w$, 卷积核窗口形状为 $k_h \times k_w$, 在高的两侧一共填充 p_h 行, 在宽的两侧一共填充 p_w 列, 则输出形状为:


$$(h - k_h + p_h + 1) \times (w - k_w + p_w + 1)$$

3. 在2的条件下, 假设高上的步长为 s_h , 宽上的步长为 s_w , 则输出形状为:


$$\lfloor (h - k_h + p_h + s_h) / s_h \rfloor \times \lfloor (w - k_w + p_w + s_w) / s_w \rfloor$$

卷积层

◆ 卷积层替代全连接层



(a) 全连接层



(b) 卷积层

局部连接

权重共享

- ◆ 计算卷积需要进行卷积核**翻转**。
- ◆ 卷积操作的目标：提取特征。**翻转是不必要的操作！**
- ◆ 在具体实现上，一般会以**互相关**操作来代替卷积，从而会减少一些不必要的操作或开销。**除非特别声明，卷积一般指“互相关”**。
互相关的运算公式如下：

$$y_{ij} = \sum_{u=1}^m \sum_{v=1}^n w_{uv} \cdot x_{i+u-1, j+v-1}$$


$$Y = w \otimes X$$

◆ 卷积核当作一个特征提取器

◆ 引入多个卷积核增强卷积层的能力

◆ 卷积层

◆ 卷积层的作用是提取一个局部区域的特征，不同的卷积核相当于不同的特征提取器




◆ 卷积层的多输入通道和多输出通道

◆ 输入：一个三维张量， $M_1 \times N_1 \times D$ ，即D个二维的特征映射，D为输入的通道数

◆ 输出：一个三维张量， $M_2 \times N_2 \times P$ ，即P个二维的特征映射，P为输出的通道数


卷积层的映射关系



$$Z^p = W^p \otimes X + b^p = \sum_{d=1}^D W^{p,d} \otimes X^d + b^p,$$

$$Y^p = f(Z^p).$$



卷积层的映射关系



此图示中的参数:
步长: 2
kernel大小: 3*3
kernel 个数: 6
输入通道数: 3
输出通道数: 2
零填充: 1

◆ 典型的卷积层可以抽象为三维结构

四维



$$Z^p = W^p \otimes X + b^p = \sum_{d=1}^D W^{p,d} \otimes X^d + b^p,$$

$$Y^p = f(Z^p).$$

汇聚层/池化层


◆卷积层虽然可以显著减少连接的个数，但是每一个特征映射的神经元个数并没有显著减少。在卷积层之后加上一个汇聚层，从而降低特征维数，避免过拟合。

◆常用的汇聚函数有两种：

◆最大汇聚 (Max Pooling)

◆平均汇聚 (Mean Pooling)


◆ 汇聚层示意图



卷积神经网络

◆ 卷积网络是由 **卷积层**、**汇聚层**、**全连接层** 交叉堆叠而成。

◆ 典型结构




◆ 一个卷积块为连续M 个卷积层和b个汇聚层（M通常设置为2~5，b为0或1）。
一个卷积网络中可以堆叠N 个连续的卷积块，然后再接着K 个全连接层（N 的取值区间比较大，比如1~100或者更大；K一般为0~2）

◆ 变化趋势：


◆ 趋向于小卷积、大深度

◆ 趋向于全卷积（去掉汇聚层）

卷积神经网络





表示学习




卷积神经网络可视化


◆ 特征图中的高激活区域



Layer 1






Layer 2






卷积神经网络可视化

◆ 特征图中的高激活区域



卷积神经网络可视化


◆ 特征图中的高激活区域



其他类型的卷积


- ◆ 即卷积核的长和宽均为1
- ◆ 可以将 1×1 卷积层看作是在每个像素位置应用的全连接层，其主要作用是通道数量的变换。

- ◆ 空洞卷积是一种不增加参数数量，同时增加输出单元感受野的一种方法，也称为膨胀卷积
- ◆ 空洞卷积通过给卷积核插入“空洞”来变相地增加其大小




使用不同膨胀率D的两个空洞卷积


◆ 从低维特征映射到高维特征，**转置卷积并不是卷积的逆运算**，两个映射只是形式上的转置关系。



卷积



转置卷积



微步卷积

步长 $S < 1$

经典的卷积神经网络

◆ LeNet-5 是一个非常成功的神经网络模型。


◆ 基于 LeNet-5 的手写数字识别系统在 90 年代被美国很多银行使用，用来识别支票上面的手写数字。

◆ LeNet 共有 7 层，由卷积层块和全连接层块两个部分组成。

◆ 卷积层块: 卷积层后接最大汇聚层

◆ 全连接层块: 将卷积层输出的样本展平成一个向量，最后接一个全连接层

◆ LeNet 接受输入图像大小为 32×32 ，输出对应 10 个类别的得分。



Large Scale Visual Recognition Challenge (ImageNet)

2012 Teams	%error
Supervision (Toronto)	15.3
ISI (Tokyo)	26.1
VGG (Oxford)	26.9
XRCE/INRIA	27.0
UvA (Amsterdam)	29.6
INRIA/LEAR	33.4


2013 Teams	%error
Clarifai (NYU spinoff)	11.7
NUS (singapore)	12.9
Zeiler-Fergus (NYU)	13.5
A. Howard	13.5
OverFeat (NYU)	14.1
UvA (Amsterdam)	14.2
Adobe	15.2
VGG (Oxford)	15.2
VGG (Oxford)	23.0

2014 Teams	%error
GoogLeNet	6.6
VGG (Oxford)	7.3
MSRA	8.0
A. Howard	8.1
DeeperVision	9.5
NUS-BST	9.7
TTIC-ECP	10.2
XYZ	11.2
UvA	12.1

(top 5 error of 16% compared to runner-up with 26% error)

- ◆ 第一个现代深度卷积网络模型，并且赢得了2012年ImageNet图像分类竞赛的冠军
 - ◆ 首次使用了很多现代深度卷积网络的一些技术方法
 - ◆ 使用GPU进行并行训练；
 - ◆ 采用了ReLU作为非线性激活函数，使用Dropout防止过拟合；
 - ◆ 使用数据增强。

- ◆ AlexNet的结构包括5个卷积层、3个汇聚层和3个全连接层。
- ◆ AlexNet的输入为 $224 \times 224 \times 3$ 的图像，输出为1 000个类别的条件概率



卷积神经网络可视化

◆ AlexNet中的卷积核 (96 Kernels $[11 \times 11 \times 3]$)




Inception 网络

◆ 2014 ILSVRC winner (22层)

◆ 参数: GoogLeNet: 4M VS AlexNet: 60M

◆ 错误率: 6.7%


◆ Inception网络是由有多个inception模块和少量的汇聚层堆叠而成。



Inception 网络

◆ 在卷积网络中，如何设置卷积层的卷积核大小是一个十分关键的问题。

- ◆ 在Inception网络中，一个卷积层包含多个不同大小的卷积操作，称为Inception模块。
- ◆ Inception模块同时使用 1×1 、 3×3 、 5×5 等不同大小的卷积核，并将得到的特征映射在深度上拼接（堆叠）起来作为输出特征映射。



卷积和最大汇聚都是等宽的。

Inception模块 v3

- ◆ 用 **多层小卷积核** 替换 **大卷积核**，以减少计算量和参数量。
- ◆ 使用两层 3×3 的卷积来替换 v1 中的 5×5 的卷积
- ◆ 使用连续的 $n \times 1$ 和 $1 \times n$ 来替换 $n \times n$ 的卷积。




Figure 5. Inception modules where each 5×5 convolution is replaced by two 3×3 convolution, as suggested by principle 3 of Section 2. <http://blog.csdn.net/xbinworld>





Figure 6. Inception modules after the factorization of the $n \times n$ convolutions. In our proposed architecture, we chose $n = 7$ for the 17×17 grid. (The filter sizes are picked using principle 3) <http://blog.csdn.net/xbinworld>




残差网络(ResNet)

◆ 2015 ILSVRC winner (152层)

◆ 错误率: 3.57%



◆ 残差块/残差单元示意图：



- ◆ 残差网络通过给非线性的卷积层增加**残差连接**的方式来提高信息的传播效率。
- ◆ 在一个深度网络中，我们期望一个非线性单元（可认为是多层的卷积网络） $f(\mathbf{x}; \theta)$ 去逼近一个目标函数 $h(\mathbf{x})$ 时，可以将目标函数拆分成两部分：**恒等函数**和**残差函数**

$$h(\mathbf{x}) = \underbrace{\mathbf{x}}_{\text{恒等函数}} + \underbrace{(h(\mathbf{x}) - \mathbf{x})}_{\text{残差函数}} \longrightarrow f(\mathbf{x}, \theta)$$

- ◆ 原来的优化问题可以转换为：让非线性单元 $f(\mathbf{x}; \theta)$ 去近似残差函数 $h(\mathbf{x}) - \mathbf{x}$ ，并用 $f(\mathbf{x}; \theta) + \mathbf{x}$ 去逼近 $h(\mathbf{x})$ 。

$$\frac{\partial f(g(x))}{\partial x} = \frac{\partial g(x)}{\partial x} \cdot \frac{\partial f(g(x))}{\partial g(x)}$$



$$\frac{\partial f(g(x)) + g(x)}{\partial x} = \boxed{\frac{\partial g(x)}{\partial x} \cdot \frac{\partial f(g(x))}{\partial g(x)}} + \frac{\partial g(x)}{\partial x}$$

◆ 具有不同数量残差块的残差网络结构

layer name	output size	18-layer	34-layer	50-layer	101-layer	152-layer
conv1	112×112	7×7, 64, stride 2				
conv2_x	56×56	3×3 max pool, stride 2				
		$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 64 \\ 3 \times 3, 64 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 64 \\ 3 \times 3, 64 \\ 1 \times 1, 256 \end{bmatrix} \times 3$
conv3_x	28×28	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 128 \\ 3 \times 3, 128 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 4$	$\begin{bmatrix} 1 \times 1, 128 \\ 3 \times 3, 128 \\ 1 \times 1, 512 \end{bmatrix} \times 8$
conv4_x	14×14	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 256 \\ 3 \times 3, 256 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 6$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 23$	$\begin{bmatrix} 1 \times 1, 256 \\ 3 \times 3, 256 \\ 1 \times 1, 1024 \end{bmatrix} \times 36$
conv5_x	7×7	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 2$	$\begin{bmatrix} 3 \times 3, 512 \\ 3 \times 3, 512 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$	$\begin{bmatrix} 1 \times 1, 512 \\ 3 \times 3, 512 \\ 1 \times 1, 2048 \end{bmatrix} \times 3$
	1×1	average pool, 1000-d fc, softmax				
FLOPs		1.8×10^9	3.6×10^9	3.8×10^9	7.6×10^9	11.3×10^9

CNN 近年新进展

OverLoCK (CVPR 2025)



This CVPR paper is the Open Access version, provided by the Computer Vision Foundation.

Except for this watermark, it is identical to the accepted version;
the final published version of the proceedings is available on IEEE Xplore.






OverLoCK: An Overview-first-LoCK-Closely-next ConvNet with Context-Mixing Dynamic Kernels

Meng Lou


Yizhou Yu

School of Computing and Data Science, The University of Hong Kong


loumeng@connect.hku.hk, yizhouy@acm.org



可视化效果



卷积神经网络的应用



The input to the policy network is a $19 \times 19 \times 48$ image stack consisting of 48 feature planes. The first hidden layer zero pads the input into a 23×23 image, then convolves k filters of kernel size 5×5 with stride 1 with the input image and applies a rectifier nonlinearity. Each of the subsequent hidden layers 2 to 12 zero pads the respective previous hidden layer into a 21×21 image, then convolves k filters of kernel size 3×3 with stride 1, again followed by a rectifier nonlinearity. The final layer convolves 1 filter of kernel size 1×1 with stride 1, with a different bias for each position, and applies a softmax function. The match version of AlphaGo used $k = 192$ filters; Fig. 2b and Extended Data Table 3 additionally show the results of training with $k = 128, 256$ and 384 filters.

policy network:

[19x19x48] Input

CONV1: 192 5x5 filters, stride 1, pad 2 => [19x19x192]

CONV2..12: 192 3x3 filters, stride 1, pad 1 => [19x19x192]

CONV: 1 1x1 filter, stride 1, pad 0 => [19x19] (*probability map of promising moves*)


分布式系统: 1202 个CPU 和176 块GPU

单机版: 48 个CPU 和8 块GPU

走子速度: 3 毫秒-2 微秒

- ◆ 目标检测 (Object Detection) 输出:
 - ◆ 检测框坐标; 物体类别; 物体置信度

R-CNN
(Region-CNN)



◆ 实例分割(Instence Segmentation)输出:

◆ 属于不同实例的像素的模板



- ◆ 光学文字识别(OCR)输出:
 - ◆ 属于文字区域的像素的模板




	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
is	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
at	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
in	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
not	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
(past tense)	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
country	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
on	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
have	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
large	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
for	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
year	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
this	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
(individual)	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
out	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
time	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
minute	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
people	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
city	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
do	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到
to	是	在	中	不	了	国	上	有	大	为	年	这	个	出	时	分	人	市	行	到

风格迁移



"i hate cigarettes with a passion"



- ◆ **截止时间：** 下周日晚9:00
- ◆ **提交方式：** 每人作业以 pdf 格式提交，命名为“学号_姓名”，班长收齐将全班作业压缩包发送到邮箱：nuoxu25@mails.jlu.edu.cn（许诺）
- ◆ **作业晚交政策：** 作业超过截止时间但在24小时以内，该次作业按照60%分数计算，超过24小时不计分

习题 5-3 分析卷积神经网络中用 1×1 的卷积核的作用.

习题 5-8 在空洞卷积中,当卷积核大小为 K ,膨胀率为 D 时,如何设置零填充 P 的值以使得卷积为等宽卷积.