

《神经网络与深度学习》

第六章-循环神经网络

人工智能学院

杨溪

➤ 模型

- 6.1 给网络增加记忆能力
- 6.2 简单循环神经网络

➤ 学习

- 6.3 应用到机器学习
- 6.4 参数学习
- 6.5 长程依赖问题

➤ 改进

- 6.6 LSTM与GRU
- 6.7 深层循环神经网络

➤ 应用

- 6.8 循环网络应用

➤ 扩展


- 6.9 扩展到图结构

◆ 存在一些问题：

◆ 相邻层之间存在单向连接，层内无连接。（有向无环图）


◆ 输入和输出的维数都是固定的，不能任意改变。无法处理变长的序列数据。

◆ 假设每次输入都是独立的，网络的输出只依赖于当前的输入，与之前输入的数据完全无关。（没有记忆能力）




(a) 全连接层

如何给网络增加记忆能力？




(b) 卷积层

◆ 下一个时刻的状态（输出）不仅仅和当前输入相关，也和当前状态（上一个时刻的输出）相关




如何用神经网络模拟一个有限状态自动机？

◆ 一种抽象数学模型，可以用来模拟任何可计算问题。



如何用神经网络模拟一个图灵机？




$$y = f(x)$$

前馈神经网络
通用近似定理

$$s_{t+1} = f(x, s_t)$$

需要记忆能力


$$y_t = f(x_t, \boxed{M})$$



具有“记忆”的网络

- ◆ 在前馈网络中的非输出层都添加一个时延单元，用来存储网络的历史信息（可以包括输入、输出、隐状态等）。这样，前馈网络就具有了短期记忆的能力。

$$\mathbf{h}_t^{(l)} = f(\mathbf{h}_t^{(l-1)}, \mathbf{h}_{t-1}^{(l-1)}, \dots, \mathbf{h}_{t-K}^{(l-1)})$$



- ◆ 自回归模型是统计学上常用的一类时间序列模型，用一个变量 y_t 的历史信息来预测自己。

$$y_t = w_0 + \sum_{k=1}^K w_k y_{t-k} + \epsilon_t$$

ϵ_t 时刻的噪声，服从正态分布

- ◆ 有外部输入的非线性自回归模型

$$y_t = f(x_t, x_{t-1}, \dots, x_{t-K_x}, y_{t-1}, y_{t-2}, \dots, y_{t-K_y})$$

- ◆ 其中 $f(\cdot)$ 表示非线性函数, x_t 为在时刻 t 的一个外部输入


循环神经网络

◆ 循环神经网络通过使用带自反馈的神经元，能够处理任意长度的时序数据。

◆ 隐藏层的更新公式：



$$h_t = f(h_{t-1}, x_t)$$

活性值
隐状态



- ◆ 循环神经网络比前馈神经网络更加符合生物神经网络的结构
- ◆ 循环神经网络已经被广泛应用于语音识别、语言模型以及自然语言生成等任务上
- ◆ 作用：
 - ◆ 输入-输出映射（机器学习模型）
 - ◆ 存储器（联想记忆模型）

◆ 循环神经网络可以看作在时间维度上权值共享的神经网络，其按时间展开的图示如下：



◆ 状态更新

$$\mathbf{h}_t = f(\mathbf{U}\mathbf{h}_{t-1} + \mathbf{W}\mathbf{x}_t + \mathbf{b})$$

◆ 一个完全连接的循环网络是任何非线性动力系统的近似器。

定理 6.1 – 循环神经网络的通用近似定理 [Haykin, 2009]: 如果一个完全连接的循环神经网络有足够数量的 sigmoid 型隐藏神经元, 它可以以任意的准确率去近似任何一个非线性动力系统

$$\mathbf{s}_t = g(\mathbf{s}_{t-1}, \mathbf{x}_t), \quad (6.10)$$

$$\mathbf{y}_t = o(\mathbf{s}_t), \quad (6.11)$$

其中 $\mathbf{s}_t$ 为每个时刻的隐状态, $\mathbf{x}_t$ 是外部输入, $g(\cdot)$ 是可测的状态转换函数, $o(\cdot)$ 是连续输出函数, 并且对状态空间的紧致性没有限制。

- ◆ 图灵机一种抽象数学模型，可以用来模拟任何可计算问题。
图灵完备（Turing Completeness）是指一种数据操作规则，比如一种编程语言，可以实现图灵机的所有功能，解决所有的可计算问题。

定理 6.2 – 图灵完备 [Siegelmann et al., 1991]: 所有的图灵机都可以被一个由使用 **Sigmoid** 型激活函数的神经元构成的全连接循环网络来进行模拟。

- ◆ 一个完全连接的循环神经网络可以近似解决所有的可计算问题。


应用到机器学习

◆循环神经网络可以解决的机器学习任务


- ◆序列到类别
- ◆同步的序列到序列模式
- ◆异步的序列到序列模式

◆ 输入为序列，输出为类别

历史信息传递长




(a) 正常模式




(b) 按时间进行平均采样模式


◆ 文本情感分类



◆ 主要用于序列标注任务，输入序列和输出序列的长度相同。




◆ 中文分词





◆ 信息抽取(Information Extraction, IE)

◆ 从无结构的文本中抽取结构化的信息，形成知识


小米创始人雷军表示，该公司2015年营收达到780亿元人民币，较2014年的743亿元人民币增长了5%。




◆ 语音识别




- ◆ 输入序列和输出序列不需要有严格的对应关系，也不需要保持相同的长度，也称为**编码器-解码器**（Encoder-Decoder）模型



◆ 机器翻译



Neural Machine Translation SEQUENCE TO SEQUENCE MODEL WITH ATTENTION




参数学习

◆ 循环神经网络在每个时刻 t ，都有一个监督信息 y_t 。定义时刻 t 的损失函数为

$$\mathcal{L}_t = \mathcal{L}(y_t, g(\mathbf{h}_t)),$$

◆ 整个序列的总损失函数为


$$\mathcal{L} = \sum_{t=1}^T \mathcal{L}_t.$$



◆ 梯度计算公式

$$\frac{\partial \mathcal{L}}{\partial U} = \sum_{t=1}^T \sum_{k=1}^t \delta_{t,k} \mathbf{h}_{k-1}^T \quad \delta_{t,k} = \prod_{\tau=k}^{t-1} \left(\text{diag}(f'(\mathbf{z}_{\tau})) U^T \right) \delta_{t,t}$$

◆ 由于梯度爆炸或消失问题，实际上只能学习到短周期的依赖关系。这就是所谓的 **长程依赖问题**



◆在时间维度上非常深

◆改进办法

◆梯度爆炸问题

◆权重衰减

◆梯度截断

◆梯度消失问题

◆改进模型

◆ 改进模型

◆ 循环边改为线性依赖关系 (模型能力变差)

$$\mathbf{h}_t = \mathbf{h}_{t-1} + g(\mathbf{x}_t; \theta)$$

◆ 增加非线性

(梯度爆炸、记忆容量)

$$\mathbf{h}_t = \mathbf{h}_{t-1} + g(\mathbf{x}_t, \mathbf{h}_{t-1}; \theta)$$

$$\mathbf{z}_t = \mathbf{U}\mathbf{h}_{t-1} + \mathbf{W}\mathbf{x}_t + \mathbf{b}$$

$$\mathbf{h}_t = f(\mathbf{z}_t)$$

$$\begin{aligned} \delta_{t,k} &= \text{diag}(f'(\mathbf{z}_k))\mathbf{U}^\top \delta_{t,k+1} \\ &= \prod_{\tau=k}^{t-1} \left(\text{diag}(f'(\mathbf{z}_\tau))\mathbf{U}^\top \right) \delta_{t,t} \end{aligned}$$



1

LSTM与GRU

◆ 引入门控机制 (Gating Mechanism) 来控制信息传递的路径。

◆ 有选择地加入新的信息，并有选择地遗忘之前累计的信息。

- 门控机制：

在数字电路中，门 (gate) 为一个二值变量 $\{0, 1\}$ ，0代表关闭状态，不允许任何信息通过；1代表开放状态，允许所有信息通过。

◆ 基于门控的循环神经网络 (Gated RNN)

◆ 长短期记忆网络 (LSTM)

Hochreiter and Schmidhuber, “Long Short Term Memory”, Neural Computation 1997

◆ 门控循环单元 (GRU)

Chung J, Gulcehre C, Cho K H, et al, “ Empirical Evaluation of Gated Recurrent Neural Networks on Sequence Modeling ”, 2014

- ◆ 引入一个新的内部状态 $\mathbf{c}_t$ 进行线性的循环信息传递，同时（非线性地）输出外部状态

$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t,$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t),$$

$\mathbf{c}$ - Memory Cell state
 $\mathbf{i}$ - Input gate
 $\mathbf{f}$ - Forget gate
 $\mathbf{o}$ - Output gate

- ◆ 引入门控机制 (Gating Mechanism)
 - ◆ 遗忘门 $\mathbf{f}_t$ 控制上一个时刻的内部状态 $\mathbf{c}_{t-1}$ 需要遗忘多少信息;
 - ◆ 输入门 $\mathbf{i}_t$ 控制当前时刻的候选状态 $\tilde{\mathbf{c}}_t$ 有多少信息需要保存;
 - ◆ 输出门 $\mathbf{o}_t$ 控制当前时刻的内部状态 $\mathbf{c}_t$ 有多少信息需要输出给外部状态 $\mathbf{h}_t$ 。

◆ 长短期记忆神经网络示意图

$$\tilde{c}_t = \tanh(W_c \mathbf{x}_t + U_c \mathbf{h}_{t-1} + \mathbf{b}_c)$$


$$\mathbf{c}_t = \mathbf{f}_t \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t,$$

$$\mathbf{h}_t = \mathbf{o}_t \odot \tanh(\mathbf{c}_t),$$

$$\mathbf{i}_t = \sigma(W_i \mathbf{x}_t + U_i \mathbf{h}_{t-1} + \mathbf{b}_i),$$

$$\mathbf{f}_t = \sigma(W_f \mathbf{x}_t + U_f \mathbf{h}_{t-1} + \mathbf{b}_f),$$

$$\mathbf{o}_t = \sigma(W_o \mathbf{x}_t + U_o \mathbf{h}_{t-1} + \mathbf{b}_o),$$



◆取消遗忘门

$$\mathbf{c}_t = \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t.$$

◆耦合输入门和遗忘门

$$\mathbf{f}_t = 1 - \mathbf{i}_t$$

$$\mathbf{c}_t = (1 - \mathbf{i}_t) \odot \mathbf{c}_{t-1} + \mathbf{i}_t \odot \tilde{\mathbf{c}}_t$$

◆peephole连接

$$\mathbf{i}_t = \sigma(W_i \mathbf{x}_t + U_i \mathbf{h}_{t-1} + \underline{V_i \mathbf{c}_{t-1}} + \mathbf{b}_i),$$

$$\mathbf{f}_t = \sigma(W_f \mathbf{x}_t + U_f \mathbf{h}_{t-1} + \underline{V_f \mathbf{c}_{t-1}} + \mathbf{b}_f),$$

$$\mathbf{o}_t = \sigma(W_o \mathbf{x}_t + U_o \mathbf{h}_{t-1} + \underline{V_o \mathbf{c}_t} + \mathbf{b}_o),$$

循环神经网络中隐藏状态的更新方式: $\mathbf{h}_t = \mathbf{h}_{t-1} + g(\mathbf{x}_t, \mathbf{h}_{t-1}; \theta)$



GRU: $\mathbf{h}_t = \mathbf{z}_t \odot \mathbf{h}_{t-1} + (1 - \mathbf{z}_t) \odot \underline{g(\mathbf{x}_t, \mathbf{h}_{t-1}; \theta)}$, $\mathbf{z}_t \in [0, 1]^D$

$\mathbf{h}_t = \mathbf{z}_t \odot \mathbf{h}_{t-1} + (1 - \mathbf{z}_t) \odot \underline{\tilde{\mathbf{h}}_t}$

◆ GRU 网络引入一个更新门来控制当前状态 $\mathbf{h}_t$ 需要从历史状态 $\mathbf{h}_{t-1}$ 中保留多少信息;

◆ GRU 网络直接使用一个重置门控制当前时刻的候选状态 $\tilde{\mathbf{h}}_t$ 是否依赖上一时刻的状态。

更新门


$$\mathbf{z}_t = \sigma(\mathbf{W}_z \mathbf{x}_t + \mathbf{U}_z \mathbf{h}_{t-1} + \mathbf{b}_z)$$

重置门

$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h \mathbf{x}_t + \mathbf{U}_h (\mathbf{r}_t \odot \mathbf{h}_{t-1}) + \mathbf{b}_h)$$

$$\mathbf{r}_t = \sigma(\mathbf{W}_r \mathbf{x}_t + \mathbf{U}_r \mathbf{h}_{t-1} + \mathbf{b}_r)$$

◆GRU 模块图示



重置门

$$\mathbf{r}_t = \sigma(\mathbf{W}_r \mathbf{x}_t + \mathbf{U}_r \mathbf{h}_{t-1} + \mathbf{b}_r)$$

更新门

$$\mathbf{z}_t = \sigma(\mathbf{W}_z \mathbf{x}_t + \mathbf{U}_z \mathbf{h}_{t-1} + \mathbf{b}_z)$$


$$\tilde{\mathbf{h}}_t = \tanh(\mathbf{W}_h \mathbf{x}_t + \mathbf{U}_h (\mathbf{r}_t \odot \mathbf{h}_{t-1}) + \mathbf{b}_h)$$

$$\mathbf{h}_t = \mathbf{z}_t \odot \mathbf{h}_{t-1} + (1 - \mathbf{z}_t) \odot \tilde{\mathbf{h}}_t$$


深层模型

- ◆ 增加循环神经网络的深度主要是**增加同一时刻网络输入到输出之间的路径**，比如增加隐状态到输出或是输入到隐状态之间的路径的深度。
- ◆ 堆叠循环神经网络
- ◆ 双向循环神经网络

◆ 简单地将多个循环网络堆叠起来



◆ 由两层循环神经网络组成，它们的输入相同，但信息传递的方向不同。



◆ 优点:

- ◆ 引入记忆
- ◆ 图灵完备



◆ 缺点:

- ◆ 长程依赖问题
- ◆ 记忆容量问题
- ◆ 并行能力


扩展到图结构



◆建模句子的语义，如以树结构表示的程序语言和自然语言的句法



◆ 递归神经网络是循环神经网络在**有向无循环图**上的扩展




$$\mathbf{h}_i = f(\mathbf{h}_{\pi_i})$$

父节点

$$\begin{aligned}\mathbf{h}_1 &= f\left(W \begin{bmatrix} \mathbf{x}_1 \\ \mathbf{x}_2 \end{bmatrix} + \mathbf{b}\right), \\ \mathbf{h}_2 &= f\left(W \begin{bmatrix} \mathbf{x}_3 \\ \mathbf{x}_4 \end{bmatrix} + \mathbf{b}\right), \\ \mathbf{h}_3 &= f\left(W \begin{bmatrix} \mathbf{h}_1 \\ \mathbf{h}_2 \end{bmatrix} + \mathbf{b}\right),\end{aligned}$$

◆ 当递归神经网络的结构退化为线性序列结构时，就等价于简单循环网络




$$h_t = f(h_{t-1}, x_t),$$


- ◆ 前馈网络和循环网络很难处理图结构的数据，比如知识图谱、社交网络、分子网络等。
- ◆ 图神经网络（Graph Neural Network, GNN）是将消息传递的思想扩展到图结构数据上的神经网络。

◆ 图结构数据

(a) Molecule




(b) Mass-Spring System




(c) n -body System




(d) Rigid Body System




(e) Sentence and Parse Tree



(f) Image and Fully-Connected Scene Graph



◆ 图结构 $G(V, E)$



◆ 对于一个任意的图结构 $G(V, E)$

◆ 初始状态可以为节点的输入特征。每个节点可以收到来自相邻节点的消息状态，通过更新函数更新状态


$$\mathbf{m}_t^{(v)} = \sum_{u \in N(v)} f(\mathbf{h}_{t-1}^{(v)}, \mathbf{h}_{t-1}^{(u)}, \mathbf{e}^{(u,v)})$$

$$\mathbf{h}_t^{(v)} = g(\mathbf{h}_{t-1}^{(v)}, \mathbf{m}_t^{(v)})$$


◆ 在整个图更新 T 次后，可以通过一个读出函数来得到整个网络的表示

$$\mathbf{y}_t = g(\{\mathbf{h}_T^{(v)} | v \in \mathcal{V}\})$$


◆ 图神经网络的更新过程:



(a) Edge update



(b) Node update



(c) Global update

循环神经网络应用

◆ 自然语言理解是判断一个句子的可能性/合理性

◆ 可个断一性判子的能句 ?????

◆ 在N元语言模型中，一切都是概率！

$$P(x_1, x_2, \dots, x_T) = \prod_i P(x_i | x_{i-1}, \dots, x_1)$$
$$\approx \prod_i P(x_i | x_{i-1}, \dots, x_{i-n+1})$$


◆作诗，作词

满怀风月一枝春，
Budding branches are full of romance.
未见梅花亦可人。
Plum blossoms are invisible but adorable.
不为东风无此客，
With the east wind comes Spring.
世间何处是前身。
Where on earth do I come from?


我在这里中的夜里
就像一场是一种生命的意时
就像我的生活变得在我一样
可我们这是一个知道
我只是一天你会怎吗
可我们这是我们的的是不要为你
我们想这有一种生活的时候

◆ 源语言: f $\longrightarrow$ 目标语言: e


◆ 模型: $\hat{e} = \operatorname{argmax}_e p(e|f) = \operatorname{argmax}_e p(f|e)p(e)$




◆ 一个RNN用来编码，另一个RNN用来解码



◆ 看图说话





- ◆ **截止时间：** 下周日晚9:00
- ◆ **提交方式：** 每人作业以 pdf 格式提交，命名为“学号_姓名”，班长收齐将全班作业压缩包发送到邮箱: nuoxu25@mails.jlu.edu.cn(许诺)
- ◆ **作业晚交政策：** 作业超过截止时间但在24小时以内，该次作业按照60%分数计算，超过24小时不计分

习题 6-1 分析延时神经网络、卷积神经网络和循环神经网络的异同点.

习题 6-3 当使用公式(6.50)作为循环神经网络的状态更新公式时,分析其可能存在梯度爆炸的原因并给出解决方法.

$$\mathbf{h}_t = \mathbf{h}_{t-1} + g(\mathbf{x}_t, \mathbf{h}_{t-1}; \theta), \quad (6.50)$$